

2 Matrixalgebra

Wie wir gesehen haben, hängt die Lösungsmenge eines LGS $A\mathbf{x} = \mathbf{b}$ im Wesentlichen von der Beschaffenheit der Matrix A ab. Es liegt deshalb nahe, sich tiefergehend mit solchen Matrizen auseinanderzusetzen. Insbesondere definieren wir nützliche Operationen auf solchen Matrizen, wie zum Beispiel die Summe $A+B$ oder das Produkt AB . Dies wird es uns erheblich erleichtern, Lösungsmengen zu analysieren und lineare Probleme zu verstehen.

2.1 Matrixoperationen

2.1.1 Addition und Skalarmultiplikation

Definition 2.1.1. Für Matrizen $A, B \in \mathbb{R}^{m \times n}$ und $c \in \mathbb{R}$ definieren wir

$$A + B = \begin{pmatrix} a_{11} + b_{11} & \cdots & a_{1n} + b_{1n} \\ & \vdots & \\ a_{m1} + b_{m1} & \cdots & a_{mn} + b_{mn} \end{pmatrix}$$

und

$$cA = \begin{pmatrix} ca_{11} & \cdots & ca_{1n} \\ & \vdots & \\ ca_{m1} & \cdots & ca_{mn} \end{pmatrix}$$

Anmerkung 2.1.2. Beachte, dass die Matrizen A und B die gleichen Dimensionen haben müssen, sonst ist $A + B$ nicht definiert.

Wir definieren außerdem die **Nullmatrix** $0 \in \mathbb{R}^{m \times n}$ als die Matrix, bei der alle Einträge gleich 0 sind. Das folgende Resultat folgt dann direkt aus den Eigenschaften der Addition und Multiplikation von reellen Zahlen.

Theorem 2.1.3. Seien $A, B, C \in \mathbb{R}^{m \times n}$ und $r, s \in \mathbb{R}$. Dann gilt:

- (i) $A + B = B + A$
- (ii) $(A + B) + C = A + (B + C)$
- (iii) $A + 0 = A$
- (iv) $r(A + B) = rA + rB$
- (v) $(r + s)A = rA + sA$
- (vi) $r(sA) = (rs)A$.

Anmerkung 2.1.4. Zusammen mit den Regeln für das Matrix-Vektor-Produkt (*Theorem 1.7.5*), bekommen wir zum Beispiel $A\mathbf{x} + B\mathbf{x} = (A + B)\mathbf{x}$. Die rechte Seite definiert also eine neue lineare Abbildung $\mathbf{x} \mapsto (A + B)\mathbf{x}$, die sich ergibt, wenn man die Resultate von $\mathbf{x} \mapsto A\mathbf{x}$ und $\mathbf{x} \mapsto B\mathbf{x}$ addiert.

2.1.2 Multiplikation

Definition 2.1.5. Sei $A \in \mathbb{R}^{m \times k}$ und $B \in \mathbb{R}^{k \times n}$. Dann definieren wir das **Matrixprodukt** AB als die Matrix

$$AB = (A\mathbf{b}_1 \cdots A\mathbf{b}_n) \in \mathbb{R}^{m \times n},$$

wobei $\mathbf{b}_1, \dots, \mathbf{b}_n$ die Spalten von B sind.

Anmerkung 2.1.6. Beachte, dass das Produkt AB nur definiert ist, wenn die Anzahl der Spalten in A gleich der Anzahl der Zeilen in B ist.

Anmerkung 2.1.7. Das Matrix-Vektor-Produkt $A\mathbf{b}$ kann als Spezialfall der Matrixmultiplikation verstanden werden, in dem wir $\mathbf{b}$ als Matrix mit nur einer Spalte auffassen, also $\mathbf{b} \in \mathbb{R}^{n \times 1}$.

Die Spalten des Matrixprodukts AB lassen sich also durch Matrix-Vektor-Multiplikation von A mit den Spalten von B berechnen. Die einzelnen Einträge bekommen wir durch die **Zeilen-Spalten-Regel**:

$$(AB)_{ij} = a_{i1}b_{1j} + \cdots a_{in}b_{nj}.$$

Den Eintrag von AB in der i -ten Zeile und j -ten Spalten bekommen wir, indem wir alle Einträge der i -ten Zeile von A und der j -ten Spalte von B multiplizieren

und summieren. Eine zeilenweise Darstellung bekommen wir über die Zeilen $\mathbf{a}_1, \dots, \mathbf{a}_m$ von A :

$$AB = \begin{pmatrix} \mathbf{a}_1 B \\ \vdots \\ \mathbf{a}_m B \end{pmatrix},$$

wobei wir die **Zeilenvektoren** $\mathbf{a}_j$ hier als Matrix in $\mathbb{R}^{1 \times k}$ verstehen.

Das Matrixprodukt AB lässt sich über die Verbindung zu linearen Abbildungen verstehen. Wir starten mit einem Vektor $\mathbf{x} \in \mathbb{R}^n$. Durch Multiplikation mit der Matrix B erhalten wir einen neuen Vektor $\mathbf{y} = B\mathbf{x} \in \mathbb{R}^k$. Diesen Vektor transformieren wir durch Multiplikation mit A und erhalten als Endresultat ein $\mathbf{z} \in \mathbb{R}^m$, nämlich $\mathbf{z} = A\mathbf{y} = A(B\mathbf{x}) = (AB)\mathbf{x}$. Die Rechenformel in [Definition 2.1.5](#) lässt sich daraus leicht herleiten, denn

$$A(B\mathbf{x}) = A(x_1\mathbf{b}_1 + \dots + x_n\mathbf{b}_n) = x_1(A\mathbf{b}_1) + \dots + x_n(A\mathbf{b}_n).$$

Das Matrixprodukt AB beschreibt also die Verkettung von zwei linearen Abbildungen. Zum Beispiel kann A um den Faktor 0.5 entlang einer Achse stauchen und B einen Punkt um 45° rotieren. AB ist dann die Matrix der Abbildung, die zuerst um 45° rotiert und dann um den Faktor 0.5 staucht.

Die Rechenregeln für Multiplikation von Matrizen sind weitestgehend ähnlich zu denen von reellen Zahlen. Dazu definieren wir die **Einheitsmatrix** (auch *Identitätsmatrix*) $I_n \in \mathbb{R}^{n \times n}$ als Matrix mit Diagonaleinträgen gleich 1 und allen anderen Einträgen gleich 0:

$$I_n = \begin{pmatrix} 1 & 0 & \dots & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 \\ \vdots & & \ddots & & \vdots \\ 0 & \dots & 0 & 1 & 0 \\ 0 & \dots & \dots & 0 & 1 \end{pmatrix}.$$

Theorem 2.1.8 (Rechenregeln Matrixmultiplikation). Sei $A \in \mathbb{R}^{m \times n}$ und B, C weitere Matrizen, sodass die untenstehenden Summen und Produkte wohldefiniert sind.

- (i) $A(BC) = (AB)C$,
- (ii) $A(B + C) = AB + AC$,
- (iii) $(B + C)A = BA + CA$,
- (iv) $c(AB) = (cA)B = A(cB)$ für jedes $c \in \mathbb{R}$,
- (v) $I_m A = A = A I_n$.

Beweis. Die Eigenschaften lassen sich direkt nachrechnen. Zum Beispiel gilt

$$(i) \quad A(BC) = A(B\mathbf{c}_1 \cdots B\mathbf{c}_n) = (AB\mathbf{c}_1 \cdots AB\mathbf{c}_n) = (AB)C.$$

Beweise der weiteren Eigenschaften überlassen wir als Übungsaufgabe. $\square$

Im Vergleich zu Multiplikation von reellen Zahlen ist bemerkenswert, dass die Kommutativität $AB = BA$ fehlt. Das kann schon deshalb nicht allgemein gelten, weil die Dimensionen von A und B oft nur eins der beiden Produkte zulassen. Ist zum Beispiel $A \in \mathbb{R}^{3 \times 2}$ und $B \in \mathbb{R}^{2 \times 4}$, dann ist AB definiert, BA aber nicht. Doch selbst, wenn die Dimension passen (z.B. bei *quadratischen* Matrizen $A, B \in \mathbb{R}^{n \times n}$), gilt im Allgemeinen nicht $AB = BA$. Die Reihenfolge der $\mathbb{R}^2 \rightarrow \mathbb{R}^2$ Transformationen aus [Abschnitt 1.10.2](#) spielt ja auch intuitiv eine Rolle (erst entlang der x_1 -Achse strecken und dann rotieren ist etwas anderes als zuerst zu rotieren und dann entlang x_1 -Achse zu strecken). Um diesen Umstand zu betonen sagen wir zu AB manchmal, dass B *von links* mit A multipliziert wird, oder A *von rechts* mit B .

Beispiel 2.1.9. Sei

$$A = \begin{pmatrix} 2 & 4 \\ 1 & 1 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & 0 \\ 2 & -1 \end{pmatrix}.$$

Dann ist

$$AB = \begin{pmatrix} 10 & -4 \\ 3 & -1 \end{pmatrix}, \quad BA = \begin{pmatrix} 2 & 4 \\ 3 & 7 \end{pmatrix}.$$

Es gibt noch einen weiteren Fallstrick. Ist $AB = 0$, können wir daraus nicht schließen, dass $A = 0$ oder $B = 0$.

Beispiel 2.1.10.

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}, \quad B = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}.$$

Dann ist $AB = 0$ aber $A, B \neq 0$.

Daraus folgend, bedeutet $AB = AC$ im Allgemeinen auch nicht, dass $B = C$. Wir können also nicht einfach „durch A teilen“. Wann das möglich ist, lernen wir in Kürze.

Indem wir eine Matrix mehrmals mit sich selbst multiplizieren können wir außerdem Potenzen A^n einer Matrix definieren. Solche Potenzen werden sich später noch als nützlich erweisen.

Definition 2.1.11. Die n -te Potenz einer Matrix A ist $A^n = \underbrace{A \cdots A}_{n \text{ mal}}$.

Wir haben gesehen, dass die Verkettung zweier Matrix-Vektor-Multiplikationen wieder eine lineare Abbildung beschreibt. Dies ist eine wichtige Eigenschaft, die wir auch allgemeiner beweisen können.

Theorem 2.1.12. *Seien $T_1: D \rightarrow E$ und $T_2: E \rightarrow W$ lineare Abbildungen. Dann ist auch die Abbildung $T := T_2 \circ T_1: D \rightarrow W$ mit $T(x) = T_2(T_1(x))$ linear.*

Beweis. Für alle $x, y \in D$ gilt

$$\begin{aligned} T(x + y) &= T_2(T_1(x + y)) \\ [T_1 \text{ linear}] &= T_2(T_1(x) + T_1(y)) \\ [T_2 \text{ linear}] &= T_2(T_1(x)) + T_2(T_1(y)) \\ &= T(x) + T(y) \end{aligned}$$

und

$$\begin{aligned} T(cx) &= T_2(T_1(cx)) \\ [T_1 \text{ linear}] &= T_2(cT_1(x)) \\ [T_2 \text{ linear}] &= cT_2(T_1(x)) \\ &= cT(x). \end{aligned}$$

□

2.1.3 Transposition

Bei der *Transposition* einer Matrix werden die Rollen von Zeilen und Spalten getauscht.

Definition 2.1.13. *Die Transposition $A^\top \in \mathbb{R}^{n \times m}$ einer Matrix $A \in \mathbb{R}^{m \times n}$ ist definiert durch $(A^\top)_{ij} = A_{ji}$ für alle $i \in 1, \dots, n$ und $j = 1, \dots, m$.*

Beispiel 2.1.14.

$$A = \begin{pmatrix} 1 & -2 & 3 \\ 0 & 3 & 4 \end{pmatrix} \quad \Rightarrow \quad A^\top = \begin{pmatrix} 1 & 0 \\ -2 & 3 \\ 3 & 4 \end{pmatrix}.$$

Die folgenden Eigenschaften lassen sich dann leicht nachrechnen.

Theorem 2.1.15. Seien A und B zwei Matrizen, sodass die folgenden Operationen wohldefiniert sind. Dann gilt:

$$(i) \quad (A^\top)^\top = A$$

$$(ii) \quad (A + B)^\top = A^\top + B^\top$$

$$(iii) \quad (cA)^\top = cA^\top \text{ f\"ur jedes } c \in \mathbb{R},$$

$$(iv) \quad (AB)^\top = B^\top A^\top.$$

2.2 Inverse

2.2.1 Inverse Matrizen

Wir sind vorher auf ein Problem beim Vereinfachen von Matrixgleichungen gestoßen: aus $AB = AC$ folgt nicht $B = C$. Für reelle Zahlen $A, B, C \in \mathbb{R}$ klappt das, falls $A \neq 0$. Dann können wir beide Seiten durch A teilen. Die Zahl $A^{-1} = 1/A$ nennen wir dabei (multiplikative) Inverse zu A . Wir wollen solche Inversen nun auch für Matrizen definieren.

Definition 2.2.1. Sei $A \in \mathbb{R}^{n \times n}$ gegeben. Wenn es eine Matrix $B \in \mathbb{R}^{n \times n}$ gibt, sodass $AB = BA = I_n$, nennen wir A **invertierbar** und bezeichnen B als **inverse Matrix** zu A . Wenn es keine inverse Matrix gibt, nennen wir A **singulär**.

Die Matrix B in der Definition schreiben wir normalerweise als A^{-1} und bezeichnen sie als „die“ Inverse. Damit gelten die Regeln

$$A^{-1}A = I_n, \quad AA^{-1} = I_n.$$

Diese Notation ist unbedenklich, weil eine invertierbare Matrix nur genau eine Inverse haben kann.

Lemma 2.2.2. Sind B und C zwei inverse Matrizen zu A , dann ist $B = C$.

Beweis. Es gilt $BA = I_n$. Multiplizieren wir beide Seiten von rechts mit C , erhalten wir $(BA)C = IC = C$. Andererseits gilt $(BA)C = B(AC) = BI_n = B$. Also gilt $B = C$. $\square$

Es gelten die folgenden Regeln.

Theorem 2.2.3.

(i) Ist A invertierbar, dann ist auch A^{-1} invertierbar und

$$(A^{-1})^{-1} = A.$$

(ii) Sind $A, B \in \mathbb{R}^{n \times n}$ invertierbar, dann ist auch AB invertierbar und

$$(AB)^{-1} = B^{-1}A^{-1}.$$

(iii) Ist A invertierbar, dann ist auch $A^\top$ invertierbar und

$$(A^\top)^{-1} = (A^{-1})^\top.$$

Beweis. Um die Eigenschaften zu Beweisen, müssen wir jeweils zeigen, dass die (behaupteten) Inversen die Eigenschaften in [Definition 2.2.1](#) erfüllen.

(i) Es gilt $A^{-1}A = I$ und $A^{-1}A = I$, also ist A eine Inverse zu A^{-1} .

(ii) Es gilt

$$(AB)(B^{-1}A^{-1}) = A(BB^{-1})A^{-1} = AIA^{-1} = AA^{-1} = I$$

und

$$(B^{-1}A^{-1})(AB) = B^{-1}(A^{-1}A)B = B^{-1}IB = BB^{-1} = I.$$

(iii) Wir verwenden Eigenschaft (iv) von [Theorem 2.1.15](#):

$$(A^{-1})^\top A^\top = (AA^{-1})^\top = I^\top = I, \quad \text{und} \quad A^\top (A^{-1})^\top = (A^{-1}A)^\top = I. \quad \square$$

Anmerkung 2.2.4. In (i) und (iii) herrscht sogar Äquivalenz, weil wir die Rollen von z.B. A und $A^\top$ einfach vertauschen können. Auch in (ii) herrscht Äquivalenz, aber das beweisen wir erst in der Übung.

Ein nützlicher Blickwinkel auf inverse Matrizen sind die zugehörigen linearen Transformationen. Ist $T(\mathbf{x}) = A\mathbf{x}$ und $T^{-1}(\mathbf{x}) = A^{-1}\mathbf{x}$, dann gilt $T^{-1}(T(\mathbf{x})) = A^{-1}A\mathbf{x}$ und $T(T^{-1}(\mathbf{x})) = \mathbf{x}$. Die Abbildung T^{-1} macht also die Transformation T rückgängig. Die meisten Transformationen in [Abschnitt 1.10.2](#) können wir rückgängig machen. Zum Beispiel lässt sich eine Streckung T um den Faktor $k \geq 1$ durch eine Stauchung T^{-1} um den Faktor $1/k$ wieder aufheben. In solchen Fällen nennen wir T^{-1} die **inverse Abbildung** zu T . Andere Transformationen, wie z.B. Projektionen lassen sich nicht rückgängig machen, also gibt es auch keine inverse Abbildung/Matrix dazu. Zur Existenz der Inversen Matrix lernen wir in Kürze mehr.

2.2.2 Berechnung und Elementarmatrizen

Inverse per Hand zu berechnen ist selten nützlich und im Allgemeinen zäh. Wir wollen trotzdem kurz einen allgemeinen Algorithmus herleiten. Der Algorithmus wird uns nämlich helfen eine Verbindung zu LGS und deren Zeilenstufenform herzustellen.

Wir beginnen mit einer Verbindung der Inversen zu linearen Gleichungssystemen.

Theorem 2.2.5. Wenn $A \in \mathbb{R}^{n \times n}$ invertierbar ist, dann hat das LGS $A\mathbf{x} = \mathbf{b}$ für jedes $\mathbf{b} \in \mathbb{R}^n$ genau eine Lösung, nämlich $\mathbf{x} = A^{-1}\mathbf{b}$.

Beweis. Zuerst sehen wir, dass $A(A^{-1}\mathbf{b}) = AA^{-1}\mathbf{b} = \mathbf{b}$, also ist $\mathbf{x} = A^{-1}\mathbf{b}$ tatsächlich eine Lösung des LGS. Außerdem muss für jede Lösung $\mathbf{x}$ gelten, dass

$$A\mathbf{x} = \mathbf{b} \quad \Rightarrow \quad A^{-1}A\mathbf{x} = A^{-1}\mathbf{b} \quad \Rightarrow \quad \mathbf{x} = A^{-1}\mathbf{b}.$$

Also ist die Lösung eindeutig. □

Wir erklären zunächst den Algorithmus, ein formaler Beweis der einzelnen Schritte folgt später. Die Spalten der inversen Matrix sind $(A^{-1}\mathbf{e}_1 \cdots A^{-1}\mathbf{e}_n)$ für Einheitsvektoren $\mathbf{e}_1, \dots, \mathbf{e}_n$. Diesen Vektor $\mathbf{x} = A^{-1}\mathbf{e}_j$ können wir auch als Lösung des LGS $A\mathbf{x} = \mathbf{e}_j$ oder $(A \mid \mathbf{e}_j)$ schreiben. Lösen wir dieses LGS, haben wir also die j -te Spalte der Inverse gefunden. Um das LGS zu lösen, führen wir es in die reduzierte Zeilenstufenform über. Die Operationen sind dabei gleich, egal welchen Einheitsvektor $\mathbf{e}_j$ wir gerade betrachten. Deshalb reicht es eine große Koeffizientenmatrix $(A \mid \mathbf{e}_1 \cdots \mathbf{e}_n) = (A \mid I_n)$ aufzustellen und zu reduzieren. Weil es nur eine Lösung gibt, muss die linke Seite des reduzierten LGS die Identitätsmatrix I_n sein. In reduzierter Form haben wir dann also $(I_n \mid A^{-1})$.

Für den Spezialfall $A \in \mathbb{R}^{2 \times 2}$ gibt es eine einfache Formel. Ist

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

dann ist

$$A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}.$$

Beispiel 2.2.6. Für $A \in \mathbb{R}^{2 \times 2}$ können wir die Formel zur Illustration des allgemeinen Algorithmus kurz überprüfen. Sei

$$A = \begin{pmatrix} 1 & -2 \\ 3 & 4 \end{pmatrix},$$

dann ergibt die Formel

$$A^{-1} = \frac{1}{10} \begin{pmatrix} 4 & 2 \\ -3 & 1 \end{pmatrix}.$$

Wir finden diese Matrix nun durch Reduktion $(A \mid I) \sim (I \mid A^{-1})$. Es gilt

$$\begin{aligned} \left(\begin{array}{cc|cc} 1 & -2 & 1 & 0 \\ 3 & 4 & 0 & 1 \end{array} \right) &\stackrel{(II)-3(I)}{\sim} \left(\begin{array}{cc|cc} 1 & -2 & 1 & 0 \\ 0 & 10 & -3 & 1 \end{array} \right) \\ &\stackrel{(II)\frac{1}{10}}{\sim} \left(\begin{array}{cc|cc} 1 & -2 & 1 & 0 \\ 0 & 1 & -3/10 & 1/10 \end{array} \right) \\ &\stackrel{(I)+2\cdot(II)}{\sim} \left(\begin{array}{cc|cc} 1 & 0 & 4/10 & 2/10 \\ 0 & 1 & -3/10 & 1/10 \end{array} \right). \end{aligned}$$

Um eine Inverse zu berechnen, führen wir eine Reihe von elementaren Zeilenoperationen durch, bis die Matrix in reduzierter Zeilenstufenform ist. Jede dieser Operationen kann durch Multiplikation mit sogenannten *Elementarmatrizen* dargestellt werden.

Definition 2.2.7. Eine Matrix E , die aus einer einzelnen elementare Zeilenoperationen angewandt auf die Identitätsmatrix entsteht, nennen wir **Elementarmatrix**.

Beispiel 2.2.8. Die Elementarmatrix

$$E = \begin{pmatrix} 1 & 0 \\ 0 & -2 \end{pmatrix},$$

entsteht aus I_2 durch Multiplikation der zweiten Zeile mit -2 . Multiplizieren wir eine beliebige Matrix A von links mit E , erhalten wir

$$EA = \begin{pmatrix} a_{11} & a_{12} \\ -2a_{21} & -2a_{22} \end{pmatrix}.$$

Die zweite Zeile von A wurde mit -2 multipliziert.

Beispiel 2.2.9. Die Elementarmatrix

$$E = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

entsteht aus I_3 durch Vertauschen der ersten beiden Zeilen. Multiplizieren wir eine beliebige Matrix A von links mit E , erhalten wir

$$EA = \begin{pmatrix} a_{21} & a_{22} & a_{23} \\ a_{11} & a_{12} & a_{13} \\ a_{31} & a_{32} & a_{33} \end{pmatrix}.$$

Die ersten beiden Zeilen von A wurden vertauscht.

Beispiel 2.2.10. Die Elementarmatrix

$$E = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 3 & 0 & 1 \end{pmatrix}$$

entsteht aus I_3 , indem wir 3-mal die erste Zeile zur dritten addieren. Multiplizieren wir eine beliebige Matrix A von links mit E , erhalten wir

$$EA = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ 3a_{11} + a_{31} & 3a_{12} + a_{32} & 3a_{13} + a_{33} \end{pmatrix}.$$

Die erste Zeile von A wurde 3-mal zur dritten Zeile addiert.

Für jede elementare Zeilenoperation gibt es eine zweite, die die erste wieder rückgängig macht. Zum Beispiel können wir die Multiplikation der zweiten Zeile mit $c \neq 0$ durch Multiplikation der Zeile mit $1/c$ rückgängig machen. Es gilt also

$$\begin{pmatrix} 1 & 0 \\ 0 & -2 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & -1/2 \end{pmatrix} = I, \quad \begin{pmatrix} 1 & 0 \\ 0 & -1/2 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & -2 \end{pmatrix} = I_2.$$

Daraus folgt, dass jede Elementarmatrix E eine Inverse E^{-1} besitzt und, dass die Inverse selbst eine Elementarmatrix ist. Im Algorithmus zur Berechnung von A^{-1} multiplizieren wir also beide Seiten des Systems $(A \mid I_n)$ mit Elementarmatrizen $E_1, \dots, E_k$, sodass

$$(A \mid I_n) \sim (E_k \cdots E_1 A \mid E_k \cdots E_1 I) \sim (I_n \mid A^{-1}).$$

Wir erhalten das folgende Resultat als Rechtfertigung des Algorithmus.

Theorem 2.2.11 (Äquivalenzen). Sei $A \in \mathbb{R}^{n \times n}$. Dann sind die folgenden Aussagen äquivalent:

- (a) A ist invertierbar.
- (b) Die reduzierte Zeilenstufenform von A ist I_n .
- (c) A kann als Produkt von Elementarmatrizen dargestellt werden.

Beweis (optional). Wir zeigen die Äquivalenzen durch den Ringschluss $(a) \Rightarrow (b) \Rightarrow (c) \Rightarrow (a)$.

- $(a) \Rightarrow (b)$: Nach Theorem 2.2.5 hat das LGS $A\mathbf{x} = \mathbf{b}$ eine Lösung für jedes $\mathbf{b}$. Wegen Theorem 1.7.6 hat A dann einen Pivot in jeder Zeile. Weil A quadratisch ist, gibt es auch in jeder Spalte einen Pivot, also ist die reduzierte Zeilenstufenform I_n .

- $(b) \Rightarrow (c)$: Angenommen die reduzierte Zeilenstufenform von A ist I_n . Dann gibt es Elementarmatrizen $E_1, \dots, E_k$, sodass

$$E_k \cdots E_1 A = I_n.$$

Weil jede Elementarmatrix E_j eine Elementarmatrix E_j^{-1} als Inverse hat, erhalten wir durch Linksmultiplikation der Gleichung mit diesen

$$A = E_1^{-1} \cdots E_k^{-1} I_n = E_1^{-1} \cdots E_k^{-1}.$$

- $(c) \Rightarrow (a)$: Wenn A das Produkt von Elementarmatrizen ist, ist es insbesondere das Produkt von invertierbaren Matrizen und damit selbst invertierbar (Theorem 2.2.3). $\square$

2.2.3 Äquivalenzen und Querverbindungen

Das Schöne an der linearen Algebra ist, dass alle Konzepte miteinander in Verbindung stehen. In Theorem 2.2.11 haben wir die Invertierbarkeit einer Matrix durch Äquivalenzen mit der Zeilenstufenform und Elementarmatrizen in Verbindung gebracht. Wir werden das Resultat von nun an Schritt für Schritt mit weiteren bereits erlernten Konzepten erweitern. Im Verlauf des Semesters werden wir noch viele weitere Äquivalenzen zu neuen Konzepten hinzufügen.

Theorem 2.2.12 (Äquivalenzen). Sei $A \in \mathbb{R}^{n \times n}$. Dann sind die folgenden Aussagen äquivalent:

- (a) A ist invertierbar.
- (b) $A^\top$ ist invertierbar.
- (c) Die reduzierte Zeilenstufenform von A ist I_n .
- (d) Das LGS $A\mathbf{x} = \mathbf{0}$ hat nur die triviale Lösung.

Beweis. Die Äquivalenz $(a) \Leftrightarrow (b)$ folgt aus Theorem 2.2.3 (iii) und $(a) \Leftrightarrow (c)$ aus Theorem 2.2.11. Äquivalenz der ersten drei Aussagen zu (d) zeigen wir nun durch den Ringschluss $(a) \Rightarrow (d) \Rightarrow (c)$. Die Implikation $(a) \Rightarrow (d)$ folgt direkt aus Theorem 2.2.5. Wir zeigen nun $(d) \Rightarrow (c)$. Hat das System $(A \mid \mathbf{0})$ nur die triviale Lösung, so gibt es laut Theorem 1.3.1 keine freien Variablen. Also hat A einen Pivot in jeder Spalte. Weil A quadratisch ist, gibt es damit auch einen Pivot in jeder Zeile. Die reduzierte Zeilenstufenform ist also I_n . $\square$

Die Verknüpfung der verschiedenen Konzepte ist ein mächtiges Werkzeug. Um beispielsweise etwas über inverse Matrizen zu lernen, können wir genauso gut die Lösungsmenge zu $A\mathbf{x} = \mathbf{0}$ charakterisieren. Das führt manchmal zu unverhofften Erkenntnissen. Um zu zeigen, dass B eine Inverse zu A ist, mussten wir bisher

die beiden Eigenschaften $BA = I_n$ und $AB = I_n$ überprüfen. Tatsächlich reicht eine der beiden Eigenschaften bereits aus.

Theorem 2.2.13. Eine Matrix $A \in \mathbb{R}^{n \times n}$ ist invertierbar, wenn eine Matrix B gibt, die $BA = I_n$ oder $AB = I_n$ erfüllt. Es gilt dann $B = A^{-1}$.

Beweis.

- Fall $BA = I_n$: Wir zeigen zuerst, dass A invertierbar ist. Nach Theorem 2.2.12 (d) reicht es zu zeigen, dass $A\mathbf{x} = \mathbf{0}$ nur die triviale Lösung hat. Sei $\mathbf{x}$ eine beliebige Lösung. Multiplizieren wir die Gleichung $A\mathbf{x} = \mathbf{0}$ von links mit B , erhalten wir

$$A\mathbf{x} = \mathbf{0} \Rightarrow BA\mathbf{x} = B\mathbf{0} \Rightarrow I_n\mathbf{x} = \mathbf{0} \Rightarrow \mathbf{x} = \mathbf{0}.$$

Also gibt es nur die triviale Lösung und A ist invertierbar. Ist A^{-1} die Inverse, erhalten wir

$$BA = I_n \Rightarrow BAA^{-1} = I_nA^{-1} \Rightarrow B = A^{-1},$$

wie behauptet.

- Fall $AB = I_n$: Aus dem ersten Fall folgt, dass B invertierbar ist mit $A = B^{-1}$. Laut Theorem 2.2.3 ist dann auch A invertierbar mit $A^{-1} = B$. $\square$

In Theorem 2.2.12 haben wir Inverse mit homogenen LGS verknüpft. Als Nächstes stellen wir eine Verbindung zu inhomogenen LGS her.

Theorem 2.2.14 (Äquivalenzen). Sei $A \in \mathbb{R}^{n \times n}$. Dann sind die folgenden Aussagen äquivalent:

- (a) A ist invertierbar.
- (b) $A^\top$ ist invertierbar.
- (c) Die reduzierte Zeilenstufenform von A ist I_n .
- (d) Das LGS $A\mathbf{x} = \mathbf{0}$ hat nur die triviale Lösung.
- (e) Das LGS $A\mathbf{x} = \mathbf{b}$ hat genau eine Lösung für jedes $\mathbf{b} \in \mathbb{R}^n$.
- (f) Das LGS $A\mathbf{x} = \mathbf{b}$ hat eine Lösung für jedes $\mathbf{b} \in \mathbb{R}^n$.

Beweis. Die Äquivalenzen der ersten vier sind bereits gezeigt. Wir zeigen den Ringschluss $(a) \Rightarrow (e) \Rightarrow (f) \Rightarrow (c)$, um Äquivalenz aller Aussagen herzustellen. Den Teil $(a) \Rightarrow (e)$ haben wir bereits in Theorem 2.2.5 gezeigt und (f) folgt

trivialerweise aus (e). Aus [Theorem 1.7.6](#) wissen wir dann, dass A einen Pivot in jeder Zeile haben muss. Weil A quadratisch ist, ist die reduzierte Zeilenstufenform deshalb I_n . $\square$

Die letzte Erweiterung für den Moment ist jetzt so gut wie trivial. Sie stellt Querverbindungen zu Linearkombinationen und Unabhängigkeit her.

Theorem 2.2.15 (Äquivalenzen). *Sei $A \in \mathbb{R}^{n \times n}$. Dann sind die folgenden Aussagen äquivalent:*

- (a) A ist invertierbar.
- (b) $A^\top$ ist invertierbar.
- (c) Die reduzierte Zeilenstufenform von A ist I_n .
- (d) Das LGS $A\mathbf{x} = \mathbf{0}$ hat nur die triviale Lösung.
- (e) Das LGS $A\mathbf{x} = \mathbf{b}$ hat genau eine Lösung für jedes $\mathbf{b} \in \mathbb{R}^n$.
- (f) Das LGS $A\mathbf{x} = \mathbf{b}$ hat eine Lösung für jedes $\mathbf{b} \in \mathbb{R}^n$.
- (g) Die Spalten von A sind linear unabhängig.
- (h) Die Zeilen von A sind linear unabhängig.
- (i) Die Spalten von A spannen $\mathbb{R}^n$.
- (j) Die Zeilen von A spannen $\mathbb{R}^n$.

Beweis. Die Äquivalenzen zwischen (a)–(f) haben wir bereits gezeigt. Die Äquivalenz (d) $\Leftrightarrow$ (g) folgt direkt aus der Definition von linearer Unabhängigkeit und (f) $\Leftrightarrow$ (i) aus [Theorem 1.7.6](#). Wegen (b) folgen auch die Äquivalenzen zu (h) und (j). $\square$

2.3 Anwendungen

2.3.1 Interpolation

Nehmen wir an, wir haben n Datenpunkte (y_j, x_j) , $j = 1, \dots, n$. Angenommen, diese Punkte sind dadurch entstanden, dass wir eine stetige Funktion f an endlich vielen Stellen $x_1, \dots, x_n \in \mathbb{R}$ messen. Hier gilt dann $y_j = f(x_j)$. Um die Funktion f zu approximieren, können wir die Punkte (y_j, x_j) *interpolieren*: wir finden eine Funktion f_n , sodass $y_j = f_n(x_j)$ für alle $j = 1, \dots, n$.

In [Abbildung 2.1](#) sehen wir links fünf beobachtete Punkte. Rechts sehen wir dann eine Funktion, die diese Punkte interpoliert. Eine solche Funktion f_n ist nicht eindeutig — außer an den Punkten $x_1, \dots, x_n$ wissen wir nichts. Um eine




Abbildung 2.1: Beobachtete Punkte (links) und das interpolierende Polynom (rechts).

eindeutige Interpolationsfunktion f_n zu bekommen, müssen wir den Suchraum einschränken. Zum Beispiel gibt es für separierte Inputs ($x_i \neq x_j$ für $i \neq j$) genau ein Polynom $(n - 1)$ -ten Grades f_n , sodass

$$y_j = f_n(x_j) := c_1 + c_2 x_j^1 + \dots + c_n x_j^{n-1}, \quad \text{für alle } j = 1, \dots, n.$$

Die Koeffizienten $\mathbf{c} = (c_1, \dots, c_n)$ des Polynoms lassen sich durch das LGS

$$\begin{pmatrix} 1 & x_1 & x_1^2 & \dots & x_1^{n-1} \\ & & & \ddots & \\ 1 & x_n & x_n^2 & \dots & x_n^{n-1} \end{pmatrix} \begin{pmatrix} c_1 \\ \vdots \\ c_n \end{pmatrix} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

bestimmen.

Im Beispiel in [Abbildung 2.1](#) haben wir fünf Beobachtungen, brauchen also ein Polynom vierten Grades. In R können wir so ein System leicht aufstellen und lösen:

```
1 # Beobachtete Daten
2 x <- seq(-2, 2, l = 5)
3 y <- 10 * sin(1 + x)
4
5 # Matrix mit Potenzen x_j^(k - 1)
6 A <- sapply(1:5, function(k) x^(k - 1))
7
8 # Loese Ac = y
9 solve(A, y)
10 #> [1] 8.4147098 5.2431570 -4.1645916 -0.6966699 0.2963688
```

Die letzte Zeile gibt uns den Lösungsvektor $\mathbf{c} = (c_1, \dots, c_n)$ aus. Wir können jetzt die interpolierende Funktion f_n auch zwischen den beobachteten Punkten auswerten. Diese Funktion ist rechts in [Abbildung 2.1](#) zu sehen.

Ähnliche LGS lassen sich immer aufstellen, wenn f_n als Linearkombination von

Basis-Funktionen $\varphi_1, \dots, \varphi_n$ erzeugt wird:

$$f_n(x) = c_1\varphi_1(x) + \dots + c_n\varphi_n(x), \quad c_1, \dots, c_n \in \mathbb{R}.$$

Im obigen Beispiel ist $\varphi_j(x) = x^{j-1}$. Im Verlauf eures Studiums werdet ihr noch andere geeignete Basissysteme kennenlernen.

2.3.2 Lineare Modelle

Ein ähnliches Problem entsteht in *linearen Modellen*. Nehmen wir an, Daten $(y_1, \mathbf{x}_1), \dots, (y_n, \mathbf{x}_n) \in \mathbb{R}^{1+p}$ folgen dem Modell

$$y_i = \mathbf{x}_i^\top \boldsymbol{\beta}, \quad i = 1, \dots, n,$$

für ein $\boldsymbol{\beta} \in \mathbb{R}^p$, das wir aber nicht kennen. Die Daten $(y_i, \mathbf{x}_i) \in \mathbb{R} \times \mathbb{R}^p$ liegen dann alle auf einer p -dimensionalen Ebene, die durch den Vektor $\boldsymbol{\beta}$ charakterisiert wird. Diese Ebene können wir als $\text{span}\{(\beta_j, \mathbf{e}_j), j = 1, \dots, p\}$ darstellen, wobei $\mathbf{e}_j$ die Einheitsvektoren des $\mathbb{R}^p$ sind.¹

Schreiben wir nun alle Gleichungen zusammen als das LGS

$$X\boldsymbol{\beta} = \mathbf{y} \quad \text{mit} \quad X = \begin{pmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{pmatrix}.$$

Jetzt können wir den passenden Parametervektor $\boldsymbol{\beta}$ finden, in dem wir das LGS lösen. Ist $n > p$, dann haben wir mehr Zeilen als Spalten. Also gibt es in der Zeilenstufenform viele Nullzeilen. Wenn die Daten wirklich aus dem Modell erzeugt wurden, dann gibt es natürlich eine Lösung. Es hätten aber auch p Datenpunkte gereicht, um die Lösung eindeutig zu bestimmen.

In Daten aus der realen Welt ist ein Modell wie $y_i = \mathbf{x}_i^\top \boldsymbol{\beta}$ niemals exakt. Hier kommt dann die Statistik ins Spiel. In der Statistik liest sich ein lineares Modell

$$y_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \epsilon_i,$$

wobei $\epsilon_1, \dots, \epsilon_n$ unabhängige Zufallsfehler sind. Beispielsweise könnten wir für ϵ_i eine Normalverteilung annehmen. Stellen wir jetzt das LGS $X\boldsymbol{\beta} = \mathbf{y}$ auf, haben wir ein Problem. Die Daten liegen nicht mehr auf einer Ebene und damit ist das LGS nicht mehr lösbar. Stattdessen sucht man einen Parameter $\hat{\boldsymbol{\beta}}$, für den die Diskrepanz $\mathbf{y} - X\hat{\boldsymbol{\beta}}$ so klein wie möglich ist. Auch das kann man mit linearer Algebra lösen und erhält die Formel $\hat{\boldsymbol{\beta}} = (X^\top X)^{-1} X^\top \mathbf{y}$. Die dazu notwendigen Konzepte *Norm* und *Projektion* werden wir später noch besprechen.

¹Anders gesagt liegen alle $(y_i, \mathbf{x}_i) \in \mathbb{R}^{1+p}$ auf der p -dimensionalen Ebene *orthogonal* zum Vektor $(-1, \boldsymbol{\beta}) \in \mathbb{R}^{1+p}$. Was Orthogonalität genau bedeutet, lernen wir später.

2.3.3 Markovketten

In sogenannten *dynamischen Systemen* beschreiben Vektoren $\mathbf{x}^{(t)} \in \mathbb{R}^n$ den Zustand des Systems zum Zeitpunkt t . Der Übergang von einem zum nächsten Zustand wird oft durch eine Matrixtransformation beschrieben: $\mathbf{x}^{(t)} = A\mathbf{x}^{(t-1)}$.

Markovketten sind dynamische Systeme, in denen der Zustandsvektor aus Wahrscheinlichkeiten besteht. Sei zum Beispiel $V^{(t)}$ das Ereignis, dass jemand in die t -te Vorlesung geht. Wir modellieren Vektoren

$$\mathbf{p}^{(t)} = \begin{pmatrix} \mathbb{P}(V^{(t)}) \\ \mathbb{P}(\bar{V}^{(t)}) \end{pmatrix}.$$

Die erste Komponente ist die Wahrscheinlichkeit, dass die Person zur Vorlesung geht. Die zweite Komponente ist die Gegenwahrscheinlichkeit, also muss gelten $p_1^{(t)} + p_2^{(t)} = 1$. $\mathbf{p}^{(1)}$ sind die Wahrscheinlichkeiten für die erste Vorlesung. Allgemein gilt auch

$$\begin{aligned} \mathbb{P}(V^{(t)}) &= \mathbb{P}(V^{(t)} \mid V^{(t-1)})\mathbb{P}(V^{(t-1)}) + \mathbb{P}(V^{(t)} \mid \bar{V}^{(t-1)})\mathbb{P}(\bar{V}^{(t-1)}) \\ \mathbb{P}(\bar{V}^{(t)}) &= \mathbb{P}(\bar{V}^{(t)} \mid V^{(t-1)})\mathbb{P}(V^{(t-1)}) + \mathbb{P}(\bar{V}^{(t)} \mid \bar{V}^{(t-1)})\mathbb{P}(\bar{V}^{(t-1)}). \end{aligned}$$

Das können wir auch kompakt als

$$\mathbf{p}^{(t)} = M\mathbf{p}^{(t-1)}$$

schreiben, wobei die Matrix M die *Übergangswahrscheinlichkeiten* enthält:

$$M = \begin{pmatrix} \mathbb{P}(V^{(t)} \mid V^{(t-1)}) & \mathbb{P}(V^{(t)} \mid \bar{V}^{(t-1)}) \\ \mathbb{P}(\bar{V}^{(t)} \mid V^{(t-1)}) & \mathbb{P}(\bar{V}^{(t)} \mid \bar{V}^{(t-1)}) \end{pmatrix}.$$

In den Spalten stehen jeweils Gegenwahrscheinlichkeiten, also muss jede Spaltensumme 1 sein.²

Nehmen wir als Beispiel die Matrix

$$\begin{pmatrix} 0.9 & 0.8 \\ 0.1 & 0.2 \end{pmatrix}.$$

Wenn man schon mal da ist, dann ist die Wahrscheinlichkeit das nächste Mal wiederzukommen 90%. Manchmal kommt ja was dazwischen. Wenn man mal nicht kommt, ist die Versuchung groß, noch eine Vorlesung auszusetzen. Die Wahrscheinlichkeit, doch zu kommen ist 80%. Die zweite Zeile enthält die entsprechenden Gegenwahrscheinlichkeiten.

Gegeben $\mathbf{p}^{(1)}$ können wir jetzt rekursiv Wahrscheinlichkeiten für die t -te Vorlesung berechnen:

$$\mathbf{p}^{(t)} = M\mathbf{p}^{(t-1)} = M^2\mathbf{p}^{(t-2)} = \dots = M^{t-1}\mathbf{p}^{(1)}.$$

²Solche Matrizen werden *stochastisch* genannt.

Nehmen wir an, die erste Vorlesung wird sicher besucht: $\mathbf{p}^{(1)} = (1, 0)$. Daraus können wir die anderen $\mathbf{p}^{(t)}$ einfach in R berechnen:

```
1 M <- cbind(c(0.9, 0.1), c(0.8, 0.2))
2 p1 <- c(1, 0)
3 M %*% p1          # 2te Vorlesung
4 #>      [,1]
5 #> [1,]  0.9
6 #> [2,]  0.1
7 library(expm)
8 (M %^% 5) %*% p1 # 6te Vorlesung
9 #>      [,1]
10 #> [1,] 0.88889
11 #> [2,] 0.11111
```

Für jemanden, der nicht in der ersten Vorlesung war ($\mathbf{p}^{(1)} = (0, 1)$) bekommen wir:

```
1 p1 <- c(0, 1)
2 M %*% p1          # 2te Vorlesung
3 #>      [,1]
4 #> [1,]  0.8
5 #> [2,]  0.2
6 (M %^% 5) %*% p1 # 6te Vorlesung
7 #>      [,1]
8 #> [1,] 0.88888
9 #> [2,] 0.11112
```

Für spätere Vorlesungen nähern sich die Wahrscheinlichkeiten in beiden Fällen an. Tatsächlich kann man zeigen, dass es einen Vektor $\mathbf{q}$ gibt mit

$$\lim_{n \rightarrow \infty} M^n \mathbf{p} = \mathbf{q},$$

egal mit welchem Wahrscheinlichkeitsvektor $\mathbf{p}$ wir starten.³ Der ursprüngliche Zustand verliert also an Relevanz. Genauso gilt

$$\lim_{n \rightarrow \infty} M^n \mathbf{p} = M \lim_{n \rightarrow \infty} M^{n-1} \mathbf{p} = M \mathbf{q}.$$

Vergleichen wir die beiden Grenzwerte, erhalten wir

$$M \mathbf{q} = \mathbf{q}.$$

Beim Zustand $\mathbf{q}$ ist das System also im Gleichgewicht: er verändert sich nicht durch Transformation mit M . Der Gleichgewichtszustand ist eine wichtige Charakteristik des dynamischen Systems (und damit der Matrix M). Auch in vielen anderen Anwendungen der linearen Algebra sind Vektoren mit $A\mathbf{x} = \lambda\mathbf{x}$ für ein $\lambda \in \mathbb{R}$ interessant. Solche Vektoren werden *Eigenvektoren* genannt und ein Kernstück der linearen Algebra. Wir werden uns später noch intensiver damit

³Konvergenz bezieht sich auf die einzelnen Komponenten des Vektors $\mathbf{v}_n = M^n \mathbf{p}$.

beschäftigen.

2.4 Determinanten

2.4.1 Intuition und Interpretation

Wir erinnern uns kurz an die Formel für die Inverse einer (2×2) -Matrix:

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \Rightarrow A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}.$$

Aus der Formel sehen wir, dass die Inverse genau dann existiert, wenn $ad - bc \neq 0$. Die Zahl $ad - bc$ wird *Determinante* der Matrix A genannt und als $\det(A)$ geschrieben.

Die Determinante hat auch eine schöne Interpretation. Betrachten wir als Beispiel die Matrizen der Transformationen in [Abschnitt 1.10.2](#) vor Augen. Jede Matrix beschreibt eine lineare Transformation, die ein Häuschen in ein anderes Objekt überführt. Das ursprüngliche Haus umrandet eine Fläche von 1.25 (0.25 für's Dach). Die Fläche *nach* einer Transformation mit A ist dann $1.25|\det(A)|$. Die Ausgangsfläche wird also um den Faktor $|\det(A)|$ verändert. Die Betragsstriche sind nötig, weil die Determinante noch mehr Information enthält. Wenn sich die Orientierung des Objekts ändert (z.B. bei einer Spiegelung), dann wird sie negativ.

Hier ein paar konkrete Beispiele:

- Eine Streckung um den Faktor 2 entlang einer Achse, verdoppelt die Fläche. Wir rechnen nach:

$$\det \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix} = 2 \cdot 1 - 0 \cdot 0 = 2.$$

- Eine Spiegelung verändert nicht das Volumen, aber die Orientierung. Es gilt dann $\det(A) = -1$. Zum Beispiel für eine Spiegelung entlang der Geraden $x_1 = x_2$ erhalten wir

$$\det \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} = 0 \cdot 0 - 1 \cdot 1 = -1.$$

- Eine Scherung ändert weder Fläche noch Orientierung, also muss $\det(A) = 1$ gelten. Tatsächlich:

$$\det \begin{pmatrix} 1 & k \\ 0 & 1 \end{pmatrix} = 1 \cdot 1 - k \cdot 0 = 1.$$

- Bei einer Projektion kollabiert das Haus zu einer Linie. Entsprechend ist

die Fläche nach der Transformation gleich 0, also muss $\det(A) = 0$ sein:

$$\det \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} = 1 \cdot 0 - 0 \cdot 0.$$

Die Determinante fasst also gewissermaßen zusammen, was die Transformation $\mathbf{x} \mapsto A\mathbf{x}$ tut. Zumindest wissen wir, wie sie die Fläche und Orientierung von Objekten beeinflusst, und außerdem, ob wir sie wieder rückgängig machen können. Dass wir das alles mit nur einer einfachen Zahl schaffen, ist durchaus bemerkenswert.

Allgemein können wir für Matrizen $A \in \mathbb{R}^{n \times n}$ eine Zahl $\det(A)$ definieren, die beschreibt, um wie viel sich das (n -dimensionale) Volumen eines Objekts durch die Transformation ändert. Falls sich dabei auch die Orientierung ändert, soll die Zahl negativ sein. Die Berechnung von $\det(A)$ ist im Allgemeinen leider weder so einfach wie für $n = 2$, noch besonders intuitiv. Ich werde gleich ohne weitere Erklärung eine rekursive Berechnungsmethode dafür angeben. Auch wenn der Zusammenhang zur Formel für $n > 2$ nicht mehr einfach zu erklären ist, sollte man die Interpretation der Determinante aber nicht vergessen.

2.4.2 Berechnung über Kofaktoren

Mal angenommen, wir können bereits die Determinante einer $(n-1) \times (n-1)$ -Matrix berechnen. Sei nun $A \in \mathbb{R}^{n \times n}$. Dann gilt

$$\det(A) = a_{11} \det(A_{11}) - a_{12} \det(A_{12}) + \cdots + (-1)^{n+1} a_{1n} \det(A_{1n}),$$

wobei die Matrizen $A_{1j} \in \mathbb{R}^{(n-1) \times (n-1)}$ dadurch entstehen, dass wir aus A die erste Zeile und j -te Spalte streichen. Die Koeffizienten $a_{1j}, j = 1, \dots, n$ sind die Einträge der ersten Zeile von A .

Beispiel 2.4.1. Für

$$A = \begin{pmatrix} 3 & -2 & 1 \\ -5 & 0 & 1 \\ 1 & 2 & -3 \end{pmatrix}$$

ist

$$\begin{aligned} A_{11} &= \begin{pmatrix} \cancel{3} & \cancel{-2} & \cancel{1} \\ -5 & 0 & 1 \\ 1 & 2 & -3 \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ 2 & -3 \end{pmatrix}, \\ A_{12} &= \begin{pmatrix} \cancel{3} & \cancel{2} & \cancel{1} \\ -5 & \cancel{0} & 1 \\ 1 & \cancel{2} & -3 \end{pmatrix} = \begin{pmatrix} -5 & 1 \\ 1 & -3 \end{pmatrix}, \\ A_{13} &= \begin{pmatrix} \cancel{3} & \cancel{2} & \cancel{1} \\ -5 & 0 & \cancel{1} \\ 1 & 2 & \cancel{-3} \end{pmatrix} = \begin{pmatrix} -5 & 0 \\ 1 & 2 \end{pmatrix}. \end{aligned}$$

Also gilt

$$\begin{aligned}\det(A) &= 3 \cdot \det(A_{11}) - (-2) \cdot \det(A_{12}) + 1 \cdot \det(A_{13}) \\ &= 3 \cdot (-2) - (-2) \cdot 14 + 1 \cdot (-10) \\ &= -6 + 28 - 10 = 12.\end{aligned}$$

Die Determinante einer (2×2) -Matrix wissen wir bereits zu berechnen. Mit der Formel oben können wir dann auch die Determinante einer (3×3) -Matrix aus drei (2×2) -Determinanten berechnen. Die Determinante einer (4×4) -Matrix aus vier (3×3) -Determinanten, und so weiter. Da die Koeffizienten a_{1j} aus der ersten Zeile von A stammen, sagen wir, dass wir die Determinante *entlang der ersten Zeile entwickelt* haben.

Die Formel oben lässt sich auf zwei Arten verallgemeinern. Erstens können wir bezüglich beliebiger Zeilen entwickeln.

Kofaktorenentwicklung entlang Zeilen. Sei $A \in \mathbb{R}^{n \times n}$. Dann gilt für jedes $i = 1, \dots, n$

$$\begin{aligned}\det(A) &= \sum_{j=1}^n (-1)^{i+j} a_{ij} \det(A_{ij}) \\ &= (-1)^{i+1} a_{i1} \det(A_{i1}) + \dots + (-1)^{i+n} a_{in} \det(A_{in}),\end{aligned}$$

wobei die Matrizen $A_{ij} \in \mathbb{R}^{(n-1) \times (n-1)}$ dadurch entstehen, dass wir aus A die i -te Zeile und j -te Spalte streichen.

Die Zahlen $c_{ij} = (-1)^{i+j} \det(A_{ij})$ werden dabei (i, j) -**Kofaktoren** genannt. Wir sehen, dass die Vorzeichen $(-1)^{i+j}$ immer nach folgendem Muster wechseln:

$$\begin{pmatrix} + & - & + & - & \dots \\ - & + & - & + & \dots \\ + & - & + & - & \dots \\ - & + & - & + & \dots \\ \vdots & \vdots & \vdots & \vdots & \ddots \end{pmatrix}$$

Beispiel 2.4.2. Für

$$A = \begin{pmatrix} 3 & -2 & 1 \\ -5 & 0 & 1 \\ 1 & 2 & -3 \end{pmatrix}$$

ist

$$A_{21} = \begin{pmatrix} -2 & 1 \\ 2 & -3 \end{pmatrix}, \quad A_{22} = \begin{pmatrix} 3 & 1 \\ 1 & -3 \end{pmatrix}, \quad A_{23} = \begin{pmatrix} 3 & -2 \\ 1 & 2 \end{pmatrix}.$$

Also gilt

$$\det(A) = -(-5) \cdot \det(A_{21}) + 0 \cdot \det(A_{22}) - 1 \cdot \det(A_{23}) = 5 \cdot 4 + 0 - 1 \cdot 8 = 12.$$

Am letzten Beispiel sehen wir auch, dass es günstig ist, nach Zeilen zu entwickeln, die möglichst viele Nullen enthalten. Das erspart uns die Berechnung möglichst vieler Unter-Determinanten.

Zweitens können wir die Determinante auch entlang Spalten entwickeln.

Kofaktorenentwicklung entlang Spalten. Sei $A \in \mathbb{R}^{n \times n}$. Dann gilt für jedes $j = 1, \dots, n$

$$\begin{aligned} \det(A) &= \sum_{i=1}^n (-1)^{i+j} a_{ij} \det(A_{ij}) \\ &= (-1)^{1+j} a_{1j} \det(A_{1j}) + \dots + (-1)^{n+j} a_{nj} \det(A_{nj}), \end{aligned}$$

wobei die Matrizen $A_{ij} \in \mathbb{R}^{(n-1) \times (n-1)}$ dadurch entstehen, dass wir aus A die i -te Zeile und j -te Spalte streichen.

Auch hier folgen die Vorzeichen dem Muster

$$\begin{pmatrix} + & - & + & - & \dots \\ - & + & - & + & \dots \\ + & - & + & - & \dots \\ - & + & - & + & \dots \\ \vdots & \vdots & \vdots & \vdots & \ddots \end{pmatrix}.$$

Beispiel 2.4.3. Für

$$A = \begin{pmatrix} 3 & -2 & 1 \\ -5 & 0 & 1 \\ 1 & 2 & -3 \end{pmatrix}$$

ist

$$A_{12} = \begin{pmatrix} -5 & 1 \\ 1 & -3 \end{pmatrix}, \quad A_{22} = \begin{pmatrix} 3 & 1 \\ 1 & -3 \end{pmatrix}, \quad A_{32} = \begin{pmatrix} 3 & 1 \\ -5 & 1 \end{pmatrix}.$$

Also gilt

$$\det(A) = -(-2) \cdot \det(A_{12}) + 0 \cdot \det(A_{22}) - 2 \cdot \det(A_{32}) = 2 \cdot 14 + 0 - 2 \cdot 8 = 12.$$

Anmerkung 2.4.4. Übrigens: Die Formel der (2×2) -Determinante ist nichts anderes als eine Kofaktorenentwicklung. Eine (1×1) -Matrix ist ein Skalar $a \in \mathbb{R}$. Multiplizieren wir ein Intervall mit einer Zahl a , dann verändert sich die Länge um den Faktor $|a|$. Ist $a < 0$, dann dreht sich außerdem die Ordnung/Orientierung

der Elemente. Also ist $\det(a) = a$. Entwickeln wir eine Matrix

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

zum Beispiel nach der ersten Zeile, erhalten wir

$$\det(A) = a \det(A_{11}) - b \det(A_{12}) = a \det(d) - b \det(c) = ad - bc.$$

Für manche Matrizen $A \in \mathbb{R}^{n \times n}$ ist die Berechnung von Determinanten ganz einfach. Sind alle Einträge einer Spalte/Zeile gleich 0, dann können wir entlang dieser Spalte/Zeile entwickeln und erhalten direkt $\det(A) = 0$. Nehmen wir nun an, alle Einträge außer einem sind gleich 0. Wenn entlang dieser Spalte/Zeile entwickeln, müssen wir dann nur eine $(n-1) \times (n-1)$ -Unterdeterminante berechnen. Ist in der Untermatrix ebenfalls eine Spalte/Zeile mit nur einem Eintrag ungleich 0, können wir so fortfahren. Insbesondere ist dies für sogenannte *Dreiecksmatrizen* möglich.

Definition 2.4.5. Eine Matrix $A = (a_{ij}) \in \mathbb{R}^{n \times n}$ nennen wir

- **obere Dreiecksmatrix**, falls $a_{ij} = 0$ für alle $i > j$,
- **untere Dreiecksmatrix**, falls $a_{ij} = 0$ für alle $i < j$.

Eine obere Dreiecksmatrix in $\mathbb{R}^{5 \times 5}$ hat zum Beispiel die Form

$$\begin{pmatrix} * & * & * & * & * \\ 0 & * & * & * & * \\ 0 & 0 & * & * & * \\ 0 & 0 & 0 & * & * \\ 0 & 0 & 0 & 0 & * \end{pmatrix}.$$

Eine untere Dreiecksmatrix dagegen

$$\begin{pmatrix} * & 0 & 0 & 0 & 0 \\ * & * & 0 & 0 & 0 \\ * & * & * & 0 & 0 \\ * & * & * & * & 0 \\ * & * & * & * & * \end{pmatrix}.$$

Entwickeln wir eine obere Dreiecksmatrix rekursiv nach der jeweils ersten Spalte, oder eine untere Dreiecksmatrix rekursiv nach der jeweils ersten Zeile, erhalten wir das folgende Resultat.

Theorem 2.4.6. Wenn $A \in \mathbb{R}^{n \times n}$ eine Dreiecksmatrix ist, dann ist $\det(A)$ das Produkt der Diagonaleinträge: $\det(A) = \prod_{i=1}^n a_{ii}$.

Beispiel 2.4.7. *Die Matrix*

$$A = \begin{pmatrix} 3 & -1 & 17 & 3 \\ 0 & -2 & 2 & -2 \\ 0 & 0 & 5 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

hat Determinante

$$\det(A) = 3 \cdot (-2) \cdot 5 \cdot 1 = -30.$$

Für die meisten anderen Matrizen ist die Berechnung über Kofaktoren aber nicht so einfach. Sind die Matrizen etwas größer, ist die Kofaktorenentwicklung zwar theoretisch valide, aber praktisch nicht mehr umsetzbar. Im Allgemeinen braucht es für die Kofaktorenentwicklung einer $(n \times n)$ -Matrix mehr als $n!$ Multiplikationen. Ein moderner Computer führt etwa drei Billionen ($3 \cdot 10^{12}$) solcher Operationen pro Sekunde aus. Für die Determinante einer (20×20) -Matrix braucht er dann schon $20!/(3 \cdot 10^{12}) \approx 800\,000$ Sekunden bzw. 9 Tage. Für eine (25×25) -Matrix bedarf es schon mehrerer hunderttausend Jahre.

2.4.3 Berechnung über Zeilenumformungen

Glücklicherweise gibt es auch eine effizientere Berechnungsmethode. Ist eine Matrix in Zeilenstufenform, ist sie insbesondere eine obere Dreiecksmatrix. Die Determinante lässt sich dann dank [Theorem 2.4.6](#) einfach als das Produkt der Diagonaleinträge berechnen. Leider sind Matrizen meist nicht in Zeilenstufenform. Es stellt sich also die Frage nach einem Zusammenhang von $\det(A)$ und $\det(U)$, wobei U eine Zeilenstufenform von A ist. Da wir U durch elementare Zeilenumformungen aus A erhalten, untersuchen wir zunächst den Effekt dieser Operationen auf die Determinante.

Theorem 2.4.8. *Seien $A, B \in \mathbb{R}^{n \times n}$.*

- (i) *Erhalten wir B aus A , indem wir eine Zeile von A mit $k \in \mathbb{R}$ multiplizieren, gilt $\det(B) = k \det(A)$.*
- (ii) *Erhalten wir B aus A , indem wir eine Zeile k mal zu einer anderen addieren, gilt $\det(B) = \det(A)$.*
- (iii) *Erhalten wir B aus A , indem wir zwei Zeilen von A miteinander vertauschen, gilt $\det(B) = -\det(A)$.*

Beweis (optional). Den Beweis führen wir durch Induktion. Durch die Formel $\det(A) = ad - bc$ lassen sich die Eigenschaften leicht für (2×2) -Matrizen überprüfen. Für entsprechende $A, B \in \mathbb{R}^{2 \times 2}$ gilt in den drei Fällen also

$$\det(B) = \alpha \det(A), \tag{2.1}$$

wobei α entweder k , 1 oder -1 ist, je nachdem ob wir uns in Fall (i), (ii) oder (iii) befinden.

Sei nun $n > 2$ und wir nehmen an, dass (2.1) für $(n \times n)$ -Matrizen gelten und folgern, dass (2.1) dann auch für $(n+1) \times (n+1)$ gelten müssen. Haben wir das gezeigt, muss (2.1) nach dem Induktionsprinzip für quadratische Matrizen jeglicher Dimension gelten.

Sei nun $A, B \in \mathbb{R}^{(n+1) \times (n+1)}$. Die Operationen in (i)–(iii) verändern maximal zwei Zeilen der Matrix A . Da $n > 2$, können wir auf jeden Fall nach einer Zeile i entwickeln, die in A und B gleich ist: Seien A_{ij} und B_{ij} die Matrizen, in der Zeile i und Spalte j gestrichen wurde. Dann kann man die Zeilen von B_{ij} aus A_{ij} durch die selbe Operation erzeugen, die auch B aus A erzeugt hat. Weil B_{ij} und A_{ij} $(n \times n)$ -Matrizen sind, gilt

$$\det(B_{ij}) = \alpha \det(A_{ij}).$$

Daraus erhalten wir:

$$\begin{aligned} \det(B) &= \sum_{j=1}^n (-1)^{i+j} b_{ij} \det(B_{ij}) \\ &= \sum_{j=1}^n (-1)^{i+j} a_{ij} \det(B_{ij}) \\ &= \alpha \sum_{j=1}^n (-1)^{i+j} a_{ij} \det(A_{ij}) \\ &= \alpha \det(A). \end{aligned}$$

Also gilt (2.1) auch für $(n+1) \times (n+1)$ -Matrizen. □

Wir können also die Determinante auch berechnen, indem wir die Matrix A in Zeilenstufenform überführen und dabei den Effekt der Operationen wie in (2.4.8) im Auge behalten.

Anmerkung 2.4.9. Wenden wir *Theorem 2.4.8* auf die Einheitsmatrix I_n an, sehen wir, dass für alle Elementarmatrizen E die Determinante $\det(E)$ entweder k , 1 oder -1 ist. Außerdem gilt für jede Matrix A , dass $\det(EA) = \det(E) \det(A)$. Das können wir auch wiederholt auf mehrere Elementarmatrizen $E_1, \dots, E_k$ anwenden, sodass

$$\det(E_1 E_2 \cdots E_k A) = \det(E_1) \det(E_2) \cdots \det(E_k) \det(A).$$

2.4.4 Eigenschaften

Die Methode im letzten Abschnitt ist nicht nur von praktischem Nutzen, sondern hilft uns auch eine Verbindung zu linearen Gleichungssystem und deren Zeilenstufenform herzustellen. Insbesondere können wir ganz einfach unsere Liste an

Äquivalenzen erweitern.

Theorem 2.4.10 (Äquivalenzen). Sei $A \in \mathbb{R}^{n \times n}$. Dann sind die folgenden Aussagen äquivalent:

- (a) A ist invertierbar.
- (b) $A^\top$ ist invertierbar.
- (c) Die reduzierte Zeilenstufenform von A ist I_n .
- (d) Das LGS $A\mathbf{x} = \mathbf{0}$ hat nur die triviale Lösung.
- (e) Das LGS $A\mathbf{x} = \mathbf{b}$ hat genau eine Lösung für jedes $\mathbf{b} \in \mathbb{R}^n$.
- (f) Das LGS $A\mathbf{x} = \mathbf{b}$ hat eine Lösung für jedes $\mathbf{b} \in \mathbb{R}^n$.
- (g) Die Spalten von A sind linear unabhängig.
- (h) Die Zeilen von A sind linear unabhängig.
- (i) Die Spalten von A spannen $\mathbb{R}^n$.
- (j) Die Zeilen von A spannen $\mathbb{R}^n$.
- (k) $\det(A) \neq 0$.

Beweis. (a)–(j) hatten wir bereits gezeigt. Sei R die reduzierte Zeilenstufenform von A . Dann gilt nach [Theorem 2.4.8](#)

$$\det(A) = k \det(R) = k \prod_{i=1}^n r_{ii},$$

für ein $k \neq 0$. Wir zeigen die Äquivalenz $(c) \Leftrightarrow (k)$:

- $(c) \Rightarrow (k)$: Ist $R = I_n$, dann gilt $\det(A) = k \neq 0$.
- $(c) \Leftarrow (k)$: Ist $\det(A) \neq 0$, dann muss $r_{ii} \neq 0$ für jedes i . Weil R eine reduzierte Zeilenstufenform ist, muss dann $r_{ii} = 1$ sein und alle anderen Einträge in der Matrix gleich 0. Also ist $R = I_n$. $\square$

Über die Determinante können wir also z.B. Invertierbarkeit, Lösbarkeit oder Unabhängigkeit prüfen.

Wir fragen uns natürlich wie sich die Determinante bezüglich Matrixoperationen in [Abschnitt 2.1](#) verhält. Multiplikation einer Matrix A mit einem Skalar k ist nichts anderes als jede der n Zeilen mit k zu multiplizieren. Also gilt nach [Theorem 2.4.8](#) (i):

Für jedes $A \in \mathbb{R}^{n \times n}$ und $k \in \mathbb{R}$ gilt $\det(kA) = k^n \det(A)$.

Entwickeln wir nun $\det(A)$ in Kofaktoren rekursiv jeweils nach der ersten Zeile, ist das das gleiche, als ob wir $\det(A^\top)$ jeweils nach der ersten Spalte entwickeln.⁴ Deshalb gilt:

Für jedes $A \in \mathbb{R}^{n \times n}$ gilt $\det(A) = \det(A^\top)$.

Insbesondere gilt [Theorem 2.4.8](#) also auch für *Spaltenoperationen*. Über die Determinante der Summe zweier Matrizen können wir wenig sagen. Für besondere Matrizen kann es sein, dass $\det(A + B) = \det(A) + \det(B)$. Das ist insbesondere der Fall, wenn A und B sich nur in einer Zeile unterscheiden. Für die meisten anderen Matrizen gilt allerdings

$$\det(A + B) \neq \det(A) + \det(B).$$

Für das Produkt zweier Matrizen bekommen wir aber ein schönes Resultat.

Theorem 2.4.11. Für alle $A, B \in \mathbb{R}^{n \times n}$ gilt $\det(AB) = \det(A) \det(B)$.

Beweis. Wir teilen den Beweis in zwei Fälle: A invertierbar und A singulär.

- Wenn A singulär ist, dann muss auch AB singulär sein ([Theorem 2.2.3](#) (ii) und Anmerkung danach). Also gilt nach [Theorem 2.4.10](#), $\det(AB) = 0$ und $\det(A) \det(B) = 0$.
- Wenn A invertierbar ist, dann lässt es sich als Produkt von Elementarmatrizen $A = E_1 E_2 \cdots E_k I_n$ schreiben ([Theorem 2.2.11](#)). Also ist nach [Anmerkung 2.4.9](#)

$$\begin{aligned} \det(AB) &= \det(E_1 E_2 \cdots E_k B) = \det(E_1) \det(E_2) \cdots \det(E_k) \det(B) \\ &= \det(A) \det(B). \end{aligned} \quad \square$$

⁴Diese Rekursion kann man zur Übung formal als Induktionsbeweis aufschreiben.