

4 Eigenwerte und Eigenvektoren

4.1 Eigenwerte, Eigenvektoren, Eigenräume

In [Abschnitt 2.3.3](#) haben wir bereits ein Beispiel für einen *Eigenvektor* gesehen. Für eine gegebene (stochastische) Matrix M , gibt es einen Vektor $\mathbf{q}$, sodass $M\mathbf{q} = \mathbf{q}$. Im Kontext dynamischer Systeme kann $\mathbf{q}$ als Gleichgewichtszustand gesehen werden: Er wird durch die Übergangsmatrix M nicht verändert. Wir bezeichnen dann $\mathbf{q}$ als einen *Eigenvektor* von M . Das „Eigen“ soll ausdrücken, dass es sich hierbei um eine Charakteristik oder Eigenheit der Matrix M handelt.¹

Dass es überhaupt einen solchen Vektor gibt, liegt daran, dass die Matrix M stochastisch ist (Spaltensumme gleich 1). Für allgemeine Matrizen $A \in \mathbb{R}^{n \times n}$ muss es einen solchen Vektor aber nicht geben. Oft gibt es aber Vektoren $\mathbf{x} \in \mathbb{R}^n$, auf die A eine ähnlich simple Wirkung hat.

Definition 4.1.1. Sei $A \in \mathbb{R}^{n \times n}$. Ein Vektor $\mathbf{x} \neq \mathbf{0} \in \mathbb{R}^n$ wird **Eigenvektor** von A genannt, wenn es ein Skalar $\lambda \in \mathbb{R}$ gibt, sodass

$$A\mathbf{x} = \lambda\mathbf{x}.$$

Der Skalar λ wird **Eigenwert** von A genannt und $\mathbf{x}$ auch der **zu λ gehörige Eigenvektor**.

Multiplizieren wir einen Eigenvektor $\mathbf{x}$ mit A , hat das den einfachen Effekt, dass $\mathbf{x}$ um den Faktor λ gestreckt/gestaucht wird. Die Richtung des Vektors kann umgekehrt (wenn $\lambda < 0$), aber nicht anderweitig verändert werden.

Beispiel 4.1.2. In [Abbildung 4.1](#) ist die Wirkung der Matrixtransformation $\mathbf{x} \mapsto A\mathbf{x}$ mit

$$A = \begin{pmatrix} 1 & 0.5 \\ 0 & 0.5 \end{pmatrix}$$

auf die Vektoren

$$\mathbf{u}_1 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad \mathbf{u}_2 = \begin{pmatrix} -3 \\ 2 \end{pmatrix}, \quad \mathbf{v}_1 = \begin{pmatrix} -2 \\ 2 \end{pmatrix}, \quad \mathbf{v}_2 = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

¹Lustigerweise hat sich der Wortstamm *eigen* auch international durchgesetzt. Im Englischen spricht man von *eigenvalues*, *eigenvectors*, *eigenspaces*.




Abbildung 4.1: Die Wirkung einer Matrix auf Eigenvektoren $\mathbf{v}_1, \mathbf{v}_2$ und andere Vektoren $\mathbf{u}_1, \mathbf{u}_2$.

dargestellt. Man kann leicht nachrechnen, dass

$$A\mathbf{v}_1 = 0.5\mathbf{v}_1, \quad A\mathbf{v}_2 = 0.5\mathbf{v}_2,$$

also sind $\mathbf{v}_1, \mathbf{v}_2$ beides Eigenvektoren zum Eigenwert 0.5. Die Matrixtransformation staucht die Vektoren also lediglich um die Hälfte Richtung Nullpunkt. Die Vektoren $\mathbf{u}_1, \mathbf{u}_2$ sind keine Eigenvektoren — hier ist die Transformation weniger einfach zu erklären.

Grundsätzlich kann es mehrere Eigenwerte und -vektoren geben. Im letzten Beispiel ist auch $\mathbf{w} = (1, 0)$ ein Eigenvektor zum Eigenwert 1. Außerdem haben wir gesehen, dass es zum selben Eigenwert mehrere Eigenvektoren geben kann. Genauer: Ist $\mathbf{v}$ ein Eigenvektor zum Eigenwert λ , dann ist auch jeder Vektor $c\mathbf{v}$ mit $c \in \mathbb{R}$ ein Eigenvektor zu λ . Denn

$$A(c\mathbf{v}) = c(A\mathbf{v}) = c(\lambda\mathbf{v}) = \lambda(c\mathbf{v}).$$

Prinzipiell müssen für ein λ nicht alle Eigenvektoren auf einer Geraden liegen. Wir haben es jedoch immer mit (Unter-)Vektorräumen zu tun.

Definition 4.1.3. Der **Eigenraum** E_λ einer Matrix $A \in \mathbb{R}^{n \times n}$ ist definiert als die Menge aller Eigenvektoren zum Eigenwert λ (und dem Nullvektor):

$$E_\lambda = \{\mathbf{x} : A\mathbf{x} = \lambda\mathbf{x}\}.$$

Das folgende Lemma darf gerne zur Übung bewiesen werden.

Lemma 4.1.4. Für jede Matrix $A \in \mathbb{R}^{n \times n}$ und $\lambda \in \mathbb{R}$ ist E_λ ein Unterraum des $\mathbb{R}^n$.

Beispiel 4.1.5. Ein einfaches Beispiel, wo es linear unabhängige Eigenvektoren zum gleichen Eigenwert gibt, ist die Nullmatrix

$$A = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}.$$

Hier ist jeder Vektor $\mathbf{x} \in \mathbb{R}^2$ ein Eigenvektor zum Eigenwert 0, denn $A\mathbf{x} = \mathbf{0} = 0 \cdot \mathbf{x}$.

Beispiel 4.1.6. Ein (minimal) interessanteres Beispiel ist die Diagonalmatrix

$$A = \begin{pmatrix} 2 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 2 \end{pmatrix}.$$

Mit ein bisschen Nachdenken sehen wir, dass A die Eigenwerte 2 und -1 besitzt und

$$E_2 = \text{span}\{\mathbf{e}_1, \mathbf{e}_3\}, \quad E_{-1} = \text{span}\{\mathbf{e}_2\}.$$

Der Eigenraum E_2 ist die Ebene, die durch den ersten und dritten Einheitsvektor aufgespannt wird. Auf alle Vektoren in dieser Ebene hat die Multiplikation mit A den einfachen Effekt, dass sie um den Faktor 2 gestreckt werden. Der Eigenraum E_{-1} ist eine Gerade in Richtung $\mathbf{e}_2$. Auf Vektoren dieser Gerade bewirkt A eine Richtungsumkehr bzw. Spiegelung an der Ebene E_2 .

Beispiel 4.1.7. Multiplikation von $\mathbf{x} \in \mathbb{R}^2$ mit der Matrix

$$A = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

führt zu einer Spiegelung an der Geraden $x_1 = x_2$ (sh. [Abschnitt 1.10.2](#)). Die Eigenwerte sind 1 und -1 und es gilt

$$E_1 = \text{span}\left\{\begin{pmatrix} 1 \\ 1 \end{pmatrix}\right\}, \quad E_{-1} = \text{span}\left\{\begin{pmatrix} 1 \\ -1 \end{pmatrix}\right\}.$$

Der Raum E_1 enthält alle Vektoren entlang der Spiegelachse; diese bleiben bei Multiplikation mit A unverändert (Eigenwert 1). Der Raum E_{-1} enthält alle Vektoren senkrecht zur Spiegelachse; diese kehren bei Multiplikation mit A ihre Richtung um (Eigenwert -1).

In allen Beispielen stellen wir fest, dass die Eigenvektoren eine Matrixtransformation gewissermaßen charakterisieren. Tatsächlich hätte man uns auch nur die Eigenräume und -werte sagen können und wir hätten daraus auf die Transformation schließen können. Und egal wie kompliziert die Transformation ist, innerhalb der Eigenräume ist sie ganz leicht zu verstehen. Wo auch immer wir es mit Matrixtransformationen zu tun haben, macht es deshalb Sinn, Eigenwerte und Eigenräume zu studieren.

4.2 Die charakteristische Gleichung

In den bisherigen Beispielen waren Eigenwerte und zugehörige Eigenvektoren einfach zu erkennen. Dies ist aber nicht immer der Fall. Wir wollen uns deshalb etwas allgemeiner mit der Existenz und der Suche nach Eigenwerten beschäftigen. Schreiben wir erstmal die Gleichung $A\mathbf{x} = \lambda\mathbf{x}$ in ein LGS um:

$$(A - \lambda I_n)\mathbf{x} = \mathbf{0}.$$

Nun sehen wir, dass λ ein Eigenwert zu A ist, falls das LGS eine nichttriviale Lösung hat. Die zugehörige Lösungsmenge, $\ker(A - \lambda I_n)$, entspricht dem Eigenraum E_λ .²

Unsere Äquivalenzen (zuletzt [Theorem 3.4.13](#)) liefern uns jetzt eine ganze Menge Möglichkeiten, die (Nicht-)Existenz eines Eigenwerts λ zu charakterisieren. Eine besonders praktische Variante liefert die Determinante.³

Theorem 4.2.1. *Ein Skalar $\lambda \in \mathbb{R}$ ist genau dann ein Eigenwert von A , wenn er die **charakteristische Gleichung***

$$\det(A - \lambda I) = 0$$

erfüllt.

Für eine allgemeine Matrix

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix},$$

²[Theorem 3.2.7](#) beweist jetzt übrigens [Lemma 4.1.4](#). War trotzdem 'ne gute Übung.

³Die charakteristische Gleichung ist praktisch für Rechnungen, aber nicht besonders intuitiv. Zur Interpretation empfiehlt es sich, die Definition $A\mathbf{x} = \lambda\mathbf{x}$ im Kopf zu behalten.

erhalten wir $A - \lambda I$, indem wir λ von allen Diagonaleinträgen abziehen:

$$A - \lambda I = \begin{pmatrix} a_{11} - \lambda & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} - \lambda & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} - \lambda \end{pmatrix}.$$

Berechnen wir diese Determinante und multiplizieren aus, erhalten wir ein Polynom der Form

$$p(\lambda) = c_n \lambda^n + c_{n-1} \lambda^{n-1} + \cdots + c_1 \lambda + c_0.$$

Es wird auch *charakteristisches Polynom* der Matrix A genannt. Die Nullstellen dieses Polynoms sind dann die Eigenwerte von A . Daraus folgt übrigens, dass es maximal n Eigenwerte geben kann.

Um Eigenwerte und Eigenvektoren rechnerisch zu finden geht man wie folgt vor:

1. Finde Eigenwerte λ_k als die Nullstellen des charakteristischen Polynoms $p(\lambda) = \det(A - \lambda I)$.
2. Für jeden Eigenwert λ_k , berechne den Eigenraum E_{λ_k} durch Lösen des LGS $(A - \lambda_k I)\mathbf{x} = \mathbf{0}$.

Per Hand ist dies eigentlich nur für (2×2) - oder (3×3) -Matrizen machbar. Zumindest ein, zwei Mal im Leben sollte man das aber gemacht haben.

Beispiel 4.2.2. Für

$$A = \begin{pmatrix} 3 & -2 \\ 1 & -1 \end{pmatrix}$$

erhalten wir

$$\det(A - \lambda I) = \det \begin{pmatrix} 3 - \lambda & -2 \\ 1 & -1 - \lambda \end{pmatrix} = (3 - \lambda)(-1 - \lambda) + 2 = \lambda^2 - 2\lambda - 1.$$

Lösen wir diese Gleichung nach λ , erhalten wir die beiden Eigenwerte

$$\lambda = \frac{2 \pm \sqrt{(-2)^2 - 4 \cdot 1 \cdot (-1)}}{2 \cdot 1} = 1 \pm \sqrt{2}.$$

Um den Eigenraum $E_{1+\sqrt{2}}$ zu finden, Lösen wir das LGS

$$\begin{pmatrix} 3 - 1 - \sqrt{2} & -2 \\ 2 & -1 - 1 - \sqrt{2} \end{pmatrix} \mathbf{x} = \mathbf{0}.$$

Wir reduzieren

$$\left(\begin{array}{cc|c} 2 - \sqrt{2} & -2 & 0 \\ 1 & -(2 + \sqrt{2}) & 0 \end{array} \right) \xrightarrow{(II) \cdot (2 - \sqrt{2})} \left(\begin{array}{cc|c} 2 - \sqrt{2} & -2 & 0 \\ 2 - \sqrt{2} & -2 & 0 \end{array} \right) \xrightarrow{(II) - (I)} \left(\begin{array}{cc|c} 2 - \sqrt{2} & -2 & 0 \\ 0 & 0 & 0 \end{array} \right)$$

Daraus erhalten wir

$$E_{1+\sqrt{2}} = \text{span} \left\{ \begin{pmatrix} 2/(2 - \sqrt{2}) \\ 1 \end{pmatrix} \right\}$$

und auf ähnliche Weise

$$E_{1-\sqrt{2}} = \text{span} \left\{ \begin{pmatrix} -2/(2 + \sqrt{2}) \\ 1 \end{pmatrix} \right\}.$$

Wir erinnern uns, dass die Determinante von Dreiecksmatrizen besonders einfach zu berechnen war ([Theorem 2.4.6](#)). Wenn wir λI von einer Dreiecksmatrix abziehen, ist das Resultat auch eine Dreiecksmatrix. Daraus folgt direkt das nächste Resultat.

Theorem 4.2.3. Ist $A \in \mathbb{R}^{n \times n}$ eine Dreiecksmatrix, dann sind die Eigenwerte von A gleich den Diagonaleinträgen $a_{ii}, i = 1, \dots, n$.

4.3 Äquivalenzen

Natürlich gibt es auch bei Eigenwerten zahlreiche Querverbindungen zum bisher gelernten. Insbesondere können wir eine Aussage zu Eigenwerten an unsere Liste von Äquivalenzen anknüpfen.

Zunächst intuitiv: Wenn $\lambda = 0$ ein Eigenwert ist, dann gibt es einen ganzen Unterraum $E_0 \neq \{\mathbf{0}\}$, der auf den Nullvektor abgebildet wird: Für alle $\mathbf{x} \in E_0$ gilt $A\mathbf{x} = 0\mathbf{x} = \mathbf{0}$. Jedes Volumen in diesem Unterraum kollabiert, also muss $\det(A) = 0$ gelten. Andersherum gilt das genauso. Wir können das leicht formalisieren und damit auch zu Invertierbarkeit von A etc. verknüpfen.

Theorem 4.3.1 (Äquivalenzen). Sei $A \in \mathbb{R}^{n \times n}$. Dann sind die folgenden Aussagen äquivalent:

- (a) A ist invertierbar.
- (b) $A^\top$ ist invertierbar.
- (c) Die reduzierte Zeilenstufenform von A ist I_n .
- (d) Das LGS $A\mathbf{x} = \mathbf{0}$ hat nur die triviale Lösung.
- (e) Das LGS $A\mathbf{x} = \mathbf{b}$ hat genau eine Lösung für jedes $\mathbf{b} \in \mathbb{R}^n$.
- (f) Das LGS $A\mathbf{x} = \mathbf{b}$ hat eine Lösung für jedes $\mathbf{b} \in \mathbb{R}^n$.
- (g) Die Spalten von A sind linear unabhängig.
- (h) Die Zeilen von A sind linear unabhängig.
- (i) Die Spalten von A spannen $\mathbb{R}^n$.
- (j) Die Zeilen von A spannen $\mathbb{R}^n$.
- (k) $\det(A) \neq 0$.
- (l) $\text{rang}(A) = n$.
- (m) $\ker(A) = \{\mathbf{0}\}$.
- (n) $\lambda = 0$ ist kein Eigenwert von A .

Beweis. Äquivalenz von (a)–(m) haben wir bereits bewiesen. Wir zeigen jetzt $(k) \Leftrightarrow (n)$. Ein Wert λ ist genau dann ein Eigenwert von A , wenn

$$\det(A - \lambda I) = 0.$$

Also ist $\lambda = 0$ genau dann ein Eigenwert, wenn $\det(A) = 0$. Andersherum ist $\lambda = 0$ also genau dann *kein* Eigenwert, wenn $\det(A) \neq 0$. $\square$

Zum Abschluss illustrieren wir einen Fall mit $\lambda = 0$ in einem ausführlichen Beispiel.

Beispiel 4.3.2. Betrachten wir eine (orthogonale) Projektion von $\mathbf{x} \in \mathbb{R}^2$ auf die Gerade in Richtung $\mathbf{v} = (2, 1)$. Was das genau bedeutet lernen wir später noch; für den Moment sollte [Abbildung 4.2](#) zur Erklärung ausreichen. Die Matrixtransformation, die beliebige Vektoren auf diese Gerade $\text{span}\{\mathbf{v}\}$ projiziert,




Abbildung 4.2: Projektion von $\mathbf{u}$ auf den Spann von $\mathbf{v}$. Die Eigenvektoren der Projektionsmatrix P sind $\mathbf{v}$ und $\mathbf{w}$.

ist gegeben⁴ durch

$$P_v = \begin{pmatrix} 0.8 & 0.4 \\ 0.4 & 0.2 \end{pmatrix}.$$

Bevor wir ans Rechnen gehen, können wir uns intuitiv überlegen, was hier die Eigenwerte und Eigenvektoren sein sollen.

- Projiziert man einen Vektor aus $\text{span}\{\mathbf{v}\}$ auf eben diese Gerade, dann passiert natürlich nichts. Also gilt $P_v \mathbf{x} = \mathbf{x}$ für alle $\mathbf{x} \in \text{span}\{\mathbf{v}\}$. Anders gesagt: $\mathbf{v}$ ist Eigenvektor zum Eigenwert 1 und $E_1 = \text{span}\{\mathbf{v}\}$.
- Betrachten wir nun Vektoren $\mathbf{w}$ die am Nullpunkt senkrecht auf der Gerade $\text{span}\{\mathbf{v}\}$ stehen. Ein solcher Vektor ist in [Abbildung 4.2](#) eingezeichnet. Dann werden alle diese Punkte auf den Nullpunkt projiziert. Also ist $\mathbf{w}$ ein Eigenvektor zum Eigenwert 0 und $E_0 = \text{span}\{\mathbf{w}\}$.

In [Abschnitt 2.4.1](#) haben wir bereits gesehen, dass durch eine Projektion Flächen kollabieren. Also erwarten wir hier $\det(A) = 0$ und deshalb auch einen Eigenwert $\lambda = 0$. Tatsächlich:

$$\det \begin{pmatrix} 0.8 & 0.4 \\ 0.4 & 0.2 \end{pmatrix} = 0.8 \cdot 0.2 - 0.4^2 = 0.16 - 0.16 = 0.$$

Zuletzt wollen wir noch den Eigenwert $\lambda = 1$ und E_1 rechnerisch überprüfen. Es gilt

$$\det \begin{pmatrix} 0.8 - 1 & 0.4 \\ 0.4 & 0.2 - 1 \end{pmatrix} = \det \begin{pmatrix} -0.2 & 0.4 \\ 0.4 & -0.8 \end{pmatrix} = (-0.8) \cdot (-0.2) - 0.4^2 = 0.16 - 0.16 = 0.$$

Reduzieren wir das LGS, erhalten wir

$$\left(\begin{array}{cc|c} -0.2 & 0.4 & 0 \\ 0.4 & -0.8 & 0 \end{array} \right) \xrightarrow{(2)+2 \cdot (1)} \left(\begin{array}{cc|c} -0.2 & 0.4 & 0 \\ 0 & 0 & 0 \end{array} \right),$$

⁴Auch diese Matrix zu finden lernen wir später.

woraus wir in der Tat den Eigenvektor $\mathbf{v} = (2, 1)$ ablesen können.

4.4 Diagonalisierung

4.4.1 Die Eigenvektorbasis

Die Eigenvektoren einer Matrix A sind charakteristisch für die zugehörige Abbildung $\mathbf{x} \mapsto A\mathbf{x}$. In Richtung dieser Vektoren hat die Matrix eine besonders einfache Wirkung. Die Vektoren werden lediglich gestreckt, gestaucht oder in der Richtung umgekehrt. Seien $\mathbf{v}_1, \dots, \mathbf{v}_n$ Eigenvektoren von $A \in \mathbb{R}^{n \times n}$ und $\lambda_1, \dots, \lambda_n$ zugehörige Eigenwerte. Nehmen wir mal an, die Vektoren sind linear unabhängig. Dann wäre $\mathcal{B} = \{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ wegen [Theorem 3.3.20](#) auch eine Basis für $\mathbb{R}^n$. Für $B = (\mathbf{v}_1 \cdots \mathbf{v}_n)$ und jedes $\mathbf{x} \in \mathbb{R}^n$ gilt dann

$$\mathbf{x} = B[\mathbf{x}]_{\mathcal{B}} \quad \text{und} \quad B^{-1}\mathbf{x} = [\mathbf{x}]_{\mathcal{B}}.$$

Wir können damit die Transformation $\mathbf{x} \mapsto A\mathbf{x}$ auch in der Basis $\mathcal{B}$ darstellen, sprich $[\mathbf{x}]_{\mathcal{B}} \mapsto [A\mathbf{x}]_{\mathcal{B}}$:

1. Wir bringen $[\mathbf{x}]_{\mathcal{B}}$ durch Multiplikation mit B in die Standardbasis.
2. Wir multiplizieren $\mathbf{x}$ mit A .
3. Wir bringen das Resultat $A\mathbf{x}$ durch Multiplikation mit B^{-1} zurück in die Koordinaten der Basis $\mathcal{B}$.

Es ergibt sich dann

$$[A\mathbf{x}]_{\mathcal{B}} = B^{-1}AB[\mathbf{x}]_{\mathcal{B}}.$$

Der Vorgang lässt sich durch folgendes Diagramm verstehen:

$$\begin{array}{ccc} [\mathbf{x}]_{\mathcal{B}} & \xrightarrow{B^{-1}AB} & [A\mathbf{x}]_{\mathcal{B}} \\ B \downarrow & & \uparrow B^{-1} \\ \mathbf{x} & \xrightarrow{A} & A\mathbf{x} \end{array}$$

Sei

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n) = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \lambda_n \end{pmatrix}$$

Betrachten wir die Matrix $B^{-1}AB$ genauer, stellen wir fest:

$$\begin{aligned}
 B^{-1}AB &= B^{-1}A(\mathbf{v}_1 \cdots \mathbf{v}_n) \\
 &= B^{-1}(A\mathbf{v}_1 \cdots A\mathbf{v}_n) \\
 &= B^{-1}(\lambda_1\mathbf{v}_1 \cdots \lambda_n\mathbf{v}_n) \\
 &= (\lambda_1 B^{-1}\mathbf{v}_1 \cdots \lambda_n B^{-1}\mathbf{v}_n) \\
 &= \Lambda(B^{-1}\mathbf{v}_1 \cdots B^{-1}\mathbf{v}_n) \\
 &= \Lambda B^{-1}B \\
 &= \Lambda.
 \end{aligned}$$

In der Eigenvektorbasis $\mathcal{B}$ ist die Transformation $\mathbf{x} \mapsto A\mathbf{x}$ also lediglich eine Multiplikation mit einer Diagonalmatrix, gefüllt mit den Eigenwerten. Jede Koordinate wird lediglich um den zugehörigen Eigenwert gestreckt. In der Basis $\mathcal{B}$ lässt sich die Transformation also bemerkenswert einfach verstehen. Wir sagen dann, dass $\mathcal{B}$ die Matrix A **diagonalisiert**.

Andersherum können wir A auch als $B\Lambda B^{-1}$ schreiben. Dies wird auch **Spektralzerlegung** genannt. Multiplikation mit A in der Standardbasis können wir dann auch so verstehen:

1. Wir bringen $\mathbf{x}$ durch Multiplikation mit B^{-1} in $\mathcal{B}$ -Koordinaten.
2. Wir multiplizieren das Resultat $[\mathbf{x}]_{\mathcal{B}} = B^{-1}\mathbf{x}$ mit der Diagonalmatrix Λ .
3. Wir bringen das Resultat $\Lambda B^{-1}\mathbf{x}$ durch Multiplikation mit B zurück in die Koordinaten der Standardbasis.

$$\begin{array}{ccc}
 \mathbf{x} & \xrightarrow{A=B\Lambda B^{-1}} & A\mathbf{x} \\
 B^{-1} \downarrow & & \uparrow B \\
 [\mathbf{x}]_{\mathcal{B}} & \xrightarrow{\Lambda} & [A\mathbf{x}]_{\mathcal{B}}
 \end{array}$$

4.4.2 Diagonalisierbarkeit

Definition 4.4.1. Wir nennen eine Matrix $A \in \mathbb{R}^{n \times n}$ **diagonalisierbar**, wenn es eine invertierbare Matrix P und eine Diagonalmatrix D gibt, sodass $P^{-1}AP = D$.

Wir haben vorher angenommen, dass die Eigenvektoren linear unabhängig sind. Das ist nicht nur eine hinreichende Bedingung für Diagonalisierbarkeit, sondern auch notwendig.

Theorem 4.4.2. Für $A \in \mathbb{R}^{n \times n}$ sind äquivalent:

- (i) A ist diagonalisierbar.
- (ii) A hat n linear unabhängige Eigenvektoren.

Beweis. Die Richtung (ii) $\Rightarrow$ (i) haben wir bereits gezeigt. Nehmen wir nun an, A ist diagonalisierbar. Dann gibt es invertierbares P und eine Diagonalmatrix D , sodass $P^{-1}AP = D$ oder, äquivalent dazu, $AP = PD$. Seien $\mathbf{p}_1, \dots, \mathbf{p}_n$ die Spaltenvektoren von P und $d_1, \dots, d_n$ die Diagonaleinträge von D . Dann gilt

$$AP = (A\mathbf{p}_1 \cdots A\mathbf{p}_n) \quad \text{und} \quad PD = (d_1\mathbf{p}_1 \cdots d_n\mathbf{p}_n).$$

Betrachten wir die Gleichung $AP = PD$ spaltenweise, folgt also

$$A\mathbf{p}_1 = d_1\mathbf{p}_1, \quad \dots, \quad A\mathbf{p}_n = d_n\mathbf{p}_n.$$

Also sind $\mathbf{p}_1, \dots, \mathbf{p}_n$ Eigenvektoren zu den Eigenwerten $d_1, \dots, d_n$. Weil die Matrix $P = (\mathbf{p}_1 \cdots \mathbf{p}_n)$ invertierbar ist, müssen die Spaltenvektoren linear unabhängig sein, sh. [Theorem 4.3.1](#) (a) & (g). $\square$

Um eine Matrix zu diagonalisieren, müssen wir also nur n linear unabhängige Eigenvektoren finden. Das ist nicht immer, aber häufig möglich. Das nächste Resultat zeigt uns einen wichtigen Fall.

Theorem 4.4.3. *Seien $\lambda_1 \neq \dots \neq \lambda_r$ verschiedene Eigenwerte einer Matrix A . Dann sind zugehörige Eigenvektoren $\mathbf{v}_1, \dots, \mathbf{v}_r$ linear unabhängig.*

Beweis. Angenommen $\mathbf{v}_1, \dots, \mathbf{v}_r$ sind linear abhängig. Dann lässt sich ein $\mathbf{v}_k$ als Linearkombination der vorherigen Eigenvektoren schreiben. Sei k der kleinste Index, für den das möglich ist. Es gibt also $c_1, \dots, c_{k-1}$, sodass

$$c_1\mathbf{v}_1 + \cdots + c_{k-1}\mathbf{v}_{k-1} = \mathbf{v}_k. \tag{4.1}$$

Multiplizieren wir die Gleichung mit A , erhalten wir

$$c_1A\mathbf{v}_1 + \cdots + c_{k-1}A\mathbf{v}_{k-1} = A\mathbf{v}_k$$

und, weil $\mathbf{v}_1, \dots, \mathbf{v}_k$ Eigenvektoren sind,

$$c_1\lambda_1\mathbf{v}_1 + \cdots + c_{k-1}\lambda_{k-1}\mathbf{v}_{k-1} = \lambda_k\mathbf{v}_k = c_1\lambda_k\mathbf{v}_1 + \cdots + c_{k-1}\lambda_k\mathbf{v}_{k-1},$$

wobei wir in der letzten Gleichheit (4.1) verwendet haben. Ziehen wir die rechte von der linken Seite ab, erhalten wir

$$c_1(\lambda_1 - \lambda_k)\mathbf{v}_1 + \cdots + c_{k-1}(\lambda_{k-1} - \lambda_k)\mathbf{v}_{k-1} = \mathbf{0}.$$

Weil $\mathbf{v}_1, \dots, \mathbf{v}_{k-1}$ linear unabhängig sind, muss gelten

$$c_1(\lambda_1 - \lambda_k) = \cdots = c_{k-1}(\lambda_{k-1} - \lambda_k) = 0$$

und, weil die Eigenwerte alle verschieden sind,

$$c_1 = \cdots = c_{k-1} = 0.$$

Daraus erhalten wir $\mathbf{v}_k = c_1 \mathbf{v}_1 + \dots + c_{k-1} \mathbf{v}_{k-1} = \mathbf{0}$, aber dann kann $\mathbf{v}_k$ kein Eigenvektor sein. Dies ist ein Widerspruch, also müssen die Vektoren linear unabhängig sein. $\square$

Aus den letzten beiden Resultaten folgt dann:

Korollar 4.4.4. *Hat $A \in \mathbb{R}^{n \times n}$ n verschiedene Eigenwerte, so ist sie diagonalisierbar.*

Es stellt sich noch die Frage, was passiert, wenn es weniger als n verschiedene Eigenwerte gibt. Auch das können wir beantworten. Den Beweis dazu sparen wir uns mal, auch wenn er nicht allzu schwierig ist.

Theorem 4.4.5. *Sei $A \in \mathbb{R}^{n \times n}$ und $\lambda_1, \dots, \lambda_r$ die verschiedenen Eigenwerte. A genau dann diagonalisierbar, wenn es eine Basis aus Eigenvektoren gibt. Dies ist äquivalent zu*

$$\dim(E_{\lambda_1}) + \dots + \dim(E_{\lambda_r}) = n.$$

Hat ein Eigenraum E_λ Dimension k , dann steht der zugehörige Eigenwert k mal in der Matrix Λ . Die Zahl k nennen wir auch *geometrische Multiplizität*.

4.4.3 Konsequenzen

Die Diagonalisierung ist besonders nützlich um die Wirkung einer Matrixtransformation zu verstehen. Innerhalb eines Eigenraums werden Vektoren lediglich entlang der Eigenvektoren gestreckt. Die Transformation in die Basis bestehend aus Eigenvektoren nennen wir auch *Hauptachsentransformation*. In der Statistik spielt sie als *principal component analysis (PCA)* eine wichtige Rolle. Mehr dazu in Kürze. Andersherum können wir A auch als $P\Lambda P^{-1}$ schreiben. Dies wird auch **Spektralzerlegung** genannt.

Es gibt aber noch andere nützliche Eigenschaften. So ist zum Beispiel

$$\det(A) = \det(P\Lambda P^{-1}) = \det(P) \det(\Lambda) \frac{1}{\det(P)} = \det(\Lambda).$$

Das gilt übrigens unabhängig davon, ob P aus Eigenvektoren besteht und Λ diagonal ist.

Die Determinante einer Transformation ist unabhängig von der Basis, in der wir die Transformation darstellen.

Insbesondere haben wir aber das folgende Resultat gezeigt:

Theorem 4.4.6. Sei $A \in \mathbb{R}^{n \times n}$ diagonalisierbar zu $A = P\Lambda P^{-1}$ mit $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$. Dann gilt

$$\det(A) = \prod_{k=1}^n \lambda_k.$$

Die Determinante ist also nichts anderes als das Produkt der Eigenwerte. Ein Eigenwert kann in diesem Produkt aber häufiger vorkommen, wenn der zugehörige Eigenraum höherdimensional ist.

Eine weitere Anwendung findet sich in Matrixpotenzen.

Theorem 4.4.7. Sei $A = P\Lambda P^{-1}$. Dann gilt für alle $k \in \mathbb{N}$

$$A^k = P\Lambda^k P^{-1}.$$

Beweis. Machen wir in der Übung. □

Die Matrix Λ^k ist leicht zu berechnen, weil Λ diagonal ist. Es gilt

$$\Lambda^k = \text{diag}(\lambda_1^k, \dots, \lambda_n^k).$$

Ähnlich verhält es sich mit Inversen. Ist A invertierbar, so gilt natürlich $A^{-1} = P\Lambda^{-1}P^{-1}$. Die Matrix Λ ist leicht zu invertieren:

$$\Lambda^{-1} = \text{diag}(\lambda_1^{-1}, \dots, \lambda_n^{-1}).$$

Für höhere Potenzen können wir nun $A^{-k} = (A^{-1})^k$ schreiben und das vorherige Theorem verwenden. Wir haben das folgende Resultat gezeigt.

Theorem 4.4.8. Sei $A = P\Lambda P^{-1}$ invertierbar. Dann gilt für alle $k \in \mathbb{N}$

$$A^{-k} = P\Lambda^{-k}P^{-1}.$$

4.5 Komplexe Eigenwerte

Man kann das ganze Spiel der linearen Algebra auch auf komplexen Zahlen treiben. Für Statistiker wird die Theorie dadurch aber unnötig abstrakt. Im Kontext von Eigenwerten kommen wir aber nicht ganz darum herum.

Wir erinnern uns, dass die Eigenwerte einer Matrix die Nullstellen des charakteristischen Polynoms

$$p(\lambda) = \det(A - \lambda I) = c_n \lambda^n + \dots + c_1 \lambda + c_0$$

sind. Es ist aber nicht gesagt, dass dieses Polynom überhaupt eine Nullstelle $\lambda \in \mathbb{R}$ besitzt.

Beispiel 4.5.1. Nehmen wir die Rotationsmatrix um 90° gegen den Uhrzeigersinn:

$$M = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}.$$

Dann gilt

$$\det(M - \lambda I) = \det \begin{pmatrix} -\lambda & -1 \\ 1 & -\lambda \end{pmatrix} = \lambda^2 + 1.$$

Die Gleichung $\lambda^2 = -1$ hat keine reellen Lösungen. Genauso kann es keinen reellen Eigenvektor geben. Eine Rotation verändert immer die Richtung eines Vektors (außer von $\mathbf{0}$).

Allerdings hat die Gleichung $\lambda^2 = -1$ die komplexen Lösungen $\lambda = \pm i \in \mathbb{C}$. Allgemeiner sagt der *Fundamentalsatz der Algebra*, dass jedes Polynom zumindest eine (womöglich komplexe) Nullstelle hat. Wir können auch zugehörige Eigenvektoren finden, wenn wir komplexwertige Einträge zulassen.

Definition 4.5.2. Sei $A \in \mathbb{R}^{n \times n}$. Ein Vektor $\mathbf{x} \neq \mathbf{0} \in \mathbb{C}^n$ wird **Eigenvektor** von A genannt, wenn es ein Skalar $\lambda \in \mathbb{C}$ gibt, sodass

$$A\mathbf{x} = \lambda\mathbf{x}.$$

Der Skalar λ wird **Eigenwert** von A genannt und $\mathbf{x}$ auch der **zu λ gehörige Eigenvektor**.

Beispiel 4.5.3. Für die Rotationsmatrix oben finden wir für $\lambda = i$ den Eigenvektor $(1, -i)$, denn

$$\begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ -i \end{pmatrix} = \begin{pmatrix} i \\ 1 \end{pmatrix} = i \begin{pmatrix} 1 \\ -i \end{pmatrix}.$$

Zum Eigenwert $\lambda = -i$ finden wir den Eigenvektor $(1, i)$:

$$\begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ i \end{pmatrix} = \begin{pmatrix} -i \\ 1 \end{pmatrix} = -i \begin{pmatrix} 1 \\ i \end{pmatrix}.$$

Im Beispiel haben wir gesehen, dass die beiden Eigenwerte jeweils Konjugierte voneinander waren.⁵ Ebenso waren die Einträge in den zugehörigen Eigenvektoren Konjugierte voneinander. Das ist allgemein wahr und folgt direkt aus den Rechenregeln für komplexe Zahlen.

⁵Für eine komplexe Zahl $z = a + ib$ ist die Konjugierte $\bar{z} = a - ib$. Bei Vektoren verstehen wir Konjugation komponentenweise.

Theorem 4.5.4. Sei $A \in \mathbb{R}^{n \times n}$, λ ein Eigenwert von A und $\mathbf{v}$ ein zugehöriger Eigenvektor. Dann ist auch $\bar{\lambda}$ ein Eigenwert von A und $\bar{\mathbf{v}}$ ein zugehöriger Eigenvektor.

Komplexe Eigenwerte tauchen meist bei Rotationen oder anderweitig periodischen Transformationen auf. Im Großen und Ganzen spielen sie in der Statistik eine untergeordnete Rolle. Deshalb belassen wir es nun bei diesem kleinen Ausflug. Merkt euch einfach, dass komplexe Eigenwerte und -vektoren auftreten können. Und falls euch sowas doch mal unterkommt, könnt ihr euch tiefer dazu einlesen.

4.6 Anwendungen

4.6.1 PCA

Die *Hauptkomponentenanalyse* (englisch *principal component analysis* oder *PCA*) ist eins der wichtigsten Werkzeuge in der multivariaten Statistik. Es hilft dabei, Zusammenhänge in großen Datensätzen leichter zu verstehen oder die Dimension zu reduzieren, ohne wichtige Information zu verlieren.

Die Idee

Angenommen unsere Daten bestehen aus d Variablen. Eine Realisierung können wir dann als Vektor $\mathbf{x} \in \mathbb{R}^d$ schreiben. Den zugehörigen Zufallsvektor schreiben wir als $\mathbf{X} \in \mathbb{R}^d$. Sei $\Sigma = \text{Cov}(\mathbf{X})$ die Kovarianzmatrix von $\mathbf{X}$. Die Diagonaleinträge beschreiben, wie viel Varianz in den einzelnen Variablen ist. Die anderen Einträge, ob und wie stark Abhängigkeit zwischen den Variablen besteht.

Wenn d groß ist, steckt eine unüberschaubare Menge an Information in Σ . Um die Variabilität und Zusammenhänge in den Daten leichter zu verstehen, können wir Σ diagonalisieren. Wir finden dazu die Eigenvektoren $\mathbf{v}_1, \dots, \mathbf{v}_n$ und zugehörigen Eigenwerte $\lambda_1, \dots, \lambda_n$. Dann gilt

$$\Sigma = P \Lambda P^{-1},$$

wobei $P = (\mathbf{v}_1 \cdots \mathbf{v}_n)$ und $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$. Die Matrizen P und P^{-1} bringen uns in die Koordinaten der Eigenvektorbasis. Dort hat die Matrix Σ eine einfache Darstellung Λ .

Nehmen wir o.B.d.A an, die Eigenwerte sind der Größe nach geordnet: $\lambda_1 \geq \lambda_2 \geq \dots \geq 0$.⁶ Dann kann man zeigen, dass der Eigenvektor $\mathbf{v}_1$ die Richtung vorgibt, in der am meisten Variabilität besteht. Genauso ist $\mathbf{v}_n$ die Richtung, wo am wenigsten passiert. Um die Daten zu verstehen, können wir uns also auf die Richtungen der ersten paar Eigenvektoren beschränken.




Abbildung 4.3: Links: Datenpunkte und die Hauptkomponenten. Rechts: Die Gleichen Daten in der Eigenvektorbasis.

Illustration

Das Ganze ist im $\mathbb{R}^2$ in [Abbildung 4.3](#) illustriert. Wir sehen links 100 Datenpunkte. Die empirische Kovarianzmatrix berechnen wir durch

```
1 Sig <- cov(data)
2 #>      [,1]      [,2]
3 #> [1,]  1.787125  1.111877
4 #> [2,]  1.111877  1.080091
```

Die Eigenwerte und Eigenvektoren bekommen wir so:

```
1 eig <- eigen(Sig)
2 lambda <- eig$values
3 #> [1]  2.6003321  0.2668837
4 P <- eig$vectors
5 #>      [,1]      [,2]
6 #> [1,] -0.8071555  0.5903389
7 #> [2,] -0.5903389 -0.8071555
```

Der Eigenvektor $\mathbf{v}_1$ (erste Spalte in P) ist in [Abbildung 4.3](#) grün eingezeichnet, $\mathbf{v}_2$ lila. Die Länge der Vektoren haben wir proportional zu $\sqrt{\lambda_k}$ gewählt, weil dies der Standardabweichung in dieser Richtung entspricht. In Richtung von $\mathbf{v}_1$ ist am meisten Variabilität; die Datenpunkte sind entlang dieser Achse am besten zu unterscheiden. $\mathbf{v}_2$ ist die Richtung, in der am wenigsten Variabilität stattfindet.

Durch Transformation mit P^{-1} können wir die Daten auch im Koordinatensystem $\{\mathbf{v}_1, \mathbf{v}_2\}$ darstellen. Die transformierten Daten sind rechts in [Abbildung 4.3](#) zu sehen. Man kann beweisen, dass die Daten in diesen Koordinaten unkorreliert sind, was die Interpretation weiter erleichtert.

⁶Dass die Eigenwerte einer symmetrischen Matrix alle positiv sind, beweisen wir später noch.

Anwendung: Diskrimination auf dem Münchner Mietmarkt

Im R^2 mag die PCA noch nicht sonderlich nützlich erscheinen. Schauen wir uns deshalb noch ein ernst zu nehmendes Beispiel mit echten Daten an. Der Datensatz ist ein Auszug einer Studie der Datenjournalisten von BR Data und SPIEGEL ONLINE, sh. <http://www.hanna-und-ismail.de>. In der Studie wurden unter unterschiedlichem Namen Anfragen an Wohnungsinserate geschickt. Ziel war es zu überprüfen, ob manche Bevölkerungsgruppen bei der Einladung zur Wohnungsbesichtigung diskriminiert werden. Wir beschränken uns hier auf Daten aus München.

Der Datensatz sieht wie folgt aus:

```
1 head(data)
2 #> # A tibble: 6 x 6
3 #>   preis zimmer flaeche deutsch maennlich einladung
4 #>   <dbl> <dbl>   <dbl>   <dbl>   <dbl>   <dbl>
5 #> 1   890     2    51.2     1       0       1
6 #> 2   890     2    51.2     0       0       1
7 #> 3   890     2    51.2     0       0       1
8 #> 4   910     2    54.5     0       1       1
9 #> 5   850     2     50     0       0       1
10 #> 6   850     2     50     1       0       0
```

Die ersten drei Spalten beschreiben die Wohnung, für die eine Anfrage zur Besichtigung gestellt wurde. Die vierte besagt, ob der Name der anfragenden Person deutsch klingt (1 = ja, 0 = nein). Die fünfte, ob der Name männlich ist (1 = ja, 0 = nein). Die letzte Spalte sagt, ob die Anfrage zu einer Einladung geführt hat (1 = ja, 0 = nein).

Um ein Verständnis für die Zusammenhänge zu bekommen, führen wir eine PCA durch. Weil die Variablen so unterschiedliche Skalen haben, standardisieren wir alle, sodass sie Varianz 1 haben. Äquivalent dazu, können wir die Diagonalisierung auch auf die Korrelationsmatrix anwenden.

```
1 R <- cor(data)
2 eig <- eigen(R)
3 lambda <- round(eig$values, 1)
4 lambda
5 #> [1] 2.3 1.2 1.0 0.8 0.6 0.1
6 P <- round(eig$vectors, 1)
7 rownames(P) <- names(data)
8 P
9 #>
10 #>   [,1] [,2] [,3] [,4] [,5] [,6]
11 #> preis -0.4 -0.4 -0.1 -0.3  0.7 -0.2
12 #> zimmer -0.6  0.1  0.1  0.0 -0.5 -0.6
13 #> flaeche -0.6 -0.1  0.1 -0.1 -0.2  0.7
14 #> deutsch  0.1 -0.6  0.5  0.6  0.0  0.0
15 #> maennlich 0.0 -0.4 -0.9  0.3 -0.1  0.0
16 #> einladung 0.3 -0.6  0.1 -0.7 -0.4  0.0
```

Die erste Spalte von P ist die wichtigste Richtung. Wandern wir entlang dieser

Richtung, multiplizieren wir den Vektor mit einem Faktor. Preis, Zimmerzahl und Fläche bewegen sich dabei immer in die gleiche Richtung. Das macht Sinn, da die drei Variablen stark Korrelieren. Wir sehen auch, dass sich die Einladungswahrscheinlichkeit in die entgegengesetzte Richtung bewegt. Je teurer/größer eine Wohnung also ist, desto weniger wahrscheinlich war es also allgemein, eingeladen zu werden.

Interessant ist der zweitwichtigste Eigenvektor. Bewegen wir uns entlang dieser Richtung, bewegen sich Deutsch-Sein, Männlich-Sein und Eingeladen-Werden in die gleiche Richtung. Das bedeutet, dass Deutsche und Männer tendenziell eher zu Besichtigungen eingeladen werden. Ähnlich können wir auch die weiteren Spalten interpretieren, wobei deren Bedeutung entsprechend den zugehörigen Eigenwerten abnimmt.

Eine formale Modellierung, die gesicherte statistische Inferenz erlaubt, ist natürlich aufwändiger als das. Zur explorativen Analyse von multivariaten Daten ist die PCA aber unglaublich mächtig. Sie wird euch noch das ein oder andere Mal im Studium begegnen.

4.6.2 Markovketten und Google

In [Abschnitt 2.3.3](#) haben wir bereits dynamische Systeme und Markovketten eingeführt. Wir wollen das jetzt ein bisschen vertiefen, mit einem Beispiel, das uns jeden Tag begegnet. Google's Suchalgorithmus basiert im Wesentlichen auf einer Markovkette. Larry Page, einer der Gründer von Google, hat kurz vor der Jahrtausendwende den *PageRank* Algorithmus erfunden. Um die Idee zu verstehen, beschränken wir uns zunächst auf ein vereinfachtes Setting.

Das stochastische Modell

Angenommen es gibt nur 5 Webseiten zu einem Suchbegriff. Die Suchmaschine versucht nun die Webseiten in eine Rangliste zu ordnen, je nachdem wie wichtig die Webseiten sind. Manche der Webseiten haben Links zu anderen. Die grobe Idee ist, dass Seiten, zu denen mehr Links bestehen, wichtiger sind. Wir stellen uns dabei einen idiotischen Nutzer Bob vor. Bob surft endlos durch das Web (bestehend aus 5 Seiten) und klickt wahllos auf Links. Die Wahrscheinlichkeiten, dass Bob nach t Schritten auf einer der 5 Webseiten ist, lassen sich als Zustandsvektor

$$\mathbf{p}^{(t)} = \begin{pmatrix} \mathbb{P}(S^{(t)} = 1) \\ \mathbb{P}(S^{(t)} = 2) \\ \mathbb{P}(S^{(t)} = 3) \\ \mathbb{P}(S^{(t)} = 4) \\ \mathbb{P}(S^{(t)} = 5) \end{pmatrix} \in \mathbb{R}^5$$

darstellen. Die Wahrscheinlichkeiten zum Zeitpunkt $t + 1$ modellieren wir durch Multiplikation mit einer Matrix von Übergangswahrscheinlichkeiten

$$M = \begin{pmatrix} \mathbb{P}(S^{(t+1)} = 1 \mid S^{(t)} = 1) & \cdots & \mathbb{P}(S^{(t+1)} = 1 \mid S^{(t)} = 5) \\ \vdots & & \vdots \\ \mathbb{P}(S^{(t+1)} = 5 \mid S^{(t)} = 1) & \cdots & \mathbb{P}(S^{(t+1)} = 5 \mid S^{(t)} = 5) \end{pmatrix} \in \mathbb{R}^{5 \times 5}.$$

Angenommen Bob ist so wahllos, dass er jedem auf der Seite vorhandenen Link mit gleicher Wahrscheinlichkeit folgt. Dann könnte M zum Beispiel so aussehen:

$$M = \begin{pmatrix} 0 & 1/2 & 0 & 0 & 1/4 \\ 1/3 & 0 & 1/2 & 1/3 & 1/4 \\ 1/3 & 0 & 0 & 1/3 & 1/4 \\ 0 & 1/2 & 0 & 0 & 1/4 \\ 1/3 & 0 & 1/2 & 1/3 & 0 \end{pmatrix}.$$

Seite 1 hat also Links zu Seiten 2, 3 und 5. Seite 2 hat Links zu Seiten 1 und 4, usw. Wenn Bob mit gleicher Wahrscheinlichkeit auf jeder der fünf Seiten startet, dann ist

$$\mathbf{p}^{(1)} = \begin{pmatrix} 1/5 \\ 1/5 \\ 1/5 \\ 1/5 \\ 1/5 \end{pmatrix}$$

und, allgemein,

$$\mathbf{p}^{(t)} = M^{t-1} \mathbf{p}^{(1)}.$$

Zum Beispiel gilt

$$\mathbf{p}^{(3)} \approx \begin{pmatrix} 0.200 \\ 0.250 \\ 0.158 \\ 0.200 \\ 0.192 \end{pmatrix}, \quad \mathbf{p}^{(5)} \approx \begin{pmatrix} 0.183 \\ 0.259 \\ 0.168 \\ 0.183 \\ 0.206 \end{pmatrix}, \quad \mathbf{p}^{(10)} \approx \begin{pmatrix} 0.181 \\ 0.259 \\ 0.172 \\ 0.181 \\ 0.207 \end{pmatrix}.$$

Wir auch in [Abschnitt 2.3.3](#) erreichen wir also einen Gleichgewichtszustand $\mathbf{q}$. Die Wahrscheinlichkeiten in diesem Zustand können wir als Ranking der Webseiten betrachten. Ein zufälliger User dürfte im Durchschnitt mit den Wahrscheinlichkeiten $\mathbf{q}$ auf den jeweiligen Webseiten landen.

Der Gleichgewichtszustand als Eigenvektor

Wie in [Abschnitt 2.3.3](#) gezeigt, gilt für den Gleichgewichtszustand $M\mathbf{q} = \mathbf{q}$. Der Vektor $\mathbf{q}$ ist also Eigenvektor zum Eigenwert 1. So einen Vektor gibt es immer.

Theorem 4.6.1. Sei $M \in \mathbb{R}^{n \times n}$ eine Matrix, des Spalten sich zu 1 summieren. Dann hat M den Eigenwert 1.

Beweis. Da die Determinante durch Transposition nicht verändert wird, gilt

$$\det(M - \lambda I) = \det((M - \lambda I)^\top) = \det(M^\top - \lambda I).$$

Also haben M und $M^\top$ die gleichen Eigenwerte. In $M^\top$ summieren sich die Zeilen zu 1. Also gilt

$$M^\top \mathbf{1} = \mathbf{1}.$$

Also ist 1 ein Eigenwert von $M^\top$ (mit $\mathbf{1}$ als Eigenvektor) und damit ist 1 auch ein Eigenwert von M . $\square$

Probleme mit dem Modell

In [Abschnitt 2.3.3](#) haben wir aber noch mehr behauptet. Nämlich, dass die Kette unabhängig von $\mathbf{p}^{(1)}$ immer zum Gleichgewichtszustand $\mathbf{q}$ konvergiert. Das ist nicht für jede Matrix M der Fall und das können wir über die Spektralzerlegung verstehen. Sei $M = P\Lambda P^{-1}$, wobei P die Eigenvektoren in den Spalten hat und $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ die zugehörigen Eigenwerte enthält. Dann ist

$$\lim_{n \rightarrow \infty} M^n = P \left(\lim_{n \rightarrow \infty} \Lambda^n \right) P^{-1} = P \text{diag} \left(\lim_{n \rightarrow \infty} \lambda_1^n, \dots, \lim_{n \rightarrow \infty} \lambda_d^n \right) P^{-1}.$$

Damit λ^n konvergiert, muss $\lambda \in (-1, 1]$ gelten. Sei aber zum Beispiel

$$M = \begin{pmatrix} 0 & 1 & 0 & 0 & 1/4 \\ 1 & 0 & 1/2 & 1/3 & 1/4 \\ 0 & 0 & 0 & 1/3 & 1/4 \\ 0 & 0 & 0 & 0 & 1/4 \\ 0 & 0 & 1/2 & 1/3 & 0 \end{pmatrix}.$$

Startet ein User auf Seite 1, wird er sicher als Nächstes auf Seite 2 landen. Danach wird er zu Seite 2 zurückkehren, usw. Der Zustand kann sich so niemals stabilisieren. Tatsächlich können wir leicht überprüfen, dass -1 ein Eigenwert ist, denn

$$\begin{pmatrix} 0 & 1 & 0 & 0 & 1/4 \\ 1 & 0 & 1/2 & 1/3 & 1/4 \\ 0 & 0 & 0 & 1/3 & 1/4 \\ 0 & 0 & 0 & 0 & 1/4 \\ 0 & 0 & 1/2 & 1/3 & 0 \end{pmatrix} \begin{pmatrix} -1 \\ 1 \\ 0 \\ 0 \\ 0 \end{pmatrix} = -1 \cdot \begin{pmatrix} -1 \\ 1 \\ 0 \\ 0 \\ 0 \end{pmatrix}.$$

Also kann M^n nicht konvergieren.

Das Problem ist, dass die Markovkette ein periodisches Verhalten aufweist. Diesen Fall auszuschließen, war eine der Hauptinnovationen des *PageRank*-Algorithmus.

Der PageRank-Algorithmus

Hier nimmt man eine etwas weniger idiotische Nutzerin Alice an. Alice klickt meistens mit gleicher Wahrscheinlichkeit auf die vorhandenen Links, aber manchmal springt sie mit auch zu einer beliebigen Seite in Web. Sei $\delta > 0$ die Wahrscheinlichkeit, dass Alice sich entscheidet, eine beliebige Seite aufzurufen. Dann ist die neue Übergangsmatrix

$$\tilde{M} = (1 - \delta)M + \frac{\delta}{n}1_{n \times n},$$

wobei alle Einträge der Matrix $1_{n \times n} \in \mathbb{R}^{n \times n}$ gleich 1 sind. In $\tilde{M}$ sind alle Einträge strikt positiv. Damit kann sichergestellt werden, dass -1 kein Eigenwert ist. Das folgt zum Beispiel aus dem *Perron-Frobenius-Theorem*⁷.

Den PageRank-Algorithmus haben Larry Page und Sergey Brin 1996 in einem Forschungsprojekt an der Stanford University entwickelt. Kurz darauf haben sie Google gegründet und den Algorithmus patentiert. Google's Kernprodukt, die Suchmaschine, basierte damals im Wesentlichen auf diesem Algorithmus. Aber selbst heute ist eine weiterentwickelte Variante noch (teilweise) im Einsatz.

⁷Sh. https://de.wikipedia.org/wiki/Satz_von_Perron-Frobenius. Die englische Wikipedia enthält auch Beweise: https://en.wikipedia.org/wiki/Perron-Frobenius_theorem#Proof_methods.