

5 Orthogonalität und Projektionen

Aus der Schule sind uns im $\mathbb{R}^2$ die Konzepte *Länge*, *Abstand*, *Winkel* und *Projektion* bereits bekannt. Sie geben dem Raum eine geometrische Struktur. Diese Struktur gibt uns nicht nur Intuition, sie ist auch ein mächtiges Werkzeug. Wir wollen diese Konzepte erweitern und so auch dem $\mathbb{R}^n$ und anderen Vektorräumen eine vergleichbare Struktur verschaffen. Wir legen hierbei den Fokus hauptsächlich auf den $\mathbb{R}^n$, auch wenn viele Konzepte und Resultate bereits für allgemeine Vektorräume hergeleitet werden. Es ist zum einfacheren Verständnis aber ratsam, sich immer den $\mathbb{R}^n$ vor Augen zu halten. Konkrete Beispiele in anderen Vektorräumen besprechen wir erst am Ende.

5.1 Norm eines Vektors




Abbildung 5.1: Die Länge/Norm eines Vektors im $\mathbb{R}^2$ und $\mathbb{R}^3$.

Zunächst wollen wir die Konzepte *Länge* und *Abstand* im $\mathbb{R}^2$ in Vektornotation umschreiben. Als Länge oder **Norm** $\|\mathbf{v}\|$ eines Vektors verstehen wir die Länge des Verbindungsstücks zwischen dem Nullpunkt $(0, 0)$ und dem Punkt (v_1, v_2) . In [Abbildung 5.1a](#) sehen wir den Vektor $\mathbf{v}$ als grünen Pfeil vom Nullpunkt zum Punkt $\mathbf{v} = (v_1, v_2)$. Wir sehen, dass der Pfeil in einem Dreieck mit den Punkten $(0, 0)$ und $(0, v_1)$ gegenüber eines rechten Winkels liegt. Nach dem Satz des Pythagoras gilt dann

$$\|\mathbf{v}\|^2 = v_1^2 + v_2^2 \quad \text{oder} \quad \|\mathbf{v}\| = \sqrt{v_1^2 + v_2^2}.$$

Eine ähnliche Formel können wir im $\mathbb{R}^3$ herleiten. Zunächst Berechnen wir die Länge des Vektors $\hat{\mathbf{v}}$ in der v_1 - v_3 -Fläche wie zuvor im $\mathbb{R}^2$:

$$\|\hat{\mathbf{v}}\|^2 = v_1^2 + v_3^2.$$

Nun können wir über das Dreieck $\mathbf{0}-\hat{\mathbf{v}}-\mathbf{v}$, die Länge von $\mathbf{v}$ berechnen als

$$\|\mathbf{v}\|^2 = \|\hat{\mathbf{v}}\|^2 + v_2^2 = v_1^2 + v_2^2 + v_3^2.$$

Genauso definieren wir die Norm auch in höheren Dimensionen.

Definition 5.1.1. Die **Norm** eines Vektors $\mathbf{v} \in \mathbb{R}^n$ ist definiert als

$$\|\mathbf{v}\| = \sqrt{v_1^2 + \cdots + v_n^2}.$$

Die folgenden Eigenschaften lassen sich leicht aus der Definition beweisen.

Theorem 5.1.2. Für $\mathbf{v} \in \mathbb{R}^n$ und $c \in \mathbb{R}$ gilt:

- (i) $\|\mathbf{v}\| \geq 0$.
- (ii) $\|\mathbf{v}\| = 0$ genau dann, wenn $\mathbf{v} = \mathbf{0}$.
- (iii) $\|c\mathbf{v}\| = |c|\|\mathbf{v}\|$

Vektoren mit Norm 1 spielen eine besondere Rolle.

Definition 5.1.3. Einen Vektor $\mathbf{v}$ mit $\|\mathbf{v}\| = 1$ nennen wir **Einheitsvektor**.

Anmerkung 5.1.4. Die Menge aller Einheitsvektoren $\{\mathbf{v} : \|\mathbf{v}\| = 1\}$ wird auch Einheitskugel genannt.

Anmerkung 5.1.5. Wir haben bisher die Vektoren $\mathbf{e}_j$ der Standardbasis als Einheitsvektoren bezeichnet. Für sie gilt $\|\mathbf{e}_j\| = 1$. Es gibt aber auch andere Einheitsvektoren, wie zum Beispiel $(1/\sqrt{2}, 1/\sqrt{2})$. Normalerweise kommt es durch die doppelte Wortbelegung nicht zur Verwechslung. Falls nötig, nennen wir $\mathbf{e}_j$ **Standard-Einheitsvektor**.

Anmerkung 5.1.6. Jeden Vektor $\mathbf{v}$ können wir zu einem Einheitsvektor in die gleiche Richtung skalieren: Der Vektor $\mathbf{w} = \mathbf{v}/\|\mathbf{v}\|$ hat Norm

$$\|\mathbf{w}\| = \|\mathbf{v}/\|\mathbf{v}\|\| = \|\mathbf{v}\|/\|\mathbf{v}\| = 1.$$

Ähnlich können wir den Abstand zwischen zwei Vektoren $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$ als die Länge des Verbindungsstücks zwischen den Punkten $\mathbf{v}$ und $\mathbf{w}$ definieren. Diese Länge beträgt $\|\mathbf{v} - \mathbf{w}\|$.

5.2 Winkel

Auch wissen wir aus der Geometrie, wie wir einen Winkel zwischen zwei Vektoren $\mathbf{v}, \mathbf{w} \in \mathbb{R}^2$ berechnen. Nehmen wir an sowohl $\mathbf{v}$ als auch $\mathbf{w}$ liegen auf dem Einheitskreis. Dann kann man sich überlegen¹, dass für den Winkel θ zwischen $\mathbf{v}$ und $\mathbf{w}$

$$\cos(\theta) = \frac{v_1 w_1 + v_2 w_2}{\|\mathbf{v}\| \|\mathbf{w}\|}$$

gelten muss. Genauso können wir im $\mathbb{R}^3$ einen Winkel θ so definieren, dass er dem Winkel zwischen $\mathbf{v}$ und $\mathbf{w}$ in der Ebene $\text{span}\{\mathbf{v}, \mathbf{w}\}$ misst. Hier gilt

$$\cos(\theta) = \frac{v_1 w_1 + v_2 w_2 + v_3 w_3}{\|\mathbf{v}\| \|\mathbf{w}\|}.$$

Im Nenner werden die Vektoren zu Einheitsvektoren normiert. Der Term im Zähler ist wichtiger für den Winkel und bekommt einen eigenen Namen.

Definition 5.2.1. Für $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$ definieren wir das (euklidische) **Skalarprodukt**^a als

$$\langle \mathbf{v}, \mathbf{w} \rangle = \sum_{i=1}^n v_i w_i = v_1 w_1 + \cdots + v_n w_n.$$

^aAuch *inneres Produkt* und im Englischen *inner product* oder *dot product*.

Anmerkung 5.2.2. Fassen wir die Vektoren $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$ als $(n \times 1)$ -Matrizen auf, können wir das Skalarprodukt auch so schreiben:

$$\langle \mathbf{v}, \mathbf{w} \rangle = \mathbf{v}^\top \mathbf{w}.$$

Die folgenden Eigenschaften des Skalarprodukts kann man direkt nachrechnen.

Theorem 5.2.3. Sei $\mathbf{u}, \mathbf{v}, \mathbf{w} \in \mathbb{R}^n$ und $c \in \mathbb{R}$. Dann gilt:

- (i) $\langle \mathbf{v}, \mathbf{w} \rangle = \langle \mathbf{w}, \mathbf{v} \rangle$. [Symmetrie]
- (ii) $\langle \mathbf{u}, \mathbf{v} + \mathbf{w} \rangle = \langle \mathbf{u}, \mathbf{v} \rangle + \langle \mathbf{u}, \mathbf{w} \rangle$. [Distributivgesetz]
- (iii) $\langle c\mathbf{v}, \mathbf{w} \rangle = c\langle \mathbf{v}, \mathbf{w} \rangle$. [Homogenität]
- (iv) $\langle \mathbf{v}, \mathbf{v} \rangle \geq 0$ und $\langle \mathbf{v}, \mathbf{v} \rangle = 0$ genau dann, wenn $\mathbf{v} = \mathbf{0}$. [Positivität]

¹Das ist nicht ganz trivial, aber nicht Thema dieser Vorlesung.




Abbildung 5.2: Drei orthogonale Vektoren im $\mathbb{R}^3$. (Fig. 5.2.1 in [LLM])

Der Winkel θ zwischen $\mathbf{v}, \mathbf{w} \neq \mathbf{0} \in \mathbb{R}^2$ ist also

$$\theta = \cos^{-1} \left(\frac{\langle \mathbf{v}, \mathbf{w} \rangle}{\|\mathbf{v}\| \|\mathbf{w}\|} \right).$$

Durch die gleiche Formel können wir nun auch in allgemeinen Vektorräumen einen Winkel *definieren*. Hauptsächlich interessiert uns aber ob die Vektoren *orthogonal* sind (= ein rechter Winkel vorliegt). Das ist der Fall, wenn $\cos(\theta) = 0$ oder, äquivalent dazu, $\langle \mathbf{v}, \mathbf{w} \rangle = 0$.

Definition 5.2.4. Vektoren $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$ sind **orthogonal**, wenn $\langle \mathbf{v}, \mathbf{w} \rangle = 0$.

Beispiel 5.2.5. Abbildung 5.2 zeigt die Vektoren

$$\mathbf{u}_1 = \begin{pmatrix} 3 \\ 1 \\ 1 \end{pmatrix}, \quad \mathbf{u}_2 = \begin{pmatrix} -1 \\ 2 \\ 1 \end{pmatrix}, \quad \mathbf{u}_3 = \begin{pmatrix} -1/2 \\ -2 \\ 7/2 \end{pmatrix}.$$

Die Vektoren stehen alle im rechten Winkel aufeinander:

$$\begin{aligned} \langle \mathbf{u}_1, \mathbf{u}_2 \rangle &= 3 \cdot (-1) + 1 \cdot 2 + 1 \cdot 1 = 0, \\ \langle \mathbf{u}_1, \mathbf{u}_3 \rangle &= 3 \cdot \frac{-1}{2} + 1 \cdot (-2) + 1 \cdot \frac{7}{2} = 0, \\ \langle \mathbf{u}_2, \mathbf{u}_3 \rangle &= (-1) \cdot \frac{-1}{2} + 2 \cdot (-2) + 1 \cdot \frac{7}{2} = 0. \end{aligned}$$

5.3 Skalarprodukt

Es ist an der Zeit, das erste Mal über allgemeine Vektorräume zu sprechen. In diesem Kontext macht [Definition 5.2.1](#) keinen Sinn. Wir wollen aber auch allgemeine Vektorräume mit einer ähnlichen geometrischen Struktur ausstatten. Wir gehen dabei ähnlich vor, wie wir auch vom $\mathbb{R}^n$ zu allgemeinen Vektorräumen V gekommen sind. Wir nehmen die wichtigsten Eigenschaften des euklidischen Skalarprodukts und nehmen sie als Axiome für ein allgemeines Skalarprodukt an.²

Definition 5.3.1. Sei V ein Vektorraum. Wir nennen $\langle \cdot, \cdot \rangle: V \times V \rightarrow \mathbb{R}$ ein **Skalarprodukt**, wenn es für alle $\mathbf{u}, \mathbf{v}, \mathbf{w} \in V$ und $c \in \mathbb{R}$ die folgenden Axiome erfüllt:

- (i) $\langle \mathbf{v}, \mathbf{w} \rangle = \langle \mathbf{w}, \mathbf{v} \rangle$. [Symmetrie]
- (ii) $\langle \mathbf{u}, \mathbf{v} + \mathbf{w} \rangle = \langle \mathbf{u}, \mathbf{v} \rangle + \langle \mathbf{u}, \mathbf{w} \rangle$. [Distributivgesetz]
- (iii) $\langle c\mathbf{v}, \mathbf{w} \rangle = c\langle \mathbf{v}, \mathbf{w} \rangle$. [Homogenität]
- (iv) $\langle \mathbf{v}, \mathbf{v} \rangle \geq 0$ und $\langle \mathbf{v}, \mathbf{v} \rangle = 0$ genau dann, wenn $\mathbf{v} = \mathbf{0}$. [Positivität]

Definition 5.3.2. Einen Vektorraum V zusammen mit einem Skalarprodukt $\langle \cdot, \cdot \rangle: V \times V \rightarrow \mathbb{R}$ nennen wir **Skalarproduktraum**.

Auch Orthogonalität können wir analog zum $\mathbb{R}^n$ definieren.

Definition 5.3.3. Vektoren $\mathbf{v}, \mathbf{w} \in V$ sind **orthogonal**, wenn $\langle \mathbf{v}, \mathbf{w} \rangle = 0$ und wir schreiben $\mathbf{v} \perp \mathbf{w}$.

Anmerkung 5.3.4. Der Nullvektor $\mathbf{0}$ ist nach dieser Definition orthogonal zu jedem Vektor $\mathbf{v}$, denn $\langle \mathbf{v}, \mathbf{0} \rangle = 0$ (wegen Homogenität).

Das euklidische Skalarprodukt hat außerdem die folgende Verbindung zur Norm: $\|\mathbf{v}\| = \sqrt{\langle \mathbf{v}, \mathbf{v} \rangle}$. In allgemeinen Vektorräumen definieren wir die Norm nun genauso.

Definition 5.3.5. Sei V ein Skalarproduktraum. Dann definieren wir die **Norm** eines Vektors $\mathbf{v} \in V$ als

$$\|\mathbf{v}\| = \sqrt{\langle \mathbf{v}, \mathbf{v} \rangle}.$$

²Über diese Axiome hinaus werden wir selten andere Eigenschaften für unsere Beweise brauchen. Wir formulieren die meisten folgenden Resultate direkt für allgemeine Vektorräume. Wie gesagt, es reicht für den Moment alles im $\mathbb{R}^n$ zu verstehen; andere Vektorräume besprechen wir später.

Das Skalarprodukt misst also nicht nur den Winkel, sondern auch die Länge von Vektoren. Wir können nun auch den Satz des Pythagoras auf allgemeine Vektorräume erweitern.

Theorem 5.3.6 (Satz des Pythagoras). Für orthogonale Vektoren $\mathbf{v}, \mathbf{w} \in V$ gilt

$$\|\mathbf{v} + \mathbf{w}\|^2 = \|\mathbf{v}\|^2 + \|\mathbf{w}\|^2.$$

Beweis. Übungsaufgabe. □

Das nächste Theorem enthält eine weitere wichtige Eigenschaft, die weniger offensichtlich ist. Auf die Beweisidee zu kommen ist nicht einfach, die einzelnen Schritte sollten aber zu folgen sein.

Theorem 5.3.7 (Cauchy-Schwarz-Ungleichung). Für $\mathbf{v}, \mathbf{w}$ in einem Skalarproduktraum V gilt

$$|\langle \mathbf{v}, \mathbf{w} \rangle| \leq \|\mathbf{v}\| \|\mathbf{w}\|.$$

Beweis. Ist $\mathbf{v} = \mathbf{0}$ oder $\mathbf{w} = \mathbf{0}$ ist die Ungleichung trivialerweise erfüllt. Seien nun $\mathbf{v}, \mathbf{w} \neq \mathbf{0}$. Für jedes $\lambda \in \mathbb{R}$ gilt nach Definition 5.3.1

$$0 \leq \langle \mathbf{v} + \lambda \mathbf{w}, \mathbf{v} + \lambda \mathbf{w} \rangle = \|\mathbf{v}\|^2 + \lambda^2 \|\mathbf{w}\|^2 + 2\lambda \langle \mathbf{v}, \mathbf{w} \rangle.$$

Lösen wir die Ungleichung nach $\lambda \langle \mathbf{v}, \mathbf{w} \rangle$ auf, erhalten wir

$$-\lambda \langle \mathbf{v}, \mathbf{w} \rangle \leq \frac{1}{2} \|\mathbf{v}\|^2 + \frac{\lambda^2}{2} \|\mathbf{w}\|^2.$$

Wir wählen $\lambda = -\langle \mathbf{v}, \mathbf{w} \rangle / \|\mathbf{w}\|^2$ und erhalten

$$\frac{\langle \mathbf{v}, \mathbf{w} \rangle^2}{\|\mathbf{w}\|^2} \leq \frac{1}{2} \|\mathbf{v}\|^2 + \frac{1}{2} \frac{\langle \mathbf{v}, \mathbf{w} \rangle^2}{\|\mathbf{w}\|^2}.$$

Multiplizieren wir beide Seiten mit $\|\mathbf{w}\|^2$ und lösen nach $\langle \mathbf{v}, \mathbf{w} \rangle$ bekommen wir wie gewünscht

$$\langle \mathbf{v}, \mathbf{w} \rangle^2 \leq \|\mathbf{v}\|^2 \|\mathbf{w}\|^2. \quad \square$$

Die Norm $\|\cdot\|$ spielt in V die gleiche Rolle wie der Betrag $|\cdot|$ in $\mathbb{R}$. Mit der Cauchy-Schwarz-Ungleichung können wir nun auch eine wichtige Eigenschaft des Betrags verallgemeinern.

Theorem 5.3.8 (Dreiecksungleichung). Für alle $\mathbf{u}, \mathbf{v}$ in einem Skalarproduktraum V gilt

$$\|\mathbf{u} + \mathbf{v}\| \leq \|\mathbf{u}\| + \|\mathbf{v}\|.$$

Beweis. Es gilt

$$\begin{aligned}
 \|\mathbf{u} + \mathbf{v}\|^2 &= \langle \mathbf{u} + \mathbf{v}, \mathbf{u} + \mathbf{v} \rangle \\
 &= \langle \mathbf{u}, \mathbf{u} \rangle + 2\langle \mathbf{u}, \mathbf{v} \rangle + \langle \mathbf{v}, \mathbf{v} \rangle \\
 &= \|\mathbf{u}\|^2 + 2\langle \mathbf{u}, \mathbf{v} \rangle + \|\mathbf{v}\|^2 \\
 &\leq \|\mathbf{u}\|^2 + 2|\langle \mathbf{u}, \mathbf{v} \rangle| + \|\mathbf{v}\|^2 \\
 &\leq \|\mathbf{u}\|^2 + 2\|\mathbf{u}\|\|\mathbf{v}\| + \|\mathbf{v}\|^2 \quad [\text{Cauchy-Schwarz}] \\
 &= (\|\mathbf{u}\| + \|\mathbf{v}\|)^2.
 \end{aligned}$$

Wir schließen den Beweis, indem wir auf beiden Seiten die Wurzel ziehen. $\square$

Anmerkung 5.3.9. Vielleicht habt ihr in der Analysis bereits von Distanzfunktionen gehört. Für $\mathbf{u}, \mathbf{v}, \mathbf{w} \in V$ erfüllt die Funktion $d(\mathbf{v}, \mathbf{w}) = \|\mathbf{v} - \mathbf{w}\|$ die Dreiecksungleichung

$$d(\mathbf{u}, \mathbf{w}) \leq d(\mathbf{u}, \mathbf{v}) + d(\mathbf{v}, \mathbf{w}),$$

denn

$$\begin{aligned}
 d(\mathbf{u}, \mathbf{w}) &= \|\mathbf{u} - \mathbf{w}\| = \|\mathbf{u} - \mathbf{v} + \mathbf{v} - \mathbf{w}\| \\
 &\leq \|\mathbf{u} - \mathbf{v}\| + \|\mathbf{v} - \mathbf{w}\| = d(\mathbf{u}, \mathbf{v}) + d(\mathbf{v}, \mathbf{w}).
 \end{aligned}$$

Zusammen mit [Theorem 5.1.2](#) sind dann auch die anderen beiden Axiome einer Distanzfunktion erfüllt:

- (i) $d(\mathbf{u}, \mathbf{v}) = d(\mathbf{v}, \mathbf{u})$.
- (ii) $d(\mathbf{u}, \mathbf{v}) = 0$ genau dann, wenn $\mathbf{u} = \mathbf{v}$.

Wir fassen nochmal kurz zusammen, was gerade passiert ist. Durch das Skalarprodukt geben wir dem Vektorraum eine geometrische Struktur. Aus dem $\mathbb{R}^2$ bekannte Konzepte wie Länge, Abstand, Winkel und Orthogonalität lassen sich damit direkt übertragen. Die Analogie zwischen der Geometrie von Vektorräumen und dem $\mathbb{R}^2$ ist damit so stark, dass viele elementare geometrische Zusammenhänge erhalten bleiben. Insbesondere gelten der Satz vom Pythagoras und die Dreiecksungleichung. Dies gibt uns eine mathematisch fundierte Rechtfertigung, uns jeden Vektorraum als $\mathbb{R}^2$ oder $\mathbb{R}^3$ vorzustellen, um Intuition zu entwickeln.³

5.4 Orthogonale Räume

Orthogonalität ist ein so wichtiges Konzept, dass es weitaus mehr Aufmerksamkeit verdient. Es wird sich als nützlich erweisen, Vektorräume in orthogonale

³Selbst die besten Mathematiker fertigen regelmäßig Skizzen im $\mathbb{R}^2$ an, wenn sie über Funktionenräume sprechen!

Unterräume aufzuteilen. Zunächst definieren wir Orthogonalität zu einem ganzen Raum.

Definition 5.4.1. Sei W ein Unterraum eines Skalarproduktraums V . Wir nennen $\mathbf{v} \in V$ **orthogonal zu W** , wenn $\langle \mathbf{v}, \mathbf{w} \rangle = 0$ für alle $\mathbf{w} \in W$, und schreiben $\mathbf{v} \perp W$.

Definition 5.4.2. Sei W ein Unterraum von V . Dann nennen wir die Menge $W^\perp = \{\mathbf{v} \in V : \mathbf{v} \perp W\}$ den **(orthogonalen) Komplementärraum** oder das **(orthogonale) Komplement** zu W .

Das Komplement $W^\perp$ enthält all jene Vektoren, die zu jedem Vektor in W orthogonal sind. Wie immer wollen wir zunächst die Teile „Raum“ und „Komplement“ im Namen rechtfertigen.

Theorem 5.4.3. Sei W ein Unterraum von V . Dann gilt:

- (i) $W^\perp$ ist ein Unterraum von V .
- (ii) $W \cap W^\perp = \{\mathbf{0}\}$.

Beweis. Übungsaufgabe. □

Beispiel 5.4.4. Sei $V = \mathbb{R}^2$ und $W = \text{span}\{\mathbf{e}_1\}$. Dann ist $W^\perp = \text{span}\{\mathbf{e}_2\}$ und damit $W \cap W^\perp = \{\mathbf{0}\}$.

Das „Komplement“ ist nur teilweise gerechtfertigt. Um dem Namen gerecht zu werden, erwarten wir auch so etwas wie $W \cup W^\perp = V$. Das kann aber nicht gelten, da Linearkombinationen aus W und $W^\perp$ nicht alle in $W \cup W^\perp$ liegen. Stattdessen definieren wir

$$W + U = \{\mathbf{w} + \mathbf{u} : \mathbf{w} \in W, \mathbf{u} \in U\}.$$

Theorem 5.4.5. Sei W ein Unterraum von V . Dann gilt $W + W^\perp = V$.

Die Mittel, um das zu beweisen, werden wir erst später entwickeln.

Anmerkung 5.4.6. Sind die Räume W und U orthogonal zueinander, also $W \perp U$, dann schreibt man statt $W + U$ auch $W \oplus U$ und spricht von der direkten Summe von W und U .

Um zu überprüfen ob $\mathbf{v} \in W^\perp$, können wir uns auf Basisvektoren von W beschränken.

Theorem 5.4.7. Sei W ein Unterraum eines Vektorraums V und $\mathcal{W} = \{\mathbf{w}_1, \dots, \mathbf{w}_k\}$ eine Basis von W . Dann gilt $\mathbf{v} \perp W$ genau dann, wenn $\mathbf{v} \perp \mathbf{w}_i$ für alle $i = 1, \dots, k$.

Beweis.

- $\Rightarrow$: Weil alle $\mathbf{w}_1, \dots, \mathbf{w}_k$ in W liegen, muss $\mathbf{v} \in W^\perp$ per Definition orthogonal zu jedem dieser Vektoren sein.
- $\Leftarrow$: Angenommen $\mathbf{v} \perp \mathbf{w}_i$ für alle $i = 1, \dots, k$. Jedes $\mathbf{w} \in W$ lässt sich schreiben als

$$\mathbf{w} = c_1 \mathbf{w}_1 + \dots + c_k \mathbf{w}_k$$

und es gilt

$$\langle \mathbf{v}, \mathbf{w} \rangle = c_1 \langle \mathbf{v}, \mathbf{w}_1 \rangle + \dots + c_k \langle \mathbf{v}, \mathbf{w}_k \rangle = 0.$$

Also ist $\mathbf{v} \perp W$. □

Man kann sich außerdem überlegen, dass

$$(W^\perp)^\perp = W.$$

Wir kommen jetzt zu einem wichtigen Beispiel für Komplemente — und damit kurz zurück zu linearen Gleichungssystemen. Sei $A \in \mathbb{R}^{m \times n}$, dann besteht die Lösungsmenge $\ker(A)$ des homogenen Systems $A\mathbf{x} = \mathbf{0}$ aus allen Vektoren, die orthogonal zu den Zeilen aus A sind. Optional können wir auch sagen, dass $\ker(A)$ orthogonal zu den Spalten in $A^\top$ sind. Damit haben wir unsere Behauptung am Ende von [Abschnitt 3.4.2](#) gezeigt.

Theorem 5.4.8. Für jede Matrix $A \in \mathbb{R}^{m \times n}$ gilt

$$\operatorname{col}(A^\top)^\perp = \ker(A) \quad \text{und} \quad \operatorname{col}(A)^\perp = \ker(A^\top).$$

5.5 Orthogonale Mengen

Definition 5.5.1.

- Wir nennen $M = \{\mathbf{v}_1, \dots, \mathbf{v}_n\} \subset V$ eine **orthogonale Menge**, wenn $\mathbf{v}_i \perp \mathbf{v}_j$ für alle $i \neq j$.
- Gilt zusätzlich $\|\mathbf{v}_j\| = 1$ für alle j , nennen wir M **orthonormal**.

Beispiel 5.5.2. Die Vektoren der Standardbasis $\mathbf{e}_1, \dots, \mathbf{e}_n$ sind orthonormal.

Beispiel 5.5.3. Die Vektoren

$$\begin{pmatrix} 1 \\ -2 \\ 0 \end{pmatrix}, \quad \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix}, \quad \begin{pmatrix} 0 \\ 0 \\ 3 \end{pmatrix}$$

sind orthogonal, aber nicht orthonormal.

Zunächst stellen wir fest, dass (nichttriviale) orthogonale Vektoren auch unabhängig sind.

Theorem 5.5.4. Eine orthogonale Menge $M = \{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ mit $\mathbf{0} \notin M$ ist linear unabhängig.

Anmerkung 5.5.5. Andersherum gilt das nicht. Zum Beispiel sind die Vektoren $(1, 1)$ und $(1, 0)$ linear unabhängig, aber nicht orthogonal, denn $\langle (1, 1), (1, 0) \rangle = 1 \neq 0$.

Beweis. Ist M orthogonal, gilt $\langle \mathbf{v}_i, \mathbf{v}_j \rangle = 0$ für alle $i \neq j$ und $\langle \mathbf{v}_i, \mathbf{v}_i \rangle = \|\mathbf{v}_i\|^2 > 0$. Angenommen M ist linear abhängig. Dann lässt sich o.B.d.A. $\mathbf{v}_n$ als Linearkombination der anderen darstellen, also

$$\mathbf{v}_n = c_1 \mathbf{v}_1 + \dots + c_{n-1} \mathbf{v}_{n-1}.$$

Da $\mathbf{v}_n \neq \mathbf{0}$ muss ein Koeffizient ungleich 0 sein. Sei zum Beispiel $c_1 \neq 0$. Dann ist

$$\langle \mathbf{v}_n, \mathbf{v}_1 \rangle = c_1 \langle \mathbf{v}_1, \mathbf{v}_1 \rangle + \dots + c_{n-1} \langle \mathbf{v}_{n-1}, \mathbf{v}_1 \rangle = c_1 \langle \mathbf{v}_1, \mathbf{v}_1 \rangle = c_1 \|\mathbf{v}_1\|^2 \neq 0,$$

da auch $\|\mathbf{v}_1\| \neq 0$. Also können $\mathbf{v}_n$ und $\mathbf{v}_1$ nicht orthogonal gewesen sein. Weil das ein Widerspruch ist, müssen $\mathbf{v}_1, \dots, \mathbf{v}_n$ linear unabhängig sein. $\square$

Angenommen wir sind in einem n -dimensionalen Vektorraum. Jede Menge von n orthogonalen Vektoren ist auch unabhängig. Mit **Theorem 3.3.20** ist die Menge dann auch eine Basis. Basen aus orthogonalen Vektoren sind besonders schön, weil sie uns oft das Leben erleichtern werden. Deshalb verdienen sie einen Namen.

Definition 5.5.6. Eine **Orthogonalbasis** eines Vektorraums V ist eine Basis von V , welche auch eine orthogonale Menge ist. Ist die Basis auch orthonormal, sprechen wir von einer **Orthonormalbasis**.

Fangen wir gleich mit der ersten Erleichterung an. Die Koordinaten bezüglich einer Orthogonalbasis lassen sich einfach durch das Skalarprodukt berechnen.

Theorem 5.5.7. Sei $\mathcal{V} = \{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ eine Orthogonalbasis für den Vektorraum V . Dann sind für jedes $\mathbf{v} \in V$ die $\mathcal{V}$ -Koordinaten, also die Koeffizienten $c_1, \dots, c_n$ in

$$\mathbf{v} = c_1 \mathbf{v}_1 + \dots + c_n \mathbf{v}_n,$$

gegeben durch

$$c_j = \frac{\langle \mathbf{v}, \mathbf{v}_j \rangle}{\langle \mathbf{v}_j, \mathbf{v}_j \rangle}, \quad j = 1, \dots, n.$$

Beweis. Wie im vorangegangenen Beweis gilt

$$\langle \mathbf{v}, \mathbf{v}_1 \rangle = c_1 \langle \mathbf{v}_1, \mathbf{v}_1 \rangle + \dots + c_n \langle \mathbf{v}_n, \mathbf{v}_1 \rangle = c_1 \langle \mathbf{v}_1, \mathbf{v}_1 \rangle.$$

Den Koeffizienten c_1 finden wir, indem wir beide Seiten durch $\langle \mathbf{v}_1, \mathbf{v}_1 \rangle \neq 0$ teilen. Das Gleiche können wir nun für alle $c_j, j = 1, \dots, n$ wiederholen. $\square$

Beispiel 5.5.8. Die Standardbasis $\{\mathbf{e}_1, \dots, \mathbf{e}_n\} \subset \mathbb{R}^n$ ist orthogonal. Dann ist

$$c_j = \frac{\langle \mathbf{v}, \mathbf{e}_j \rangle}{\langle \mathbf{e}_j, \mathbf{e}_j \rangle} = v_j$$

und entsprechend

$$\mathbf{v} = v_1 \mathbf{e}_1 + \dots + v_n \mathbf{e}_n.$$

Beispiel 5.5.9. Die Vektoren

$$\mathbf{v}_1 = \begin{pmatrix} 1 \\ -2 \\ 0 \end{pmatrix}, \quad \mathbf{v}_2 = \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix}, \quad \mathbf{v}_3 = \begin{pmatrix} 0 \\ 0 \\ 3 \end{pmatrix}$$

sind eine Orthogonalbasis des $\mathbb{R}^3$. Sei zum Beispiel

$$\mathbf{v} = \begin{pmatrix} 3 \\ 0 \\ -1 \end{pmatrix}.$$

Dann ist

$$c_1 = \frac{\langle \mathbf{v}, \mathbf{v}_1 \rangle}{\langle \mathbf{v}_1, \mathbf{v}_1 \rangle} = \frac{3}{5}, \quad c_2 = \frac{\langle \mathbf{v}, \mathbf{v}_2 \rangle}{\langle \mathbf{v}_2, \mathbf{v}_2 \rangle} = \frac{6}{5}, \quad c_3 = \frac{\langle \mathbf{v}, \mathbf{v}_3 \rangle}{\langle \mathbf{v}_3, \mathbf{v}_3 \rangle} = \frac{-3}{9} = -\frac{1}{3}.$$

Tatsächlich gilt

$$c_1 \mathbf{v}_1 + c_2 \mathbf{v}_2 + c_3 \mathbf{v}_3 = \frac{3}{5} \begin{pmatrix} 1 \\ -2 \\ 0 \end{pmatrix} + \frac{6}{5} \begin{pmatrix} 2 \\ 1 \\ 0 \end{pmatrix} - \frac{1}{3} \begin{pmatrix} 0 \\ 0 \\ 3 \end{pmatrix} = \begin{pmatrix} 3 \\ 0 \\ -1 \end{pmatrix} = \mathbf{v}.$$

Noch einfacher wirds, wenn die Basis orthonormal ist.

Korollar 5.5.10. Sei $\mathcal{V} = \{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ eine Orthonormalbasis für den Vektorraum V . Dann sind für jedes $\mathbf{v} \in V$ die $\mathcal{V}$ -Koordinaten $c_1, \dots, c_n$ gegeben durch

$$c_j = \langle \mathbf{v}, \mathbf{v}_j \rangle, \quad j = 1, \dots, n.$$

5.6 Orthogonale Matrizen

Wir können orthonormale Mengen im $\mathbb{R}^n$ auch über Matrizen charakterisieren.

Theorem 5.6.1.

- Eine Matrix $U \in \mathbb{R}^{m \times n}$ hat genau dann orthonormale Spalten, wenn $U^\top U = I_n$.
- Eine Matrix $U \in \mathbb{R}^{m \times n}$ hat genau dann orthonormale Zeilen, wenn $UU^\top = I_m$.

Beweis. Nach den Rechenregeln für die Matrixmultiplikation gilt

$$U^\top U = \begin{pmatrix} \mathbf{u}_1^\top \mathbf{u}_1 & \cdots & \mathbf{u}_1^\top \mathbf{u}_n \\ \vdots & & \vdots \\ \mathbf{u}_n^\top \mathbf{u}_1 & \cdots & \mathbf{u}_n^\top \mathbf{u}_n \end{pmatrix} = \begin{pmatrix} \langle \mathbf{u}_1, \mathbf{u}_1 \rangle & \cdots & \langle \mathbf{u}_1, \mathbf{u}_n \rangle \\ \vdots & & \vdots \\ \langle \mathbf{u}_n, \mathbf{u}_1 \rangle & \cdots & \langle \mathbf{u}_n, \mathbf{u}_n \rangle \end{pmatrix} = I_n.$$

Ähnlich können wir auch mit orthogonalen Zeilen verfahren. □

Definition 5.6.2. Eine Matrix $U \in \mathbb{R}^{n \times n}$ mit orthonormalen Spalten und Zeilen nennen wir **Orthogonalmatrix**.

Anmerkung 5.6.3. Vorsicht: Eine Matrix mit lediglich orthogonalen Spalten/Zeilen ist nicht automatisch eine Orthogonalmatrix. Die Spalten müssen orthonormal (!) sein.

Aus dem letzten Theorem folgt außerdem, dass Orthogonalmatrizen eine besonders einfache Inverse haben:

Korollar 5.6.4. $U \in \mathbb{R}^{n \times n}$ ist genau dann orthogonal, wenn U invertierbar ist mit $U^{-1} = U^\top$.

Mit Theorem 2.2.13 folgt dann außerdem das folgende überraschende Resultat.

Korollar 5.6.5. Für $U \in \mathbb{R}^{n \times n}$ sind äquivalent:

- (i) U hat orthonormale Spalten.
- (ii) U hat orthonormale Zeilen.

Orthogonalmatrizen werden später noch eine große Rolle spielen. Wir halten schon mal ein paar wichtige Eigenschaften fest.

Theorem 5.6.6. Für Orthogonalmatrizen $U, W \in \mathbb{R}^{n \times n}$ gilt:

- (i) $U^\top$ und U^{-1} sind orthogonal.
- (ii) Sind $U, W \in \mathbb{R}^{n \times n}$ orthogonal, dann ist auch UW orthogonal.
- (iii) $\det(U) = \pm 1$.
- (iv) $\|U\mathbf{x}\| = \|\mathbf{x}\|$ für alle $\mathbf{x} \in \mathbb{R}^n$.
- (v) $\langle U\mathbf{x}, U\mathbf{y} \rangle = \langle \mathbf{x}, \mathbf{y} \rangle$ für alle $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$.

Beweis. Übung. □

Eigenschaften (iv)–(v) zeigt, dass Orthogonalmatrizen Längen Winkel erhalten. Man kann sogar zeigen, dass es die einzigen Matrizen sind, die das tun.

5.7 Orthogonale Projektionen

5.7.1 Die Idee

Theorem 5.4.5 (noch unbewiesen) besagt, dass wir für jedes $\mathbf{v} \in V$ und einem Unterraum W , ein $\hat{\mathbf{v}} \in W$ und ein $\mathbf{z} \in W^\perp$ finden, sodass

$$\mathbf{v} = \hat{\mathbf{v}} + \mathbf{z}.$$

Wir haben also $\mathbf{v}$ aufgeteilt in einen Vektor des Unterraums W und einen der orthogonal auf W steht. Den Vektor $\hat{\mathbf{v}} \in W$ nennen wir dann **Projektion** von $\mathbf{v}$ auf W und $\mathbf{z} = \mathbf{v} - \hat{\mathbf{v}}$ das **Residuum**. Wir schreiben auch $\hat{\mathbf{v}} = \text{proj}_W \mathbf{v}$.

Der Vorgang ist in [Abbildung 5.3](#) illustriert. Wir haben einen Vektor $\mathbf{y}$ und einen Vektor $\mathbf{u}$. Wir wollen $\mathbf{y}$ auf den Unterraum (die Gerade) $L = \text{span}\{\mathbf{u}\}$ projizieren. Wir finden dann einen Punkt $\hat{\mathbf{y}}$ auf der Geraden L , sodass $\mathbf{z} = \mathbf{y} - \hat{\mathbf{y}}$ orthogonal auf $\mathbf{u}$ steht. Außerdem ist $\hat{\mathbf{y}}$ der Punkt in L , der am nächsten an $\mathbf{y}$




Abbildung 5.3: Orthogonale Projektion von $\mathbf{y}$ auf den Spann von $\mathbf{u}$. (Fig. 6.2.3 in [LLM])

liegt. Das ist kein Zufall, wie wir noch sehen werden. Weil $\mathbf{z} = \mathbf{y} - \hat{\mathbf{y}}$ orthogonal zu $\mathbf{u}$ ist und $\hat{\mathbf{y}} = c\mathbf{u}$ gelten muss, ist

$$0 = \langle \mathbf{u}, \mathbf{y} - \hat{\mathbf{y}} \rangle = \langle \mathbf{u}, \mathbf{y} \rangle - \langle \mathbf{u}, \hat{\mathbf{y}} \rangle = \langle \mathbf{u}, \mathbf{y} \rangle - c\langle \mathbf{u}, \mathbf{u} \rangle.$$

Also gilt

$$c = \frac{\langle \mathbf{u}, \mathbf{y} \rangle}{\langle \mathbf{u}, \mathbf{u} \rangle} \quad \text{oder} \quad \text{proj}_L \mathbf{y} = \frac{\langle \mathbf{u}, \mathbf{y} \rangle}{\langle \mathbf{u}, \mathbf{u} \rangle} \mathbf{u}.$$

5.7.2 Das Projektionstheorem

Wir werden nun diese Formel verallgemeinern und beweisen, dass so eine Zerlegung immer möglich ist. Damit wäre dann auch [Theorem 5.4.5](#) bewiesen.

Theorem 5.7.1 (Projektionstheorem). *Sei W ein endlich-dimensionaler Unterraum eines Skalarproduktraums V .*

(i) *Jedes $\mathbf{v} \in V$ kann eindeutig als*

$$\mathbf{v} = \hat{\mathbf{v}} + \mathbf{z}$$

dargestellt werden mit $\hat{\mathbf{v}} \in W$ und $\mathbf{z} \in W^\perp$.

(ii) *Für jede Orthogonalbasis $\mathcal{W} = \{\mathbf{w}_1, \dots, \mathbf{w}_k\}$ von W gilt*

$$\hat{\mathbf{v}} = \text{proj}_W \mathbf{v} = \frac{\langle \mathbf{v}, \mathbf{w}_1 \rangle}{\langle \mathbf{w}_1, \mathbf{w}_1 \rangle} \mathbf{w}_1 + \dots + \frac{\langle \mathbf{v}, \mathbf{w}_k \rangle}{\langle \mathbf{w}_k, \mathbf{w}_k \rangle} \mathbf{w}_k.$$

Beweis. Sei $\mathcal{W} = \{\mathbf{w}_1, \dots, \mathbf{w}_k\}$ eine Orthogonalbasis für W . (Dass es so eine Basis immer gibt, zeigen wir später.) Definiere

$$\hat{\mathbf{v}} = \frac{\langle \mathbf{v}, \mathbf{w}_1 \rangle}{\langle \mathbf{w}_1, \mathbf{w}_1 \rangle} \mathbf{w}_1 + \dots + \frac{\langle \mathbf{v}, \mathbf{w}_k \rangle}{\langle \mathbf{w}_k, \mathbf{w}_k \rangle} \mathbf{w}_k.$$




Abbildung 5.4: Orthogonale Projektion von $\mathbf{y}$ auf den Spann von $\mathbf{u}$. (Fig. 6.3.2 in [AR])

Der Vektor $\hat{\mathbf{v}}$ ist eine Linearkombination aus $\mathcal{W}$, also $\hat{\mathbf{v}} \in W = \text{span}(\mathcal{W})$. Für $\mathbf{z} = \mathbf{v} - \hat{\mathbf{v}}$ gilt dann

$$\begin{aligned} \langle \mathbf{z}, \mathbf{w}_1 \rangle &= \langle \mathbf{v} - \hat{\mathbf{v}}, \mathbf{w}_1 \rangle = \langle \mathbf{v}, \mathbf{w}_1 \rangle - \langle \hat{\mathbf{v}}, \mathbf{w}_1 \rangle \\ &= \langle \mathbf{v}, \mathbf{w}_1 \rangle - \frac{\langle \mathbf{v}, \mathbf{w}_1 \rangle}{\langle \mathbf{w}_1, \mathbf{w}_1 \rangle} \langle \mathbf{w}_1, \mathbf{w}_1 \rangle - 0 - \dots - 0 \\ &= \langle \mathbf{v}, \mathbf{w}_1 \rangle - \langle \mathbf{v}, \mathbf{w}_1 \rangle = 0. \end{aligned}$$

Genauso können wir $\langle \mathbf{z}, \mathbf{w}_j \rangle = 0$ für alle $j = 1, \dots, k$ zeigen. Also ist nach [Theorem 5.4.7](#) $\mathbf{z} \perp W$.

Wir zeigen noch, dass die Darstellung eindeutig ist. Seien $\hat{\mathbf{v}}' \in W, \mathbf{z}' \in W^\perp$ Vektoren, sodass $\mathbf{v} = \hat{\mathbf{v}}' + \mathbf{z}'$. Für $\mathbf{v}' = c_1 \mathbf{w}_1 + \dots + c_k \mathbf{w}_k$ gilt dann

$$\begin{aligned} \langle \mathbf{v}, \mathbf{w}_1 \rangle &= \langle \hat{\mathbf{v}}', \mathbf{w}_1 \rangle + \underbrace{\langle \mathbf{z}', \mathbf{w}_1 \rangle}_{=0} \\ &= c_1 \langle \mathbf{w}_1, \mathbf{w}_1 \rangle + \underbrace{c_2 \langle \mathbf{w}_2, \mathbf{w}_1 \rangle + \dots + c_k \langle \mathbf{w}_k, \mathbf{w}_1 \rangle}_{=0}. \end{aligned}$$

Lösen der Gleichung ergibt $c_1 = \langle \mathbf{v}, \mathbf{w}_1 \rangle / \langle \mathbf{w}_1, \mathbf{w}_1 \rangle$. Wiederhole nun das Argument für $c_j, j = 2, \dots, k$. $\square$

Anmerkung 5.7.2. Eine Einschränkung in [Theorem 5.7.1](#) ist, dass der Unterraum W endlich-dimensional ist. Man kann es auch auf unendlich-dimensionale Räume erweitern, braucht aber eine weitere, milde Einschränkung. Statt eines Skalarproduktraums, muss man sich hier auf Hilberträume⁴ beschränken. Dort ist das Resultat auch als Hilbert's Projektionstheorem bekannt.

Das Theorem ist in [Abbildung 5.4](#) illustriert. Hier wird der Punkt $\mathbf{u}$ ganz oben auf die Ebene $W = \text{span}\{\mathbf{v}_1, \mathbf{v}_2\}$ projiziert. Die Projektion $\hat{\mathbf{u}} = \text{proj}_W \mathbf{u}$ ist der

⁴Ein Hilbertraum ist ein Skalarproduktraum, in dem alle Cauchyfolgen bezüglich der durch das Skalarprodukt induzierte Norm konvergieren.

Punkt in der Fläche, sodass die Gerade durch $\hat{\mathbf{u}}$ und $\mathbf{u}$ senkrecht auf der Ebene W steht. Weil $\mathbf{v}_1$ und $\mathbf{v}_2$ orthogonal sind, ist außerdem $\text{proj}_W \mathbf{u}$ die Summe der Projektionen auf die einzelnen Unterräume $\text{span}\{\mathbf{v}_1\}$ und $\text{span}\{\mathbf{v}_2\}$.

$$\text{proj}_W \mathbf{u} = \text{proj}_{\mathbf{v}_1} \mathbf{u} + \text{proj}_{\mathbf{v}_2} \mathbf{u} = \frac{\langle \mathbf{u}, \mathbf{v}_1 \rangle}{\langle \mathbf{v}_1, \mathbf{v}_1 \rangle} \mathbf{v}_1 + \frac{\langle \mathbf{u}, \mathbf{v}_2 \rangle}{\langle \mathbf{v}_2, \mathbf{v}_2 \rangle} \mathbf{v}_2.$$

Projektionen sind lineare Operationen. In Euklidischen Räumen lassen sie sich also als Matrix-Vektor-Multiplikation darstellen.

Theorem 5.7.3. Ist $U \in \mathbb{R}^{n \times k}$ eine Matrix, dessen Spalten eine Orthogonalbasis für einen Unterraum $W \subset \mathbb{R}^n$ ist, dann gilt

$$\text{proj}_W \mathbf{v} = U(U^\top U)^{-1} U^\top \mathbf{v}.$$

Beweis. Übungsaufgabe. □

5.7.3 Das Gram-Schmidt-Verfahren

Wir können jetzt auch zeigen, dass jeder Vektorraum eine Orthogonalbasis besitzt. Wir starten dabei bei einer beliebigen Basis $\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ und verwandeln sie in eine Basis $\{\mathbf{u}_1, \dots, \mathbf{u}_n\}$ aus orthogonalen Vektoren.

Gram-Schmidt-Verfahren

1. $\mathbf{u}_1 = \mathbf{v}_1.$
2. $\mathbf{u}_2 = \mathbf{v}_2 - \text{proj}_{\text{span}\{\mathbf{u}_1\}} \mathbf{v}_2.$
3. $\mathbf{u}_3 = \mathbf{v}_3 - \text{proj}_{\text{span}\{\mathbf{u}_1, \mathbf{u}_2\}} \mathbf{v}_3.$
- ...
- $n.$ $\mathbf{u}_n = \mathbf{v}_n - \text{proj}_{\text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_{n-1}\}} \mathbf{v}_n.$

Theorem 5.7.4. Sei $S = \{\mathbf{v}_1, \dots, \mathbf{v}_n\} \subset V$. Dann ist für jedes $k = 1, \dots, n$, die durch das Gram-Schmidt-Verfahren erzeugte Menge $\{\mathbf{u}_1, \dots, \mathbf{u}_k\}$ orthogonal und

$$\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_k\}.$$

Beweis (optional). Wir zeigen das Resultat durch Induktion über k . Da $\mathbf{u}_1 = \mathbf{v}_1$, ist die Aussage offensichtlich wahr für $k = 1$. Nehmen wir nun an, dass

$\{\mathbf{u}_1, \dots, \mathbf{u}_k\}$ orthogonal ist und definieren wir der Einfachheit halber $U_k = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_k\}$. Da

$$\mathbf{u}_{k+1} = \mathbf{v}_{k+1} - \text{proj}_{U_k} \mathbf{v}_{k+1}$$

das Residuum der Projektion auf U_k ist, ist es nach [Theorem 5.7.1](#) orthogonal zu U_k . Nehmen wir zusätzlich an, dass

$$\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_k\}.$$

Dann gilt per Definition auch

$$\mathbf{v}_{k+1} = \mathbf{u}_{k+1} + \text{proj}_{U_k} \mathbf{v}_{k+1}$$

und weil $\text{proj}_{U_k} \mathbf{v}_{k+1} \in U_k$, gilt dann auch

$$\mathbf{v}_{k+1} \in \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_{k+1}\}.$$

Daraus folgt $\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_{k+1}\} \subseteq \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_{k+1}\}$. Außerdem ist

$$\mathbf{u}_{k+1} = \mathbf{v}_{k+1} + \text{proj}_{\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}} \mathbf{v}_{k+1} \in \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_{k+1}\}$$

und darum auch $\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_{k+1}\} \supseteq \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_{k+1}\}$. $\square$

Korollar 5.7.5. *Ist $\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ eine Basis für V , dann ist die durch das Gram-Schmidt-Verfahren erzeugte Menge $\{\mathbf{u}_1, \dots, \mathbf{u}_k\}$ eine Orthogonalbasis für V .*

Anmerkung 5.7.6. *Genauso kann man auch eine Orthonormalbasis $\{\mathbf{w}_1, \dots, \mathbf{w}_n\}$ erzeugen, in dem man die Vektoren der Orthogonalbasis standardisiert: $\mathbf{w}_j = \mathbf{u}_j / \|\mathbf{u}_j\|$.*

Das Gram-Schmidt-Verfahren ersetzt die ursprünglichen Basisvektoren mit einem Projektionsresiduum. Dabei wird immer auf den Raum projiziert, der bereits durch die vorher generierten Vektoren $\mathbf{u}_1, \dots, \mathbf{u}_k$ erzeugt wird. Per Konstruktion sind die Vektoren dann orthogonal zueinander. Weil es sich damit auch um n linear unabhängige Vektoren handelt, müssen sie eine Basis sein ([Theorem 3.3.20](#)). Wir haben damit das folgende bewiesen.

Theorem 5.7.7. *Jeder endlich-dimensionale Skalarproduktraum hat eine Orthogonalbasis.*

5.7.4 Projektion als beste Annäherung

Zuletzt wollen wir noch eine andere intuitive Eigenschaft formalisieren. Die Projektion von $\mathbf{v}$ auf W ist der Punkt in W , der am nächsten an $\mathbf{v}$ liegt. Der Abstand zum Vektor $\mathbf{v}$ wird also minimiert.

Theorem 5.7.8. Sei W ein Unterraum von V und $\mathbf{v} \in V$. Dann ist $\text{proj}_W \mathbf{v}$ die **beste Annäherung** zu $\mathbf{v}$ in W :

$$\|\mathbf{v} - \text{proj}_W \mathbf{v}\| < \|\mathbf{v} - \mathbf{w}\| \quad \text{für alle } \mathbf{w} \in W, \mathbf{w} \neq \text{proj}_W \mathbf{v}.$$

Beweis. Für jedes $\mathbf{w} \in W$ gilt

$$\mathbf{v} - \mathbf{w} = (\mathbf{v} - \text{proj}_W \mathbf{v}) + (\text{proj}_W \mathbf{v} - \mathbf{w}).$$

Weil $\mathbf{v} - \text{proj}_W \mathbf{v}$ per Konstruktion orthogonal zu W ist, ist $\mathbf{v} - \text{proj}_W \mathbf{v} \in W^\perp$. Weil außerdem $\text{proj}_W \mathbf{v} \in W$ und $\mathbf{w} \in W$, ist $\text{proj}_W \mathbf{v} - \mathbf{w} \in W$. Insbesondere gilt $(\mathbf{v} - \text{proj}_W \mathbf{v}) \perp (\text{proj}_W \mathbf{v} - \mathbf{w})$ und dann mit dem Satz des Pythagoras

$$\|\mathbf{v} - \mathbf{w}\|^2 = \|\mathbf{v} - \text{proj}_W \mathbf{v}\|^2 + \|\text{proj}_W \mathbf{v} - \mathbf{w}\|^2.$$

Für $\mathbf{w} \neq \text{proj}_W \mathbf{v}$ gilt $\|\text{proj}_W \mathbf{v} - \mathbf{w}\|^2 > 0$. Also ist

$$\|\mathbf{v} - \mathbf{w}\|^2 > \|\mathbf{v} - \text{proj}_W \mathbf{v}\|^2,$$

wie behauptet. □

5.8 Die Methode der kleinsten Quadrate

5.8.1 Das Problem

Erinnern wir uns an die linearen Modelle aus [Abschnitt 2.3.2](#). Hier hatten wir Daten $(y_1, \mathbf{x}_1), \dots, (y_n, \mathbf{x}_n) \in \mathbb{R}^{1+p}$ gegeben, die für ein unbekanntes $\boldsymbol{\beta} \in \mathbb{R}^p$ dem Modell

$$y_i = \mathbf{x}_i^\top \boldsymbol{\beta}$$

folgen. Schreiben wir nun alle Gleichungen zusammen als das LGS

$$X\boldsymbol{\beta} = \mathbf{y} \quad \text{mit} \quad X = \begin{pmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{pmatrix}.$$

Jetzt können wir den passenden Parametervektor $\boldsymbol{\beta}$ finden, in dem wir das LGS lösen. Solche Daten sind nicht besonders realistisch, weshalb wir in der Statistik Zufallsfehler ϵ_i zulassen:

$$y_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \epsilon_i.$$

Das LGS $X\boldsymbol{\beta} = \mathbf{y}$ hat dann in der Regel keine Lösung.

Stattdessen wollen wir nun den Parameter $\boldsymbol{\beta}$ finden, der *am besten* die Daten beschreibt: der Abstand zwischen $X\boldsymbol{\beta}$ und $\mathbf{y}$ soll möglichst klein sein. Den Abstand

zweier Vektoren messen wir durch die Norm deren Differenz, hier also $\|X\beta - \mathbf{y}\|$. Je kleiner dieser Abstand, desto besser approximiert $X\beta$ die Beobachtungen $\mathbf{y}$. Wir wollen also den Vektor β finden, der diese Norm minimiert. Haben wir dieses β gefunden, können wir die Variable y_i durch $\mathbf{x}_i^\top \beta$ vorhersagen.

Bevor wir uns an die Lösung machen, formulieren wir zunächst das Problem in unserer üblichen Notation:

Kleinste-Quadrate-Problem. Gegeben einem LGS $A\mathbf{x} = \mathbf{b}$ mit $A \in \mathbb{R}^{m \times n}$ und $\mathbf{b} \in \mathbb{R}^m$, wollen wir einen Vektor $\hat{\mathbf{x}} \in \mathbb{R}^n$ finden, sodass $\|A\hat{\mathbf{x}} - \mathbf{b}\|$ minimal ist.

Anmerkung 5.8.1. Hat das LGS eine Lösung $\mathbf{x}^*$, dann gilt natürlich $\|A\mathbf{x}^* - \mathbf{b}\| = 0$ und $\mathbf{x}^*$ ist automatisch auch eine Lösung des Kleinste-Quadrate-Problems. Interessant ist die Problemstellung insbesondere für LGS die keine Lösung besitzen.

Anmerkung 5.8.2. Den Abstand $\|A\mathbf{x} - \mathbf{b}\|$ zu minimieren ist äquivalent dazu, $\|A\mathbf{x} - \mathbf{b}\|^2 = \epsilon_1^2 + \dots + \epsilon_n^2$ zu minimieren, wobei

$$\boldsymbol{\epsilon} = \begin{pmatrix} \epsilon_1 \\ \vdots \\ \epsilon_n \end{pmatrix} := A\mathbf{x} - \mathbf{b}$$

der Fehlervektor ist. Wir finden also das $\mathbf{x}$, dass die Summe der quadrierten Fehler ϵ_i^2 minimiert. Das erklärt auch den Namen „kleinste Quadrate“.

5.8.2 Die Lösung

Zunächst ein paar Bemerkungen. Der Vektor $\mathbf{b}$ liegt irgendwo im $\mathbb{R}^m$. Egal welches $\mathbf{x}$ wir wählen, kann $A\mathbf{x}$ allerdings nur in $\text{col}(A)$ liegen. Wir suchen also ein Element $\hat{\mathbf{b}} = A\hat{\mathbf{x}} \in \text{col}(A)$, das den Abstand zu $\mathbf{b}$ minimiert. Laut [Theorem 5.7.8](#) ist dieses $\hat{\mathbf{b}}$ eindeutig durch die Projektion von $\mathbf{b}$ auf $\text{col}(A)$ gegeben. Wir halten fest:

Theorem 5.8.3. Die Lösungsmenge des Kleinste-Quadrate-Problems ist gleich der Lösungsmenge des LGS

$$A\hat{\mathbf{x}} = \hat{\mathbf{b}}, \quad \text{mit } \hat{\mathbf{b}} = \text{proj}_{\text{col}(A)} \mathbf{b}.$$

Da $\hat{\mathbf{b}} \in \text{col}(A)$ ist, hat das LGS $A\hat{\mathbf{x}} = \hat{\mathbf{b}}$ immer eine Lösung. Aber Obacht: Obwohl $\hat{\mathbf{b}}$ eindeutig ist, muss $\hat{\mathbf{x}}$ nicht eindeutig sein. Nichtsdestotrotz haben wir jetzt ein Lösungsverfahren für das Kleinste-Quadrate-Problem gefunden:

1. Projiziere $\mathbf{b}$ auf $\text{col}(A)$: $\hat{\mathbf{b}} = \text{proj}_{\text{col}(A)} \mathbf{b}$.

2. Löse das LGS $A\hat{\mathbf{x}} = \hat{\mathbf{b}}$.

Die Projektion können wir uns auch sparen, indem wir das Problem umschreiben.

Theorem 5.8.4. Die Menge aller Lösungen des Kleinsten-Quadrate-Problems ist gleich der Menge aller Lösungen der **Normalengleichungen**

$$A^\top A\hat{\mathbf{x}} = A^\top \mathbf{b}.$$

Beweis. Es gilt

$$\begin{aligned} & \text{Lösungsmenge der Normalengleichungen} \\ &= \{\mathbf{x} : A^\top A\mathbf{x} = A^\top \mathbf{b}\} \\ &= \{\mathbf{x} : A^\top (A\mathbf{x} - \mathbf{b}) = \mathbf{0}\} && \text{(subtrahiere } A^\top \mathbf{b}) \\ &= \{\mathbf{x} : A\mathbf{x} - \mathbf{b} \in \ker(A^\top)\} && \text{(Definition } \ker(A^\top)) \\ &= \{\mathbf{x} : A\mathbf{x} - \mathbf{b} \in \text{col}(A)^\perp\} && \text{(Theorem 5.4.8)} \\ &= \{\mathbf{x} : A\mathbf{x} = \text{proj}_{\text{col}(A)} \mathbf{b}\} && \text{(Theorem 5.7.1)} \\ &= \text{Lösungsmenge des KQ-Problems.} && \text{(Theorem 5.8.3)} \end{aligned}$$

Der vorletzte Schritt benötigt etwas mehr Erklärung. Beachte dass die Gleichung $\mathbf{b} = A\mathbf{x} - (A\mathbf{x} - \mathbf{b})$ immer trivialerweise erfüllt ist. Wissen wir zusätzlich, dass $-(A\mathbf{x} - \mathbf{b}) \in \text{col}(A)^\perp$, dann muss wegen der Eindeutigkeit der Zerlegung in [Theorem 5.7.1](#) auch $A\mathbf{x} = \text{proj}_{\text{col}(A)} \mathbf{b}$ gelten. Andersherum folgt aus $A\mathbf{x} = \text{proj}_{\text{col}(A)} \mathbf{b}$, bereits $-(A\mathbf{x} - \mathbf{b}) \in \text{col}(A)^\perp$. $\square$

Ist die Matrix $A^\top A$ invertierbar haben die Normalengleichungen die *eindeutige* Lösung $\hat{\mathbf{x}} = (A^\top A)^{-1} A^\top \mathbf{b}$. Dies ist genau dann der Fall, wenn die Spalten von A unabhängig sind.

Theorem 5.8.5. Die folgenden Aussagen sind äquivalent:

- (i) Die Spalten von A sind linear unabhängig.
- (ii) $A^\top A$ ist invertierbar.
- (iii) Das Kleinste Quadrate-Problem hat die eindeutige Lösung

$$\hat{\mathbf{x}} = (A^\top A)^{-1} A^\top \mathbf{b}.$$

Beweis.

- (i) $\Leftrightarrow$ (ii): Wir bemerken zunächst, dass

$$\{\mathbf{x} : A^\top A\mathbf{x} = \mathbf{0}\} = \{\mathbf{x} : A\mathbf{x} \in \text{col}(A), A\mathbf{x} \in \ker(A^\top)\} = \{\mathbf{x} : A\mathbf{x} = \mathbf{0}\},$$




Abbildung 5.5: Datenpunkte, die um die Regressionsgerade $y = a + bx$ fluktuieren. (Fig. 6.5.2 in [AR])

da $\text{col}(A) \cap \ker(A^\top) = \text{col}(A) \cap \text{col}(A)^\perp = \mathbf{0}$ nach [Theorem 5.4.8](#) und [Theorem 5.4.3](#). Nun gilt aber

$$\begin{aligned} (ii) &\Leftrightarrow \{\mathbf{x}: A^\top A \mathbf{x} = \mathbf{0}\} = \{\mathbf{0}\} && \text{(Theorem 4.3.1a)} \\ &\Leftrightarrow \{\mathbf{x}: A \mathbf{x} = \mathbf{0}\} = \{\mathbf{0}\} \\ &\Leftrightarrow (i). && \text{(Definition von Unabhängigkeit)} \end{aligned}$$

- $(ii) \Leftrightarrow (iii)$: Folgt aus [Theorem 5.8.4](#) und unseren Äquivalenzen (zuletzt [Theorem 4.3.1](#)). $\square$

Die Formel

$$\hat{\mathbf{x}} = (A^\top A)^{-1} A^\top \mathbf{b}$$

ist vorrangig in theoretischen Herleitungen nützlich. Numerisch ist sie nämlich verhältnismäßig aufwändig und instabil. Wir werden noch bessere Möglichkeiten dafür kennenlernen.

5.8.3 Anwendung in der Statistik: (nicht-)lineare Regression

Wir kehren jetzt zu den linearen Modellen aus der Statistik zurück. Ihr werdet das folgende noch in aller Ausführlichkeit im 4. Semester besprechen, aber ich möchte ich euch schonmal einen Vorgeschmack geben.

Seien X und Y zwei Zufallsvariablen und $(x_1, y_1), \dots, (x_n, y_n)$ beobachtete Werte von ihnen. Wir möchten auf Basis von der Variable X eine Vorhersage für den Wert von Y treffen. Zum Beispiel könnten X die Außentemperatur an einem bestimmten Tag und Y die Verkäufe eines Eisstands im Englischen Garten sein. Ein Datenpunkt (x_i, y_i) ist dann ein beobachtetes Temperatur-Verkauf-Paar für den Tag i . Wir nehmen an, dass ein linearer Zusammenhang besteht. Das heißt: Es gibt $a, b \in \mathbb{R}$, sodass

$$Y = a + bX + D$$

wobei D eine weitere Zufallsvariable ist, die Abweichungen vom linearen Zusam-




Abbildung 5.6: Datenpunkte, die um die Regressionskurven $y = a + b_1x + b_2x^2$ (links) und $y = a + b_1x + b_2x^2 + b_3x^3$ fluktuieren. (Fig. 6.5.1 in [AR])

menhang auffängt. In der Statistik nennen wir das eine *lineare Regression* von Y auf X . Für die Daten heißt das dann

$$y_i = a + bx_i + d_i, \quad i = 1, \dots, n.$$

Die Situation ist beispielhaft in [Abbildung 5.5](#) dargestellt.

Wir wollen nun Parameterwerte $\hat{a}, \hat{b}$ finden, die die Daten am besten beschreiben. Genauer gesagt, wollen wir damit die Gerade $y = \hat{a} + \hat{b}x$ bestimmen, die die Summe der Quadrate der *Residuen*

$$\hat{d}_i = y_i - \hat{a} - \hat{b}x_i$$

minimiert. Schreiben wir

$$M = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix},$$

ist $(\hat{a}, \hat{b})$ dann die Lösung des Kleinsten-Quadrate-Problems von

$$M \begin{pmatrix} a \\ b \end{pmatrix} = \mathbf{y},$$

spricht:

$$\begin{pmatrix} \hat{a} \\ \hat{b} \end{pmatrix} = (M^\top M)^{-1} M^\top \mathbf{y}.$$

Auch wenn ein linearer Zusammenhang zwischen Y und X zu simpel ist, kann die lineare Algebra Abhilfe verschaffen. Wir folgen dabei einer ähnlichen Idee, wie bei der Funktionsinterpolation (sh. [Abschnitt 2.3.1](#)). In [Abbildung 5.6](#) sehen wir Situationen, wo die Daten um eine quadratische oder kubische Kurve

fluktuieren. In letzterem Fall nehmen wir zum Beispiel an, dass der nicht-lineare Zusammenhang

$$Y = a + b_1X + b_2X^2 + b_3X^3 + D$$

besteht. Die optimalen Parameter finden wir durch

$$\begin{pmatrix} \hat{a} \\ \hat{b}_1 \\ \hat{b}_2 \\ \hat{b}_3 \end{pmatrix} = (M^\top M)^{-1} M^\top \mathbf{y},$$

wobei diesmal

$$M = \begin{pmatrix} 1 & x_1 & x_1^2 & x_1^3 \\ 1 & x_2 & x_2^2 & x_2^3 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 & x_n^3 \end{pmatrix}.$$

Um für den nächsten Tag richtig zu kalkulieren, kann der Eisverkäufer jetzt den Wetterbericht verfolgen und dann aufgrund der vermuteten Temperatur x ein wahrscheinliches Verkaufsvolumen $y = \hat{a} + \hat{b}_1x + \hat{b}_2x^2 + \hat{b}_3x^3$ berechnen. Wie ihr seht, stehen ausgebildeten Statistikern beruflich wirklich alle Möglichkeiten offen.

5.8.4 Historische Anmerkung

Die Geschichte des Problems und deren Lösung ist bemerkenswert. Um 1800 versuchten weltweit die besten Mathematiker (damals auch alles Astronomen) Umlaufbahnen von Planeten anhand von Himmelsbeobachtungen zu bestimmen. Im Alter von nur 24 Jahren entwickelte Carl Friedrich Gauß dazu die neue „Methode der kleinsten Quadrate“. Damit konnte er die Umlaufbahn des Zwergplaneten Ceres so genau vorhersagen, dass der Planet danach regelmäßig wiedergefunden werden konnte.

Das war in vielerlei Hinsicht ein Durchbruch. In der Astronomie ist die Methode bis heute das Standardverfahren für Umlaufberechnung und vieles darüber hinaus. Auch für die Mathematik war das ein riesiger Schub. Gauß entwickelte nämlich in diesem Kontext auch das bereits bekannte Gauß'sche Eliminationsverfahren zur Lösung eines LGS, die LR-Zerlegung zur effizienteren Berechnung und den Gauß-Newton-Algorithmus zum Lösen von nicht-linearen Gleichungen (nächstes Semester).

Als wäre das nicht genug, entstanden daraus auch wichtige Grundlagen der modernen Statistik. Gauß modellierte die Fehler nämlich explizit probabilistisch durch die (deswegen oft nach ihm benannte und bis dahin kaum bekannte) Normalverteilung und leitete die Methode als optimale Lösung dafür her. Das rief Pierre-Simon Laplace auf den Plan, der bereits seit einigen Jahren am gleichen Problem arbeitete. Er bewies daraufhin den ersten allgemeinen Zentralen Grenz-

wertsatz, um damit die Methode der kleinsten Quadrate zu rechtfertigen.

Das alles passierte in einer Spanne von nur 10 Jahren. Doch bis heute sind die erwähnten Errungenschaften fundamentale Bestandteile der modernen Linearen Algebra, Optimierung, Statistik und Wahrscheinlichkeitstheorie.

5.9 Andere Skalarprodukträume

Aus gutem Grund haben wir die Resultate in [Abschnitt 5.3–5.7](#) für allgemeine Skalarprodukträume formuliert. Sie haben zahlreiche nützliche Anwendungen außerhalb der euklidischen Welt. Wir wollen zum Abschluss nun ein paar andere Skalarprodukträume besprechen und dabei insbesondere die Beispiele aus [Abschnitt 3.1](#) wieder aufgreifen. Wir steigern uns dabei in der Komplexität der Beispiele. Es ist in Ordnung, wenn damit auch der Grad der Verwirrung steigt. Aber auch mit Verwirrtheit ist es nützlich, diese Beispiele mal gesehen zu haben.

5.9.1 Gewichtetes euklidisches Skalarprodukt

Zunächst bleiben wir kurz im $\mathbb{R}^n$. Das euklidische Skalarprodukt

$$\langle \mathbf{u}, \mathbf{v} \rangle = \sum_{i=1}^n u_i v_i = u_1 v_1 + \cdots + u_n v_n$$

ist nicht die einzig sinnvolle Variante ein Skalarprodukt auf $\mathbb{R}^n$ zu definieren (im Sinne von [Definition 5.3.1](#)). Oft ist es nützlich, die einzelnen Komponenten eines Vektors zu gewichten. Das ist insbesondere der Fall, wenn die einzelnen Komponenten der Vektoren auf anderen Skalen leben.

Als Beispiel können wir Vektoren $\mathbf{u}, \mathbf{v} \in \mathbb{R}^2$ betrachten, bei denen die erste Komponente ein Zeitintervall in Sekunden und die zweite Komponente eine Strecke in Meter beschreibt. Die Distanz zwischen zwei Vektoren $\mathbf{u}, \mathbf{v}$, ist dann

$$\|\mathbf{u} - \mathbf{v}\|^2 = \langle \mathbf{u} - \mathbf{v}, \mathbf{u} - \mathbf{v} \rangle = (u_1 - v_1)^2 + (u_2 - v_2)^2.$$

Je nach Anwendung sind Sekunden und Meter aber vielleicht keine sinnvollen Einheiten. Definieren wir nun $\tilde{\mathbf{u}}, \tilde{\mathbf{v}}$ als die gleichen Vektoren, nur dass die erste Komponente in Zentimetern gegeben ist, also

$$\begin{pmatrix} \tilde{u}_1 \\ \tilde{u}_2 \end{pmatrix} = \begin{pmatrix} 100u_1 \\ u_2 \end{pmatrix}, \quad \begin{pmatrix} \tilde{v}_1 \\ \tilde{v}_2 \end{pmatrix} = \begin{pmatrix} 100v_1 \\ v_2 \end{pmatrix}.$$

Dann wird plötzlich die erste Komponente viel höher gewichtet, denn

$$\begin{aligned} \|\tilde{\mathbf{u}} - \tilde{\mathbf{v}}\|^2 &= \langle \tilde{\mathbf{u}} - \tilde{\mathbf{v}}, \tilde{\mathbf{u}} - \tilde{\mathbf{v}} \rangle \\ &= (\tilde{u}_1 - \tilde{v}_1)^2 + (\tilde{u}_2 - \tilde{v}_2)^2 \\ &= 10000(u_1 - v_1)^2 + (u_2 - v_2)^2. \end{aligned}$$

Anstatt die Einheiten der Vektoren zu ändern, können wir hier aber genauso das Skalarprodukt als

$$\langle \mathbf{u}, \mathbf{v} \rangle := 10000u_1v_1 + u_2v_2$$

definieren. In geometrischer Hinsicht (Länge, Winkel, Orthogonalität, Projektion) sind die beiden Varianten äquivalent. Oft ist die zweite Variante — Änderung des Skalarprodukts — aber bequemer.

Definition 5.9.1. Für $\mathbf{u}, \mathbf{v}, \mathbf{w} \in \mathbb{R}^n$ mit $w_i > 0, 1 \leq i \leq n$, definieren wir das durch $\mathbf{w} = (w_1, \dots, w_n)$ **gewichtete euklidische Skalarprodukt** als

$$\langle \mathbf{u}, \mathbf{v} \rangle_{\mathbf{w}} = w_1(u_1v_1) + \dots + w_n(u_nv_n).$$

Das gewichtete Skalarprodukt ist in der Statistik zum Beispiel sinnvoll, wenn die erhobenen Daten $x_1, \dots, x_n$ nicht repräsentativ für die Population sind, sondern x_j eigentlich w_j mal so häufig auftreten sollte.

Man kann leicht verifizieren, dass das gewichtete Skalarprodukt die Axiome von Definition 5.3.1 erfüllt. Wir müssen aber beachten, dass sich die Geometrie des Raumes (Längen, Winkel) ändert, wenn wir das Skalarprodukt wechseln.

Beispiel 5.9.2. Die Vektoren

$$\begin{pmatrix} 1 \\ -1 \end{pmatrix} \quad \text{und} \quad \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

sind orthogonal unter dem üblichen euklidischen Skalarprodukt, aber nicht unter dem durch $\mathbf{w} = (1, 2)$ gewichteten Skalarprodukt. In letzterem wären zum Beispiel

$$\begin{pmatrix} 2 \\ -1 \end{pmatrix} \quad \text{und} \quad \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

orthogonal. Außerdem sind die Vektoren

$$\begin{pmatrix} 1 \\ 0 \end{pmatrix} \quad \text{und} \quad \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

nicht mehr gleich lang. Nur der erste ist ein Einheitsvektor.

5.9.2 Matrixräume

Wir betrachten nun den Vektorraum aller $(m \times n)$ -Matrizen, $\mathbb{R}^{m \times n}$ (für fixes m und n). Das gängigste Skalarprodukt entsteht hier, indem wir die Matrizen als einen langen euklidischen Vektor in $\mathbb{R}^{mn}$ auffassen und dann das euklidische Skalarprodukt anwenden.

Definition 5.9.3. Das **Standardskalarprodukt** auf dem Vektorraum $\mathbb{R}^{m \times n}$ ist gegeben durch.

$$\langle A, B \rangle = \sum_{i=1}^m \sum_{j=1}^n a_{ij} b_{ij}.$$

Anmerkung 5.9.4. Das Standardskalarprodukt wird oft anders dargestellt. Sei dazu die **Spur** (englisch: **trace**) einer quadratischen Matrix $C \in \mathbb{R}^{n \times n}$ definiert als $\text{tr}(C) = \sum_{i=1}^n c_{ii}$. Dann ist $\langle A, B \rangle = \text{tr}(A^\top B)$.

Die dadurch induzierte Norm

$$\|A\| = \sqrt{\langle A, A \rangle} = \sqrt{\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2}.$$

Wird auch *Frobeniusnorm*^{5,6} bezeichnet und als $\|A\|_F$ geschrieben.

Beispiel 5.9.5. Unter dem Standardskalarprodukt sind die Matrizen

$$\frac{1}{\sqrt{3}} \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix} \quad \text{und} \quad \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}$$

orthogonal zueinander. Beide haben Norm 1.

Eine Anwendung findet dieses Skalarprodukt zum Beispiel in der Physik. Dort gibt es viele theoretische Modelle, die durch spezielle Matrixtransformationen charakterisiert werden. Oft gibt es theoretische Gründe zu glauben, dass die Matrizen eine bestimmte Struktur besitzen. Nehmen wir zum Beispiel an, dass die Matrizen eigentlich nur Rotationsmatrizen sein können. Im $\mathbb{R}^{2 \times 2}$ lassen sich alle Rotationsmatrizen darstellen als

$$\begin{pmatrix} a & -b \\ b & a \end{pmatrix}, \quad \text{mit } a, b \in \mathbb{R}. \quad (*)$$

Matrizen dieser Form bilden einen zwei-dimensionalen Unterraum von $\mathbb{R}^{2 \times 2}$, nämlich $R = \text{span}\{M_1, M_2\}$ mit

$$M_1 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad M_2 = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}.$$

In Experimenten versucht man dann solche Matrizen zu „messen“. Messfehler sind dabei eigentlich unvermeidbar, z.B. aufgrund schwankender Messbedingungen oder technischen Limitationen der Instrumente. Eine gemessene Matrix A wird

⁵In der Analysis wird die Norm oft auch als *Hilbert-Schmidt-Norm* bezeichnet.

⁶Andere Matrixnormen lernen wir noch gegen Ende des Semester kennen.

dann die Struktur $(*)$ nicht mehr exakt erfüllen. Stattdessen können wir A mit einer Matrix $\hat{A} \in R$ approximieren. Wählen wir $\hat{A} = \text{proj}_R A$, minimieren wir dabei nach [Theorem 5.7.8](#) den Approximationsfehler $\|\hat{A} - A\|_F$.

Ist zum Beispiel

$$A = \begin{pmatrix} 1 & -0.5 \\ 0.4 & 1.1 \end{pmatrix},$$

erhalten wir

$$\hat{A} = \text{proj}_R A = \frac{\langle A, M_1 \rangle}{\langle M_1, M_1 \rangle} M_1 + \frac{\langle A, M_2 \rangle}{\langle M_2, M_2 \rangle} M_2 = \frac{2.1}{2} M_1 + \frac{0.9}{2} M_2 = \begin{pmatrix} 1.05 & -0.45 \\ 0.45 & 1.05 \end{pmatrix}.$$

Hierbei haben wir [Theorem 5.7.1](#) und die Tatsache, dass $\{M_1, M_2\}$ eine Orthonormalbasis für R ist, verwendet. Das ist eine echte Rotationsmatrix und möglichst nah dran an unserer fehlerhaften Messung A .

5.9.3 Folgenräume

Wir gehen jetzt zu unendlich-dimensionalen Vektorräumen über. Wir bezeichnen mit ℓ_2 den Raum aller Folgen mit quadratisch summierbaren Folgengliedern:

$$\ell_2 = \left\{ \mathbf{x} = (x_i)_{i=1}^\infty : \sum_{i=1}^n x_i^2 < \infty \right\}.$$

Das ist ein Unterraum des Raums aller Folgen aus [Beispiel 3.1.3](#). In Anwendungen entsteht er oft als Grenzfall des $\mathbb{R}^n$, wenn wir die Dimension n gegen unendlich gehen lassen. So eine Betrachtung ist in der Statistik zum Beispiel nützlich, wenn wir Modelle mit sehr vielen Parametern haben (z.B. große neuronale Netze).

Am naheliegendsten ist das folgende Skalarprodukt:

Definition 5.9.6. Das **Standardskalarprodukt** auf dem Vektorraum ℓ_2 ist gegeben durch

$$\langle \mathbf{x}, \mathbf{y} \rangle = \sum_{i=1}^{\infty} x_i y_i.$$

Die dadurch induzierte Norm ist

$$\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle} = \sqrt{\sum_{i=1}^{\infty} x_i^2}.$$

Beispiel 5.9.7. Sei $\mathbf{e}_j \in \ell_2$ die Folge die überall 0 ist außer einer 1 an der j -ten Stelle. Dann sind die Vektoren $\mathbf{e}_1, \mathbf{e}_2, \dots$ eine Orthonormalbasis von ℓ_2 .

Indem wir uns auf Folgen mit $\sum_{i=1}^n x_i^2 < \infty$ beschränken, stellen wir also sicher, dass sowohl $\|\mathbf{x}\| < \infty$ als auch $|\langle \mathbf{x}, \mathbf{y} \rangle| < \infty$ für alle $\mathbf{x}, \mathbf{y} \in \ell_2$. Wäre dies

nicht der Fall, könnten wir die Homogenität in [Definition 5.3.1](#) nicht mehr so einfach gewähren. Um einen Vektorraum zu einem Skalarproduktraum zu machen, müssen wir uns also manchmal auf einen Unterraum beschränken.

5.9.4 Funktionenräume

Sei nun V der Vektorraum aller stetigen Funktionen $f: [a, b] \rightarrow \mathbb{R}$. Um ein sinnvolles Skalarprodukt zu definieren, schränken wir uns erstmal auf einen großen, aber besser kontrollierbaren Unterraum ein. Wir bezeichnen mit $C([a, b])$ den Unterraum aller stetigen Funktionen, also

$$C([a, b]) = \left\{ f: [a, b] \rightarrow \mathbb{R} \text{ stetig} \right\}.$$

Insbesondere ist dann f beschränkt auf $[a, b]$. Das Standardskalarprodukt definieren wir hier als

$$\langle f, g \rangle = \int_a^b f(x)g(x)dx$$

und entsprechend die Norm einer Funktion als

$$\|f\| = \sqrt{\int_a^b f(x)^2 dx}.$$

Beispiel 5.9.8. Sei $[a, b] = [-1, 1]$. Dann sind die Funktionen $f(x) = 1$ und $g(x) = x$ orthogonal, denn

$$\int_{-1}^1 f(x)g(x)dx = \int_{-1}^1 x dx = 0.$$

Insbesondere gilt der Satz des Pythagoras:

$$\|f + g\|^2 = \|f\|^2 + \|g\|^2,$$

oder genauer

$$\int_{-1}^1 (1+x)^2 dx = \int_{-1}^1 1 dx + \int_{-1}^1 x^2 dx$$

Die Funktion $h(x) = x^2$ ist nicht orthogonal zu f und g . Man kann aber nachrechnen⁷

$$\tilde{h}(x) = \frac{1}{2}(3x^2 - 1)$$

orthogonal zu f und g ist. f, g und $\tilde{h}$ sind die ersten drei Legendre-Polynome.

⁷Man kann $\tilde{h}$ auch selbst herleiten, indem man das Gram-Schmidt-Verfahren auf $\{1, x, x^2\}$ anwendet.




Abbildung 5.7: Die Funktion $f(x) = e^{2\sin(3x)}\sqrt{2+x}$ und Approximationen durch n -dimensionale Legendre-Polynom-Basen.

Diese sind eine Menge von Polynomen ansteigenden Grades, die alle orthogonal zueinander sind. Die ersten $n+1$ Legendrepolynome sind also eine Orthogonalbasis des Raums aller Polynome n -ten Grades.

Beispiel 5.9.9. Sei $[a, b] = [0, 2\pi]$. Die Funktionen

$$1, \cos(x), \cos(2x), \cos(3x), \dots, \cos(nx), \sin(1x), \sin(2x), \dots, \sin(nx).$$

sind alle orthogonal zueinander. Sie werden als Fourierbasis bezeichnet.

Orthogonalbasen für Unterräume des $C([a, b])$ sind extrem nützlich. Wir können sie zur Funktionsapproximation verwenden; ein Kernproblem in nichtparametrischer Statistik und Machine Learning. Sei zum Beispiel $f \in C([a, b])$ beliebig und $\{\phi_1, \dots, \phi_n\}$ eine Orthogonalbasis eines n -dimensionalen Unterrums

$$\Phi = \left\{ \phi(x) = \sum_{i=1}^n c_i \phi_i(x), : c_1, \dots, c_n \in \mathbb{R} \right\}.$$

Während f in einem unendlich-dimensionalen Raum liegt, wird jede Funktion in Φ durch den Koeffizientenvektor $(c_1, \dots, c_n) \in \mathbb{R}^n$ charakterisiert. Wir wollen jetzt die komplizierte Funktion f möglichst genau durch eine „einfache“ Funktion in Φ approximieren. Die bestmögliche Approximation ist nach [Theorem 5.7.8](#)

$$\hat{f} = \text{proj}_{\Phi} f = \sum_{i=1}^n \frac{\langle \phi_i, f \rangle}{\|\phi_i\|^2} \phi_i.$$

In [Abbildung 5.7](#) sind solche Approximationen der Funktion $f(x) = e^{2\sin(3x)}\sqrt{2+x}$ durch Legendre-Polynome mit $n = 3, 5, 8$ dargestellt. Wir sehen, dass die appro-

ximierenden Funktionen $\hat{f}$ der wahren Funktion f mit steigendem n immer näher kommt.

5.9.5 Zufallsvariablen

Zugegeben: jetzt wird es ein bisschen esoterisch. Als (angehende) Statistiker sollten wir das folgende Beispiel aber nicht übergehen. Die technischen Details müssen hier nicht präzise verstanden werden. Ihr werdet aber hoffentlich trotzdem die bisher erlernten Konzepte und Resultate wiedererkennen. Ihr dürft das dann gerne einfach als „irgendwie geht da was mit linearer Algebra“ abspeichern.

Sei L^2 die Menge aller Zufallsvariablen $X: \Omega \rightarrow \mathbb{R}$ mit $\mathbb{E}(X^2) < \infty$. Dann ist L^2 mit den üblichen Additions- und Multiplikationsoperationen ein Vektorraum. Die Kovarianz gibt uns ein Skalarprodukt⁸

$$\langle X, Y \rangle = \text{Cov}(X, Y).$$

Die zugehörige Norm ist die Standardabweichung der Zufallsvariable, denn

$$\sqrt{\text{Cov}(X, X)} = \sqrt{\text{Var}(X)}.$$

Man kann auch zeigen, dass der Raum vollständig, also ein Hilbertraum ist.

Zwei Zufallsvariablen sind in diesem Skalarprodukt orthogonal, wenn sie unkorreliert sind. Für sie gilt dann zum Beispiel der Satz des Pythagoras

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y).$$

Und für alle Zufallsvariablen gilt die Cauchy-Schwarz-Ungleichung

$$|\text{Cov}(X, Y)| \leq \sqrt{\text{Var}(X)\text{Var}(Y)}.$$

Beide Eigenschaften dürften bereits bekannt sein (letzteres weil $|\text{Corr}(X, Y)| \leq 1$).

Der Blickwinkel des Skalarproduktraums ist trotzdem nützlich — schon deshalb, weil er uns eine geometrische Analogie zwischen Zufallsvariablen und dem $\mathbb{R}^2$ herstellen lässt. In der mathematischen Statistik bringt er manchmal auch tiefere Einblicke. Eine wichtige Anwendung ist die Formulierung des bedingten Erwartungswerts als Projektion.

⁸Das stimmt nicht ganz, denn die Positivität in [Definition 5.3.1](#) ist nicht erfüllt. Sei zum Beispiel $\Omega = [0, 1]$ und $X(\omega) = 0$ für alle $\omega \in [0, 1)$ und $X(\omega) = 1$ für $\omega = 1$. Dann ist $\langle X, X \rangle = \text{Var}(X) = 0$ obwohl $X \neq 0$. Allgemeiner können wir zwei Zufallsvariablen X, Y mit $\mathbb{P}(X = Y) = 1$ hier nicht unterscheiden. Das ist allerdings eine Formalität, die keine größeren Auswirkungen hat.

Theorem 5.9.10. Seien $Y, X \in L^2$ zwei fixe Zufallsvariablen und $W \subset L^2$ die Untermenge aller Zufallsvariablen, die sich als $g(X)$ für eine beliebige Funktion g schreiben lassen. Dann ist W ein Untervektorraum von L^2 und

$$\text{proj}_W Y = E(Y | X).$$

Beweis. Zu zeigen, dass W ein Untervektorraum ist, überlassen wir als Übung. Die Projektionseigenschaft zeigen wir im Wesentlichen durch wiederholte Anwendung der „Turmeigenschaft“. Wir bemerken zunächst, dass $g(X) = E(Y | X)$ eine Funktion von X ist und

$$E[g(X)^2] = E[E(Y | X)^2] \stackrel{\text{Jensen}}{\leq} E[E(Y^2 | X)] = E[Y^2] < \infty, \quad (5.1)$$

also gilt $E(Y | X) \in W$. Definieren wir $Z = Y - E(Y | X)$ gilt außerdem

$$E(Z | X) = E(Y | X) - E[E(Y | X) | X] = E(Y | X) - E(Y | X) = 0$$

und damit auch $E(Z) = E[E(Z | X)] = 0$. Für eine beliebige Funktion g gilt nun

$$\begin{aligned} \text{Cov}[g(X), Z] &= E[g(X)Z] - E[g(X)] \underbrace{E(Z)}_{=0} \\ &= E(E[g(X)Z | X]) \\ &= E(g(X)E[Z | X]) \\ &= E(g(X) \cdot 0) \\ &= 0. \end{aligned}$$

Das bedeutet, dass Z orthogonal zu W ist, also $Z \in W^\perp$. Nach dem Projektionstheorem lässt sich Y eindeutig (!) als $Y = \text{proj}_W Y + Z$ mit $\text{proj}_W Y \in W$ und $Z \in W^\perp$ schreiben. Also gilt

$$\text{proj}_W Y = Z - Y = E(Y | X). \quad \square$$

Anmerkung 5.9.11. Aus Theorem 5.7.8 folgt dann auch, dass $g^*(X) = E(Y | X)$ die Funktion ist, die den Fehler $E([Y - g(X)]^2)$ minimiert. So gesehen gibt uns die Funktion $g^*(X) = E(Y | X)$ die bestmögliche Vorhersage für Y , wenn wir nur die Information aus X zur Verfügung haben.

Nach diesem Ausflug werden wir nun für den Rest des Semesters wieder zum euklidischen Skalarprodukt zurückkehren.

5.10 Orthogonale Diagonalisierung

5.10.1 Definition

In [Abschnitt 5.6](#) haben wir kurz orthogonale Matrizen kennengelernt. Diese haben viele konzeptionelle und rechnerische Vorteile. Insbesondere bekommen wir die Inverse einer orthogonalen Matrix U einfach durch Transposition: $U^{-1} = U^\top$ ([Korollar 5.6.4](#)). Denken wir nun zurück an das Konzept der Diagonalisierung einer Matrix ([Abschnitt 4.4.2](#)) A als $A = PDP^{-1}$, wobei P eine invertierbare Matrix und D diagonal ist. Es wäre natürlich praktisch, wenn P nicht nur invertierbar, sondern sogar orthogonal ist. Dann gilt nämlich $A = PDP^\top$.

Definition 5.10.1. Wir nennen eine Matrix $A \in \mathbb{R}^{n \times n}$ **orthogonal diagonalisierbar**, wenn es eine Orthogonalmatrix P und eine Diagonalmatrix D gibt, sodass $P^\top AP = D$ bzw. $A = PDP^\top$.

5.10.2 Äquivalenz zu symmetrischen Matrizen

Es stellt sich erstmal die Frage, für welche Matrizen eine orthogonale Diagonalisierung möglich ist. Es gilt das folgende, bemerkenswerte Resultat.

Theorem 5.10.2. Eine Matrix $A \in \mathbb{R}^{n \times n}$ ist genau dann orthogonal diagonalisierbar, wenn sie symmetrisch ist.

Daraus folgt zum Beispiel, dass die Hauptkomponenten in der PCA ([Abschnitt 4.6](#)) orthogonal zueinander sind.

Wir werden das Theorem schrittweise herleiten und dabei auch ein paar wichtige Eigenschaften von symmetrischen Matrizen beleuchten. Die eine Richtung ist einfach: Wir können leicht sehen, dass A symmetrisch sein muss, denn

$$A^\top = (PDP^\top)^\top = (P^\top)^\top D^\top P^\top = PDP^\top = A.$$

Andererseits gilt für symmetrische Matrizen das Folgende.

Lemma 5.10.3. Wenn $A \in \mathbb{R}^{n \times n}$ symmetrisch ist, dann sind alle Eigenräume von A orthogonal zueinander.

Beweis. Seien $\mathbf{v}_1, \mathbf{v}_2$ Eigenvektoren aus zwei Eigenräumen $E_{\lambda_1}, E_{\lambda_2}$ mit $\lambda_1 \neq \lambda_2$. Wir wollen zeigen, dass $\mathbf{v}_1 \perp \mathbf{v}_2$ bzw. $\mathbf{v}_1^\top \mathbf{v}_2 = 0$. Dazu berechnen wir

$$\lambda_1 \mathbf{v}_1^\top \mathbf{v}_2 = (A\mathbf{v}_1)^\top \mathbf{v}_2 = \mathbf{v}_1^\top A^\top \mathbf{v}_2 = \mathbf{v}_1^\top A\mathbf{v}_2 = \lambda_2 \mathbf{v}_1^\top \mathbf{v}_2.$$

Da $\lambda_1 \neq \lambda_2$ muss $\mathbf{v}_1^\top \mathbf{v}_2 = 0$ gelten. □

Wären alle Eigenwerte verschieden, wären wir nun am Ziel. Dann gibt es n orthogonale Eigenvektoren, diese können wir normieren und wie im Beweis von [Theorem 4.4.2](#) in die Spalten der Matrix P schreiben. Diese Einschränkung ist aber nicht notwendig, wie [Theorem 5.10.2](#) zeigt. Damit kommen wir zur nächsten wichtigen Einsicht:

Theorem 5.10.4. *Alle Eigenwerte einer symmetrischen Matrix sind reell.*

Beweis. Sei $\lambda \in \mathbb{C}$ ein Eigenwert von A und $\mathbf{v} \in \mathbb{C}^n$ ein zugehöriger Eigenvektor mit $\|\mathbf{v}\| = \bar{\mathbf{v}}^\top \mathbf{v} = 1$. Dann ist nach [Theorem 4.5.4](#) auch $\bar{\lambda}$ ein Eigenwert mit zugehörigem Eigenvektor $\bar{\mathbf{v}}$. Es gilt

$$\bar{\mathbf{v}}^\top A\mathbf{v} = \bar{\mathbf{v}}^\top (\lambda\mathbf{v}) = \lambda \bar{\mathbf{v}}^\top \mathbf{v} = \lambda$$

und außerdem

$$\bar{\mathbf{v}}^\top A\mathbf{v} = \bar{\mathbf{v}}^\top A^\top \mathbf{v} = (A\bar{\mathbf{v}})^\top \mathbf{v} = \bar{\lambda} \bar{\mathbf{v}}^\top \mathbf{v} = \bar{\lambda}.$$

Wir haben gezeigt, dass $\lambda = \bar{\lambda}$ und damit $\lambda \in \mathbb{R}$. □

Das Resultat ist selbst schon interessant. Da wir es in der Statistik so oft mit symmetrischen Matrizen zu tun bekommen, erklärt es auch unsere etwas stiefmütterliche Behandlung von komplexen Eigenwerten und Vektoren in [Abschnitt 4.5](#).

Dass alle Eigenwerte reell sind, benötigen wir auch für den schwierigsten Schritt des Beweises von [Theorem 5.10.2](#). Es erlaubt uns nämlich, die Matrix A als $PDP^\top$ mit P orthogonal und einer oberen Dreiecksmatrix D zu schreiben. Dies wird als *Schur-Zerlegung*⁹ bezeichnet.

Theorem 5.10.5 (Schur-Zerlegung). *Sei $A \in \mathbb{R}^{n \times n}$ mit reellen Eigenwerten. Dann gibt es eine Orthogonalmatrix $P \in \mathbb{R}^{n \times n}$, sodass $D = P^\top A P$ eine obere Dreiecksmatrix mit den Eigenwerten auf der Diagonalen ist.*

Beweis (optional). Wir zeigen das Resultat durch Induktion über n . Für $n = 1$ ist die Eigenschaft trivialerweise erfüllt. Wir nehmen nun an, dass jede $(n \times n)$ -Matrix eine Schur-Zerlegung besitzt, und zeigen, dass auch jede Matrix $A \in \mathbb{R}^{(n+1) \times (n+1)}$ eine Schur-Zerlegung besitzt.

Sei λ ein Eigenwert von A und $\mathbf{v}_1$ ein zugehöriger Eigenvektor mit Länge 1. Wir erweitern $\mathbf{v}_1$ zu einer Orthonormalbasis $\{\mathbf{v}_1, \dots, \mathbf{v}_{n+1}\}$ des $\mathbb{R}^{n+1}$ und definieren die Orthogonalmatrix

$$V = (\mathbf{v}_1 \cdots \mathbf{v}_{n+1}) = (\mathbf{v}_1 \ V_2).$$

⁹Benannt nach dem russisch-deutschen Mathematiker Issai Schur (1875-1941), der in Berlin lehrte, bis er 1938 vor den Nazis nach Israel floh.

Es gilt dann

$$\begin{aligned} V^\top AV &= \begin{pmatrix} \mathbf{v}_1^\top \\ V_2^\top \end{pmatrix} A \begin{pmatrix} \mathbf{v}_1 & V_2 \end{pmatrix} = \begin{pmatrix} \mathbf{v}_1^\top \\ V_2^\top \end{pmatrix} \begin{pmatrix} A\mathbf{v}_1 & AV_2 \end{pmatrix} = \begin{pmatrix} \mathbf{v}_1^\top A\mathbf{v}_1 & \mathbf{v}_1^\top AV_2 \\ V_2^\top A\mathbf{v}_1 & V_2^\top AV_2 \end{pmatrix} \\ &= \begin{pmatrix} \lambda & \mathbf{v}_1^\top AV_2 \\ 0 & V_2^\top AV_2 \end{pmatrix}. \end{aligned}$$

Die Matrix $V_2^\top AV_2 \in \mathbb{R}^{n \times n}$ hat per Induktionsannahme eine Schur-Zerlegung $U^\top RU$ mit U orthogonal und einer oberen Dreiecksmatrix R . Also gilt

$$V^\top AV = \begin{pmatrix} \lambda & \mathbf{v}_1^\top AV_2 \\ 0 & U^\top RU \end{pmatrix} = \begin{pmatrix} 1 & \mathbf{0}^\top \\ \mathbf{0} & U^\top \end{pmatrix} \begin{pmatrix} \lambda & U\mathbf{v}_1^\top AV_2 U^\top \\ 0 & R \end{pmatrix} \begin{pmatrix} 1 & \mathbf{0}^\top \\ \mathbf{0} & U \end{pmatrix}.$$

Da U orthogonal ist, ist auch

$$\begin{pmatrix} 1 & \mathbf{0}^\top \\ \mathbf{0} & U \end{pmatrix}$$

orthogonal. Es gilt deshalb

$$\begin{pmatrix} 1 & \mathbf{0}^\top \\ \mathbf{0} & U \end{pmatrix} V^\top AV \begin{pmatrix} 1 & \mathbf{0}^\top \\ \mathbf{0} & U^\top \end{pmatrix} = \begin{pmatrix} \lambda & \mathbf{v}_1^\top AV_2 \\ 0 & R \end{pmatrix},$$

wobei auf der rechten Seite eine Dreiecksmatrix steht. Da außerdem das Produkt von Orthogonalmatrizen orthogonal ist, ist auch die Matrix

$$P = V \begin{pmatrix} 1 & \mathbf{0}^\top \\ \mathbf{0} & U^\top \end{pmatrix}$$

orthogonal. □

Die Schur-Zerlegung ist selbst schon bemerkenswert. Die Symmetrie der Matrix A wird hierfür nicht benötigt, nur dass die Eigenwerte reell sind. Die Symmetrie von A ermöglicht uns aber nun den letzten Schritt im Beweis von [Theorem 5.10.2](#): Für die Schur-Zerlegung gilt dann

$$D = P^\top AP = P^\top A^\top P = (P^\top AP)^\top = D^\top.$$

Deshalb muss die Dreiecksmatrix D eine Diagonalmatrix sein.

5.10.3 Algorithmus

Aus den vorangegangenen Resultaten ergibt sich der folgende Algorithmus zur orthogonalen Diagonalisierung einer symmetrischen Matrix A :

1. Finde eine Basis für jeden Eigenraum von A .
2. Konstruiere durch das Gram-Schmidt-Verfahren eine Orthonormalbasis

für jeden Eigenraum. Alle Basisvektoren zusammen ergeben eine Orthonormalbasis des $\mathbb{R}^n$.

3. Schreibe die Vektoren der Orthonormalbasis in die Spalten der Matrix P und die zugehörigen Eigenwerte (in gleicher Reihenfolge) auf die Diagonale der Diagonalmatrix D .

Beispiel 5.10.6. (Bsp. 7.2.2 aus [AR]). Die Matrix

$$A = \begin{pmatrix} 1 & 2 \\ 2 & -2 \end{pmatrix}$$

hat die Eigenwerte $\lambda_1 = -3$ und $\lambda_2 = 2$ mit zugehörigen Eigenvektoren

$$\mathbf{v}_1 = \begin{pmatrix} 1 \\ -2 \end{pmatrix} \quad \text{und} \quad \mathbf{v}_2 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}.$$

Die Vektoren sind bereits orthogonal, aber wir müssen sie normalisiert in die Spalten von P schreiben:

$$P = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 & 2 \\ -2 & 1 \end{pmatrix}$$

und $D = \text{diag}(-3, 2)$. Damit gilt

$$A = P^\top D P = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 & 2 \\ -2 & 1 \end{pmatrix} \begin{pmatrix} -3 & 0 \\ 0 & 2 \end{pmatrix} \frac{1}{\sqrt{5}} \begin{pmatrix} 1 & -2 \\ 2 & 1 \end{pmatrix}.$$

5.10.4 Spektralzerlegung

Sei nun $A = P \Lambda P^\top$ die Spektralzerlegung von A . Die Spalten von P sind orthonormale Eigenvektoren $\mathbf{p}_1, \dots, \mathbf{p}_n$ und $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ enthält die zugehörigen Eigenwerte. Es gilt also

$$A = P \Lambda P^\top = \begin{pmatrix} \mathbf{p}_1 & \cdots & \mathbf{p}_n \end{pmatrix} \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{pmatrix} \begin{pmatrix} \mathbf{p}_1^\top \\ \vdots \\ \mathbf{p}_n^\top \end{pmatrix} = \sum_{i=1}^n \lambda_i \mathbf{p}_i \mathbf{p}_i^\top.$$

Die Matrix A lässt sich also in eine Summe aus n Matrizen $\lambda_i \mathbf{p}_i \mathbf{p}_i^\top \in \mathbb{R}^{n \times n}$ zerlegen.

So lässt sich die Wirkung der Matrixmultiplikation $\mathbf{x} \mapsto A\mathbf{x}$ besonders gut interpretieren. Weil $\|\mathbf{p}_i\| = \mathbf{p}_i^\top \mathbf{p}_i = 1$, sehen wir mit [Theorem 5.7.3](#), dass $\mathbf{x} \mapsto$

$\mathbf{p}_i \mathbf{p}_i^\top \mathbf{x}$ eine Projektion auf den Raum $\text{span}\{\mathbf{p}_i\}$ entspricht. Also:

$$A\mathbf{x} = \sum_{i=1}^n \lambda_i \text{proj}_{\text{span}\{\mathbf{p}_i\}} \mathbf{x}.$$

Der Vektor $\mathbf{x}$ wird also separat auf die Geraden durch $\mathbf{p}_i$ projiziert, entlang dieser Geraden jeweils um λ_i gestreckt und zuletzt die gestreckten Vektoren aufsummiert.

Beispiel 5.10.7. Wir erinnern uns aus *Beispiel 5.10.6*, dass

$$A = \begin{pmatrix} 1 & 2 \\ 2 & -2 \end{pmatrix}, \quad P = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 & 2 \\ -2 & 1 \end{pmatrix}, \quad \Lambda = \text{diag}(-3, 2).$$

Entsprechend gilt auch

$$\begin{aligned} A &= -3 \cdot \frac{1}{5} \begin{pmatrix} 1 \\ -2 \end{pmatrix} \begin{pmatrix} 1 & -2 \end{pmatrix} + 2 \cdot \frac{1}{5} \begin{pmatrix} 2 \\ 1 \end{pmatrix} \begin{pmatrix} 2 & 1 \end{pmatrix} \\ &= -3 \begin{pmatrix} 1/5 & -2/5 \\ -2/5 & 4/5 \end{pmatrix} + 2 \begin{pmatrix} 4/5 & 1/5 \\ 1/5 & 1/5 \end{pmatrix}. \end{aligned}$$

Wenden wir dies nun auf den Vektor $\mathbf{x} = (1, 1)$ an. Es gilt

$$A\mathbf{x} = \begin{pmatrix} 1 & 2 \\ 2 & -2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 0 \end{pmatrix}$$

und, tatsächlich,

$$\begin{aligned} A\mathbf{x} &= -3 \begin{pmatrix} 1/5 & -2/5 \\ -2/5 & 4/5 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} + 2 \begin{pmatrix} 4/5 & 2/5 \\ 2/5 & 1/5 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \\ &= -3 \begin{pmatrix} -1/5 \\ 2/5 \end{pmatrix} + 2 \begin{pmatrix} 6/5 \\ 3/5 \end{pmatrix} \\ &= \begin{pmatrix} 3/5 \\ -6/5 \end{pmatrix} + \begin{pmatrix} 12/5 \\ 6/5 \end{pmatrix} \\ &= \begin{pmatrix} 3 \\ 0 \end{pmatrix}. \end{aligned}$$

Die Rechnung kann grafisch in *Abbildung 5.8* nachvollzogen werden.




Abbildung 5.8: Spektralzerlegung der Matrixtransformation $\mathbf{x} \rightarrow A\mathbf{x}$ in [Beispiel 5.10.7](#). (Fig. 7.2.1 in [AR].)