

6 Quadratische Formen und die Singulärwertzerlegung

6.1 Quadratische Formen

6.1.1 Definition und Motivation

Bisher haben wir uns im Wesentlichen um lineare Funktionen $\mathbf{x} \mapsto A\mathbf{x}$ gekümmert. Sie sind das höher-dimensionale Äquivalent zu einer Geraden $f(x) = ax$ im Falle $\mathbb{R} \rightarrow \mathbb{R}$. *Quadratische Formen* verallgemeinern quadratische Funktionen $f(x) = ax^2 = xax$ in höhere Dimensionen. Die folgende Definition sollte euch bereits aus der Analysis geläufig sein.

Definition 6.1.1. Eine **quadratische Form** auf $\mathbb{R}^n$ ist eine Funktion $Q: \mathbb{R}^n \rightarrow \mathbb{R}$ gegeben durch $Q(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x}$, wobei $A \in \mathbb{R}^{n \times n}$ eine symmetrische Matrix ist.

Eine wichtige Anwendung finden quadratische Formen beim Maximieren bzw. Minimieren einer Funktion. Wir erinnern uns zum Beispiel an die linearen Modelle in [Abschnitt 5.8.3](#). Hier versuchen wir, einen Parameter zu finden, der die Summe der quadratischen Fehler minimiert. Ein verallgemeinertes Prinzip dazu, die *Maximum-Likelihood-Methode*, darf getrost als das Herz der modernen Statistik betrachtet werden und wird im nächsten Semester ausführlich besprochen. Hierbei passen wir die Parameter eines statistischen Modells an, indem wir die sogenannte Likelihood-Funktion maximieren. Selbst beim Trainieren von modernen neuronalen Netzen mit Billionen von Parametern kommt dieses Prinzip zum Einsatz.

Der Zusammenhang lässt sich über Taylor's Theorem herstellen. Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine hinreichend glatte Funktion und $\mathbf{x}^*$ der Punkt, der diese Funktion minimiert. Dann können wir in einer Umgebung von $\mathbf{x}^*$ die Funktion durch

$$f(\mathbf{x}) \approx f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)(\mathbf{x} - \mathbf{x}^*) + \frac{1}{2}(\mathbf{x} - \mathbf{x}^*)^\top H(\mathbf{x}^*)(\mathbf{x} - \mathbf{x}^*)$$

approximieren, wobei $\nabla f(\mathbf{x}^*)$ der *Gradient* und $H(\mathbf{x}^*) = \nabla^2 f(\mathbf{x}^*)$ die *Hesse-Matrix* am Punkt $\mathbf{x}^*$ ist. Der Term $f(\mathbf{x}^*)$ ist eine Konstante und, da f an $\mathbf{x}^*$ ein Minimum hat, gilt $\nabla f(\mathbf{x}^*) = \mathbf{0}$. Die Funktion f lässt sich also lokal durch die quadratische Form $Q(\mathbf{z}) = \mathbf{z}^\top H(\mathbf{x}^*)\mathbf{z}$ approximieren, wobei wir $\mathbf{z} = \mathbf{x} - \mathbf{x}^*$ definieren. Die Funktion Q ist meist viel einfacher zu verstehen als die beliebige

komplizierte Funktion f selbst. Die Matrix $H(\mathbf{x}^*)$ beschreibt dabei die Krümmung von f in die verschiedenen Richtungen vom Punkt $\mathbf{x}^*$ aus gesehen.

Auch wenn das alles bereits bekannt ist, lohnt es sich durchaus, quadratische Formen auch aus dem Blickwinkel der linearen Algebra zu betrachten. Insbesondere werden uns die bisher entwickelten Werkzeuge weiteren Aufschluss bezüglich deren Definitheit geben.

6.1.2 Hauptachsentheorem

Eine quadratische Form

$$Q(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x} = \sum_{i=1}^n a_{ii} x_i^2 + \sum_{i=1}^n \sum_{j \neq i} a_{ij} x_i x_j,$$

beinhaltet sowohl rein quadratische Terme $a_{ii} x_i^2$ und gemischte Terme $a_{ij} x_i x_j$. Besonders die gemischten Terme machen es schwer, die Funktion Q zu interpretieren. Da A symmetrisch ist, ist sie orthogonal diagonalisierbar zu $A = P \Lambda P^\top$, wobei $P = (\mathbf{p}_1 \cdots \mathbf{p}_n)$ orthonormale Eigenvektoren in den Spalten hat. Es gilt also

$$\mathbf{x}^\top A \mathbf{x} = \mathbf{x}^\top P \Lambda P^\top \mathbf{x} = (P^\top \mathbf{x})^\top \Lambda (P^\top \mathbf{x}).$$

Durch den Koordinatenwechsel in die Eigenvektorbasis $\mathbf{y} = P^\top \mathbf{x}$, können wir die quadratische Form also in rein quadratischen Termen darstellen.

Theorem 6.1.2 (Hauptachsentheorem). Sei $A \in \mathbb{R}^{n \times n}$ eine symmetrische Matrix, die durch P orthogonal zur Matrix $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ diagonalisiert wird. Dann gilt für $\mathbf{y} = P^\top \mathbf{x}$,

$$\mathbf{x}^\top A \mathbf{x} = \mathbf{y}^\top \Lambda \mathbf{y} = \sum_{i=1}^n \lambda_i y_i^2.$$

Das erleichtert weiter die Interpretation. In Richtung $\mathbf{p}_i$ entspricht die Funktion Q einer simplen Parabel $\lambda_i y_i^2$. Der Eigenwert λ_i gibt dabei die Stärke und Richtung der Krümmung vor. Die gesamte Funktion Q lässt sich dann als Summe von solchen einfachen Parabeln in zueinander orthogonalen Richtungen zusammensetzen.

6.1.3 Definitheit

Aus der Analysis wisst ihr bereits, dass sich anhand der *Definitheit* feststellen lässt, ob ein kritischer Punkt ein Maximum, Minimum oder Sattelpunkt ist. Wir wiederholen zunächst die Definition.




Abbildung 6.1: Graphen von quadratischen Formen $Q: \mathbb{R}^2 \rightarrow \mathbb{R}$. (Fig 7.2.4 in [LLM].)

Definition 6.1.3. Sei $A \in \mathbb{R}^{n \times n}$ symmetrisch und $Q(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x}$ die zugehörige quadratische Form. Dann nennen wir A und Q

- **positiv definit**, wenn $Q(\mathbf{x}) > 0$ für alle $\mathbf{x} \neq 0$;
- **positiv semidefinit**, wenn $Q(\mathbf{x}) \geq 0$ für alle $\mathbf{x} \neq 0$;
- **negativ definit**, wenn $Q(\mathbf{x}) < 0$ für alle $\mathbf{x} \neq 0$;
- **negativ semidefinit**, wenn $Q(\mathbf{x}) \leq 0$ für alle $\mathbf{x} \neq 0$;
- **indefinit**, wenn sowohl $Q(\mathbf{x}) > 0$ für ein $\mathbf{x} \in \mathbb{R}^n$ also auch $Q(\mathbf{x}) < 0$ für ein anderes $\mathbf{x} \in \mathbb{R}^n$.

Visuell ist die Definitheit an den Graphen in [Abbildung 6.1](#) illustriert.

- (a) Es gilt $Q(\mathbf{x}) = 3x_1^2 + 7x_2^2 > 0$ für alle $\mathbf{x} \neq 0$, also ist die Form positiv definit und besitzt ein globales Minimum.
- (b) Es gilt $Q(\mathbf{x}) = 3x_1^2 \geq 0$, also ist die Form positiv semidefinit. Es gilt aber zum Beispiel $Q((0, 2)) = 0$, also ist sie nicht positiv definit. Die Funktion hat entsprechend ein Minimum, das aber nicht strikt ist.
- (c) Es gilt $Q(\mathbf{x}) = 3x_1^2 - 7x_2^2 > 0$ für $\mathbf{x} = (1, 0)$ und $Q(\mathbf{x}) < 0$ für $\mathbf{x} = (0, 1)$. Also ist Q indefinit und es gibt weder ein Minimum noch ein Maximum.
- (d) Es gilt $Q(\mathbf{x}) = -3x_1^2 - 7x_2^2 < 0$ für alle $\mathbf{x} \neq 0$, also ist die Form negativ definit und besitzt ein globales Maximum.

Die Definitheit lässt sich am besten über die Eigenwerte bestimmen.

Theorem 6.1.4. Sei $A \in \mathbb{R}^{n \times n}$ symmetrisch. Dann ist die quadratische Form $Q(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x}$ genau dann ...

- (i) positiv definit, wenn alle Eigenwerte strikt positiv sind;
- (ii) positiv semidefinit, wenn alle Eigenwerte nichtnegativ sind;
- (iii) negativ definit, wenn alle Eigenwerte strikt negativ sind;
- (iv) negativ semidefinit, wenn alle Eigenwerte nichtpositiv sind;
- (v) indefinit, wenn es einen strikt positiven und einen strikt negativen Eigenwert gibt.

Beweis. Aus dem Hauptsachsentheorem (Theorem 6.1.2) bekommen wir

$$Q(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x} = \mathbf{y}^\top \Lambda \mathbf{y} = \sum_{i=1}^n \lambda_i y_i^2,$$

wobei $\mathbf{y} = P^\top \mathbf{x}$ und $\lambda_1, \dots, \lambda_n$ die Eigenwerte von A sind. Da P invertierbar ist, gibt es zu jedem $\mathbf{x}$ genau ein $\mathbf{y}$, sodass $\mathbf{y} = P^\top \mathbf{x}$. Deshalb nimmt $Q(\mathbf{x})$ für $\mathbf{x} \neq 0$ genau die gleichen Werte an wie $\sum_{i=1}^n \lambda_i y_i^2$. Das Vorzeichen dieser Summe lässt sich dann offensichtlich durch die im Theorem genannten Fälle charakterisieren. $\square$

6.1.4 Variationelle Charakterisierung von Eigenwerten

Quadratische Formen geben uns auch einen überraschenden, neuen Blickwinkel auf die Eigenwerte einer Matrix. Wir können sie nämlich als das Resultat einer Maximierung/Minimierung von $Q(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x}$ unter Einschränkung des Definitionsbereiches charakterisieren. Dies wird auch *variationelle Charakterisierung* der Eigenwerte genannt. Zunächst charakterisieren wir nur den größten und kleinsten Eigenwert:

Theorem 6.1.5. Sei $A \in \mathbb{R}^{n \times n}$ symmetrisch mit der Größe nach geordneten Eigenwerten $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$. Dann gilt

$$\lambda_n = \min_{\|\mathbf{x}\|=1} \mathbf{x}^\top A \mathbf{x} \leq \max_{\|\mathbf{x}\|=1} \mathbf{x}^\top A \mathbf{x} = \lambda_1.$$

Das Minimum wird für einen Eigenvektor zu λ_n , das Maximum für einen Eigenvektor zu λ_1 angenommen.

Beweis. Wie im Hauptsachsentheorem (Theorem 6.1.2) gilt

$$Q(\mathbf{x}) = \sum_{i=1}^n \lambda_i y_i^2$$




Abbildung 6.2: Graph der quadratischen Form $Q(\mathbf{x}) = 3x_1^2 + 7x_2^2$ (links) und die Einschränkung auf $\|\mathbf{x}\| = 1$ (rechts). Das Maximum des rechten Graphen ist der größte Eigenwert ($\lambda_1 = 7$), das Minimum der kleinste Eigenwert $\lambda_2 = 3$. (Fig 7.3.1–2 in [LLM].)

mit $\mathbf{y} = P^\top \mathbf{x}$. Weil P orthogonal ist, gilt $\|\mathbf{y}\| = \|P^\top \mathbf{x}\| = \|\mathbf{x}\| = 1$ (Übung!). Da alle y_i^2 positiv sind, ist dann

$$Q(\mathbf{x}) = \sum_{i=1}^n \lambda_i y_i^2 \leq \lambda_1 \sum_{i=1}^n y_i^2 = \lambda_1 \|\mathbf{y}\|^2 = \lambda_1.$$

Außerdem ist $Q(\mathbf{x}) = \lambda_1$ für $\mathbf{y} = \mathbf{e}_1$ bzw. $\mathbf{x} = P\mathbf{e}_1 = \mathbf{p}_1$. Der größte Eigenwert erfüllt also

$$\lambda_1 = \max_{\|\mathbf{x}\|=1} Q(\mathbf{x}) = \max_{\|\mathbf{x}\|=1} \mathbf{x}^\top A \mathbf{x}.$$

Mit dem gleichen Argument (aber Abschätzung nach unten) können wir außerdem zeigen, dass

$$\lambda_n = \min_{\|\mathbf{x}\|=1} Q(\mathbf{x}) = \min_{\|\mathbf{x}\|=1} \mathbf{x}^\top A \mathbf{x}.$$

□

Beispiel 6.1.6. *Theorem 6.1.5 ist grafisch in [Abbildung 6.2](#) illustriert. Links sehen wir den Graphen der quadratischen Form*

$$Q(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x} = \mathbf{x}^\top \begin{pmatrix} 3 & 0 \\ 0 & 7 \end{pmatrix} \mathbf{x}.$$

Weil A diagonal ist, können wir die Eigenwerte 3 und 7 einfach ablesen. Rechts sehen wir den Graphen, wenn die Funktion $Q(\mathbf{x})$ auf den Bereich $\|\mathbf{x}\| = 1$ eingeschränkt wird (das ist die Schnittmenge von Q mit dem Einheitszylinder).

Wie erwartet, ist das Maximum dieser Funktion 7 und das Minimum 3.

Das Argument lässt sich noch verfeinern und so auf alle anderen Eigenwerte ausweiten.

Theorem 6.1.7. Sei $A \in \mathbb{R}^{n \times n}$ symmetrisch mit der Größe nach geordneten Eigenwerten $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ und zugehörigen orthonormalen Eigenvektoren $\mathbf{p}_1, \dots, \mathbf{p}_n$. Dann gilt für alle $k = 1, \dots, n$:

$$\lambda_k = \max_{\substack{\|\mathbf{x}\|=1 \\ \mathbf{x} \perp \text{span}\{\mathbf{p}_1, \dots, \mathbf{p}_{k-1}\}}} \mathbf{x}^\top A \mathbf{x} = \min_{\substack{\|\mathbf{x}\|=1 \\ \mathbf{x} \perp \text{span}\{\mathbf{p}_{k+1}, \dots, \mathbf{p}_n\}}} \mathbf{x}^\top A \mathbf{x}.$$

Das Maximum/Minimum wird jeweils für einen Eigenvektor zu λ_k angenommen.

Beweisidee. Für $\mathbf{x} \perp \text{span}\{\mathbf{p}_1, \dots, \mathbf{p}_{k-1}\}$ und $\mathbf{y} = P^\top \mathbf{x}$ gilt $y_1, \dots, y_{k-1} = 0$ und deshalb

$$Q(\mathbf{x}) = \sum_{i=k}^n \lambda_i y_i^2 \leq \lambda_k \sum_{i=1}^n y_i^2 = \lambda_k \|\mathbf{y}\|^2 = \lambda_k,$$

wobei $Q(\mathbf{x}) = \lambda_k$ für $\mathbf{y} = \mathbf{e}_k$ bzw. $\mathbf{x} = P \mathbf{e}_k = \mathbf{p}_k$. Ähnlich geht das Argument für das Minimum (hier mit Abschätzung nach unten). $\square$

Diese Charakterisierung hilft uns zum Beispiel bei der Interpretation der PCA. Angenommen ein Zufallsvektor $\mathbf{Y} \in \mathbb{R}^n$ hat Kovarianzmatrix $\text{Cov}(\mathbf{Y}) = \Sigma$. Dann folgt aus der Linearität der Kovarianz, dass $\text{Var}(\mathbf{x}^\top \mathbf{Y}) = \mathbf{x}^\top \Sigma \mathbf{x}$ für jede (deterministische) Richtung $\mathbf{x} \in \mathbb{R}^n, \|\mathbf{x}\| = 1$. Die erste Hauptkomponente $\mathbf{p}_1$ von Σ ist also die Richtung mit der größten Varianz und diese Varianz ist gleich λ_1 . Danach suchen wir die zweite Hauptkomponente im Raum orthogonal zu $\mathbf{p}_1$ und maximieren die Varianz unter den verbleibenden Richtungen, etc.

Eine weitere, verwandte Charakterisierung ist der folgende Satz von Courant-Fischer.

Theorem 6.1.8 (Minimum-Maximum-Prinzip). Sei $A \in \mathbb{R}^{n \times n}$ symmetrisch mit der Größe nach geordneten Eigenwerten $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$. Dann gilt für alle $k = 1, \dots, n$:

$$\begin{aligned} \lambda_k &= \max_{\dim(V)=k} \min_{\substack{\mathbf{x} \in V \\ \|\mathbf{x}\|=1}} \mathbf{x}^\top A \mathbf{x} \\ &= \min_{\dim(V)=n-k+1} \max_{\substack{\mathbf{x} \in V \\ \|\mathbf{x}\|=1}} \mathbf{x}^\top A \mathbf{x}, \end{aligned}$$

wobei V jeweils ein Untervektorraum des $\mathbb{R}^n$ ist. Das Maximum/Minimum wird jeweils für einen Eigenvektor zu λ_k angenommen.

Beweis (optional). Wir folgen der Notation der vorherigen Beweise und beginnen mit der zweiten Gleichheit. Zunächst bemerken wir, dass

$$V := \text{span}\{\mathbf{p}_k, \dots, \mathbf{p}_n\} = \text{span}\{\mathbf{p}_1, \dots, \mathbf{p}_{k-1}\}^\perp$$

ein Unterraum mit $\dim(V) = n - k + 1$ ist. Nach [Theorem 6.1.7](#) gilt

$$\max_{\mathbf{x} \in V, \|\mathbf{x}\|=1} \mathbf{x}^\top A \mathbf{x} = \max_{\mathbf{x} \in V} \frac{\mathbf{x}^\top A \mathbf{x}}{\mathbf{x}^\top \mathbf{x}} = \lambda_k.$$

Sei nun V ein beliebiger anderer Unterraum mit $\dim(V) = n - k + 1$. Dann ist die Schnittmenge von V und $\text{span}\{\mathbf{p}_1, \dots, \mathbf{p}_k\}$ nicht leer. (Denn sonst hätte deren Spann die Dimension $n + 1$.) Also gibt es ein Element $\mathbf{v} \in V$, dass wir darstellen können als $\mathbf{v} = \sum_{i=1}^k c_i \mathbf{p}_i$. Für dieses Element gilt dann

$$\frac{\mathbf{v}^\top A \mathbf{v}}{\mathbf{v}^\top \mathbf{v}} = \frac{\sum_{i=1}^k c_i^2 \lambda_i}{\sum_{i=1}^k c_i^2} \geq \lambda_k.$$

Und da es ein solches Element in jedem Unterraum mit $\dim(V) = n - k + 1$ gibt, erhalten wir

$$\lambda_k = \min_{\dim(V)=n-k+1} \max_{\substack{\mathbf{x} \in V \\ \|\mathbf{x}\|=1}} \mathbf{x}^\top A \mathbf{x}.$$

Die erste Gleichheit folgt aus der zweiten angewandt auf die Matrix $\tilde{A} = -A$, wessen Eigenwerte $-\lambda_n \geq -\lambda_{n-1} \geq \dots \geq -\lambda_1$ sind. $\square$