



LUDWIG-
MAXIMILIANS-
UNIVERSITÄT
MÜNCHEN

14. Komplexe Eigenwerte und Anwendungen

Methoden der Linearen Algebra in der Statistik
Thomas Nagler <t.nagler@lmu.de>

Agenda

1 Komplexe Eigenwerte

2 Hauptkomponentenanalyse

3 Markovketten und Google

Agenda

1 Komplexe Eigenwerte

2 Hauptkomponentenanalyse

3 Markovketten und Google

Motivation:

- Die Eigenwerte einer Matrix sind die Nullstellen des charakteristischen Polynoms

$$p(\lambda) = \det(A - \lambda I) = c_n \lambda^n + \cdots + c_1 \lambda + c_0.$$

- Es ist aber möglich, dass dieses Polynom keine Nullstelle $\lambda \in \mathbb{R}$ besitzt.

Komplexe Eigenwerte

Beispiel:

- Nehmen wir die Rotationsmatrix um 90° gegen den Uhrzeigersinn:

$$M = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}.$$

Komplexe Eigenwerte

Beispiel:

- Nehmen wir die Rotationsmatrix um 90° gegen den Uhrzeigersinn:

$$M = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}.$$

- Dann gilt

$$\det(M - \lambda I) = \det \begin{pmatrix} -\lambda & -1 \\ 1 & -\lambda \end{pmatrix} = \lambda^2 + 1.$$

Komplexe Eigenwerte

Beispiel:

- Nehmen wir die Rotationsmatrix um 90° gegen den Uhrzeigersinn:

$$M = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}.$$

- Dann gilt

$$\det(M - \lambda I) = \det \begin{pmatrix} -\lambda & -1 \\ 1 & -\lambda \end{pmatrix} = \lambda^2 + 1.$$

- Die Gleichung $\lambda^2 = -1$ hat keine reellen Lösungen.
- Deshalb kann es keinen reellen Eigenvektor geben.

Komplexe Eigenwerte

- Eine Rotation verändert immer die Richtung eines Vektors (außer von $\mathbf{0}$).
- Die Gleichung $\lambda^2 = -1$ hat die komplexen Lösungen $\lambda = \pm i \in \mathbb{C}$.

Komplexe Eigenwerte

- Eine Rotation verändert immer die Richtung eines Vektors (außer von $\mathbf{0}$).
- Die Gleichung $\lambda^2 = -1$ hat die komplexen Lösungen $\lambda = \pm i \in \mathbb{C}$.
- Der *Fundamentalsatz der Algebra* besagt, dass jedes Polynom zumindest eine (womöglich komplexe) Nullstelle hat.
- Wir können zugehörige Eigenvektoren finden, indem wir komplexwertige Einträge zulassen.

Definition

Sei $A \in \mathbb{R}^{n \times n}$. Ein Vektor $\mathbf{x} \neq \mathbf{0} \in \mathbb{C}^n$ wird **Eigenvektor** von A genannt, wenn es ein Skalar $\lambda \in \mathbb{C}$ gibt, sodass

$$A\mathbf{x} = \lambda\mathbf{x}.$$

Der Skalar λ wird **Eigenwert** von A genannt und $\mathbf{x}$ auch der **zu λ gehörige Eigenvektor**.

Komplexe Eigenwerte

Beispiel

- Für die vorherige Rotationsmatrix finden wir für $\lambda = i$ den Eigenvektor $(1, -i)$, denn

$$\begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ -i \end{pmatrix} = \begin{pmatrix} i \\ 1 \end{pmatrix} = i \begin{pmatrix} 1 \\ -i \end{pmatrix}.$$

Komplexe Eigenwerte

Beispiel

- Für die vorherige Rotationsmatrix finden wir für $\lambda = i$ den Eigenvektor $(1, -i)$, denn

$$\begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ -i \end{pmatrix} = \begin{pmatrix} i \\ 1 \end{pmatrix} = i \begin{pmatrix} 1 \\ -i \end{pmatrix}.$$

- Zum Eigenwert $\lambda = -i$ finden wir den Eigenvektor $(1, i)$:

$$\begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ i \end{pmatrix} = \begin{pmatrix} -i \\ 1 \end{pmatrix} = -i \begin{pmatrix} 1 \\ i \end{pmatrix}.$$

Theorem

Sei $A \in \mathbb{R}^{n \times n}$, λ ein Eigenwert von A und $\mathbf{v}$ ein zugehöriger Eigenvektor. Dann ist auch $\bar{\lambda}$ ein Eigenwert von A und $\bar{\mathbf{v}}$ ein zugehöriger Eigenvektor.

Quiz

Gegeben sei $A = \begin{pmatrix} 0 & 2 \\ -2 & 0 \end{pmatrix}$. Außerdem ist $2i$ Eigenwert von A .
Wie sieht der zweite Eigenwert aus?

- A. $-i$
- B. -2
- C. -1
- D. $-2i$

Quiz

Gegeben sei $A = \begin{pmatrix} 0 & 2 \\ -2 & 0 \end{pmatrix}$. Was ist der Eigenvektor zum Eigenwert $2i$ von A ?

A. $\begin{pmatrix} -i \\ 1 \end{pmatrix}$

B. $\begin{pmatrix} -2i \\ 1 \end{pmatrix}$

C. $\begin{pmatrix} -1 \\ 2i \end{pmatrix}$

D. $\begin{pmatrix} 1 \\ -2i \end{pmatrix}$

Agenda

1 Komplexe Eigenwerte

2 Hauptkomponentenanalyse

3 Markovketten und Google

Hauptkomponentenanalyse

Idee:

- Angenommen unsere Daten bestehen aus d Variablen.
- Eine Realisierung können wir dann als Vektor $\mathbf{x} \in \mathbb{R}^d$ schreiben.
- Den zugehörigen Zufallsvektor schreiben wir als $\mathbf{X} \in \mathbb{R}^d$.
- Sei $\Sigma = \text{Cov}(\mathbf{X})$ die Kovarianzmatrix von $\mathbf{X}$.

Hauptkomponentenanalyse

- Je größer d , desto unüberschaubarer die Menge an Information in Σ .

Hauptkomponentenanalyse

- Je größer d , desto unüberschaubarer die Menge an Information in Σ .
- Lösung: Wir diagonalisieren Σ .
- Dann gilt

$$\Sigma = P\Lambda P^{-1},$$

wobei $P = (\mathbf{v}_1 \cdots \mathbf{v}_n)$ und $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$.

Hauptkomponentenanalyse

- O.B.d.A seien die Eigenwerte der Größe nach geordnet:
 $\lambda_1 \geq \lambda_2 \geq \dots \geq 0$.
- Der Eigenvektor $\mathbf{v}_1$ gibt die Richtung mit der größten Variabilität vor.
- $\mathbf{v}_n$ ist die Richtung mit geringsten Variabilität.
- Um die Daten zu verstehen oder die Dimension zu reduzieren, beschränken wir uns auf die Richtungen der ersten paar Eigenvektoren.

Hauptkomponentenanalyse

Illustration: 100 Datenpunkte in $\mathbb{R}^2$




Abbildung: Links: Datenpunkte und die Hauptkomponenten. Rechts: Die Gleichen Daten in der Eigenvektorbasis.

Hauptkomponentenanalyse

```
1  Sig <- cov(data)
2  #>      [,1]      [,2]
3  #> [1,] 1.787125 1.111877
4  #> [2,] 1.111877 1.080091
```

```
1  eig <- eigen(Sig)
2  eig$values
3  #> [1] 2.6003321 0.2668837
4  eig$vectors
5  #>      [,1]      [,2]
6  #> [1,] -0.8071555 0.5903389
7  #> [2,] -0.5903389 -0.8071555
```

Anwendung

- Anwendung auf den Münchner Mietmarkt.¹
- Ziel war es zu überprüfen, ob manche Bevölkerungsgruppen bei der Wohnungssuche diskriminiert werden.

¹<http://www.hanna-und-ismail.de>

Anwendung

- Anwendung auf den Münchner Mietmarkt.¹
- Ziel war es zu überprüfen, ob manche Bevölkerungsgruppen bei der Wohnungssuche diskriminiert werden.

```
1 head(data)
2 #> # A tibble: 6 x 6
3 #>   preis zimmer flaeche deutsch männlich einladung
4 #>   <dbl>  <dbl>   <dbl>   <dbl>   <dbl>   <dbl>
5 #> 1    890      2    51.2      1       0       1
6 #> 2    890      2    51.2      0       0       1
7 #> 3    890      2    51.2      0       0       1
8 #> 4    910      2    54.5      0       1       1
9 #> 5    850      2     50      0       0       1
10 #> 6    850      2     50      1       0       0
```

¹<http://www.hanna-und-ismail.de>

Anwendung

- Diagonalisierung auf die Korrelationsmatrix angewendet:

```
1 R <- cor(data)
2 eig <- eigen(R)
3 lambda <- round(eig$values, 1)
4 lambda
5 #> [1] 2.3 1.2 1.0 0.8 0.6 0.1
6 P <- round(eig$vectors, 1)
7 rownames(P) <- names(data)
8 P
9 #>           [,1] [,2] [,3] [,4] [,5] [,6]
10 #> preis      -0.4 -0.4 -0.1 -0.3  0.7 -0.2
11 #> zimmer     -0.6  0.1  0.1  0.0 -0.5 -0.6
12 #> flaeche    -0.6 -0.1  0.1 -0.1 -0.2  0.7
13 #> deutsch    0.1 -0.6  0.5  0.6  0.0  0.0
14 #> männlich   0.0 -0.4 -0.9  0.3 -0.1  0.0
15 #> einladung  0.3 -0.6  0.1 -0.7 -0.4  0.0
```

Agenda

1 Komplexe Eigenwerte

2 Hauptkomponentenanalyse

3 Markovketten und Google

Markovketten und Google

- Angenommen es gibt nur 5 Webseiten zu einem Suchbegriff.
- Manche der Webseiten haben Links zu anderen.
- Die Suchmaschine versucht die Webseiten in eine Rangliste zu ordnen.
- Die grobe Idee ist, dass Seiten, zu denen mehr Links bestehen, wichtiger sind.

Markovketten und Google

- Modell: Ein idiotischer Nutzer Bob surft endlos durch das Web (bestehend aus 5 Seiten) und klickt wahllos auf Links.

Markovketten und Google

- Modell: Ein idiotischer Nutzer Bob surft endlos durch das Web (bestehend aus 5 Seiten) und klickt wahllos auf Links.
- Wahrscheinlichkeiten, dass Bob nach t Schritten auf einer der 5 Webseiten ist:

$$\mathbf{p}^{(t)} = \begin{pmatrix} \mathbb{P}(S^{(t)} = 1) \\ \mathbb{P}(S^{(t)} = 2) \\ \mathbb{P}(S^{(t)} = 3) \\ \mathbb{P}(S^{(t)} = 4) \\ \mathbb{P}(S^{(t)} = 5) \end{pmatrix} \in \mathbb{R}^5.$$

Markovketten und Google

- Modell: Ein idiotischer Nutzer Bob surft endlos durch das Web (bestehend aus 5 Seiten) und klickt wahllos auf Links.
- Wahrscheinlichkeiten, dass Bob nach t Schritten auf einer der 5 Webseiten ist:

$$\mathbf{p}^{(t)} = \begin{pmatrix} \mathbb{P}(S^{(t)} = 1) \\ \mathbb{P}(S^{(t)} = 2) \\ \mathbb{P}(S^{(t)} = 3) \\ \mathbb{P}(S^{(t)} = 4) \\ \mathbb{P}(S^{(t)} = 5) \end{pmatrix} \in \mathbb{R}^5.$$

- Die Wahrscheinlichkeiten zum Zeitpunkt $t + 1$ modellieren wir durch

$$M = \begin{pmatrix} \mathbb{P}(S^{(t+1)} = 1 \mid S^{(t)} = 1) & \cdots & \mathbb{P}(S^{(t+1)} = 1 \mid S^{(t)} = 5) \\ \vdots & & \vdots \\ \mathbb{P}(S^{(t+1)} = 5 \mid S^{(t)} = 1) & \cdots & \mathbb{P}(S^{(t+1)} = 5 \mid S^{(t)} = 5) \end{pmatrix} \in \mathbb{R}^{5 \times 5}.$$

Markovketten und Google

- M könnte zum Beispiel so aussehen:

$$M = \begin{pmatrix} 0 & 1/2 & 0 & 0 & 1/4 \\ 1/3 & 0 & 1/2 & 1/3 & 1/4 \\ 1/3 & 0 & 0 & 1/3 & 1/4 \\ 0 & 1/2 & 0 & 0 & 1/4 \\ 1/3 & 0 & 1/2 & 1/3 & 0 \end{pmatrix}.$$

- Seite 1 hat Links zu Seiten 2, 3 und 5.
- Seite 2 hat Links zu Seiten 1 und 4, usw.

Markovketten und Google

- Allgemein gilt: $\boldsymbol{p}^{(t)} = M^{t-1} \boldsymbol{p}^{(1)}$.
- Sei

$$\boldsymbol{p}^{(1)} = \begin{pmatrix} 1/5 \\ 1/5 \\ 1/5 \\ 1/5 \\ 1/5 \end{pmatrix}.$$

Markovketten und Google

- Allgemein gilt: $\mathbf{p}^{(t)} = M^{t-1} \mathbf{p}^{(1)}$.
- Sei

$$\mathbf{p}^{(1)} = \begin{pmatrix} 1/5 \\ 1/5 \\ 1/5 \\ 1/5 \\ 1/5 \end{pmatrix}.$$

- Dann sind zum Beispiel:

$$\mathbf{p}^{(3)} \approx \begin{pmatrix} 0.200 \\ 0.250 \\ 0.158 \\ 0.200 \\ 0.192 \end{pmatrix}, \quad \mathbf{p}^{(5)} \approx \begin{pmatrix} 0.183 \\ 0.259 \\ 0.168 \\ 0.183 \\ 0.206 \end{pmatrix}, \quad \mathbf{p}^{(10)} \approx \begin{pmatrix} 0.181 \\ 0.259 \\ 0.172 \\ 0.181 \\ 0.207 \end{pmatrix}.$$

Markovketten und Google

- Wir erreichen also einen Gleichgewichtszustand $\mathbf{q}$.

- Wir erreichen also einen Gleichgewichtszustand $\mathbf{q}$.

Theorem

Sei $M \in \mathbb{R}^{n \times n}$ eine Matrix, des Spalten sich zu 1 summieren. Dann hat M den Eigenwert 1.

- Nicht für jede Matrix M konvergiert die Kette unabhängig von $\mathbf{p}^{(1)}$ immer zum Gleichgewichtszustand $\mathbf{q}$.
- Sei $M = P\Lambda P^{-1}$, wobei P die Eigenvektormatrix und $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ ist.

- Nicht für jede Matrix M konvergiert die Kette unabhängig von $\mathbf{p}^{(1)}$ immer zum Gleichgewichtszustand $\mathbf{q}$.
- Sei $M = P\Lambda P^{-1}$, wobei P die Eigenvektormatrix und $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ ist.
- Es gilt

$$\lim_{n \rightarrow \infty} M^n = P \left(\lim_{n \rightarrow \infty} \Lambda^n \right) P^{-1} = P \text{diag} \left(\lim_{n \rightarrow \infty} \lambda_1^n, \dots, \lim_{n \rightarrow \infty} \lambda_d^n \right) P^{-1}.$$

- Damit λ^n konvergiert, muss $\lambda \in (-1, 1]$ gelten.

Markovketten und Google

Beispiel:

- Sei

$$M = \begin{pmatrix} 0 & 1 & 0 & 0 & 1/4 \\ 1 & 0 & 1/2 & 1/3 & 1/4 \\ 0 & 0 & 0 & 1/3 & 1/4 \\ 0 & 0 & 0 & 0 & 1/4 \\ 0 & 0 & 1/2 & 1/3 & 0 \end{pmatrix}.$$

Markovketten und Google

Beispiel:

- Sei

$$M = \begin{pmatrix} 0 & 1 & 0 & 0 & 1/4 \\ 1 & 0 & 1/2 & 1/3 & 1/4 \\ 0 & 0 & 0 & 1/3 & 1/4 \\ 0 & 0 & 0 & 0 & 1/4 \\ 0 & 0 & 1/2 & 1/3 & 0 \end{pmatrix}.$$

- Dann ist -1 ein Eigenwert, denn

$$\begin{pmatrix} 0 & 1 & 0 & 0 & 1/4 \\ 1 & 0 & 1/2 & 1/3 & 1/4 \\ 0 & 0 & 0 & 1/3 & 1/4 \\ 0 & 0 & 0 & 0 & 1/4 \\ 0 & 0 & 1/2 & 1/3 & 0 \end{pmatrix} \begin{pmatrix} -1 \\ 1 \\ 0 \\ 0 \\ 0 \end{pmatrix} = -1 \cdot \begin{pmatrix} -1 \\ 1 \\ 0 \\ 0 \\ 0 \end{pmatrix}.$$

- Also kann M^n nicht konvergieren.

Der PageRank-Algorithmus

- Eine weniger idiotische Nutzerin Alice springt manchmal auch zu einer beliebigen Seite im Web.
- Sei $\delta > 0$ die Wahrscheinlichkeit, dass Alice sich entscheidet, eine beliebige Seite aufzurufen.

Der PageRank-Algorithmus

- Eine weniger idiotische Nutzerin Alice springt manchmal auch zu einer beliebigen Seite im Web.
- Sei $\delta > 0$ die Wahrscheinlichkeit, dass Alice sich entscheidet, eine beliebige Seite aufzurufen.
- Dann ist die neue Übergangsmatrix

$$\tilde{M} = (1 - \delta)M + \frac{\delta}{n} \mathbf{1}_{n \times n},$$

wobei alle Einträge der Matrix $\mathbf{1}_{n \times n} \in \mathbb{R}^{n \times n}$ gleich 1 sind.

- In $\tilde{M}$ sind alle Einträge strikt positiv und damit -1 kein Eigenwert.

Wrap-up

Heute gelernt

- Komplexe Eigenwerte
- Hauptkomponentenanalyse
- Markovketten und Google

Nächste Vorlesung

- Skalarprodukt und Orthogonalität