



LUDWIG-
MAXIMILIANS-
UNIVERSITÄT
MÜNCHEN

21. Quadratische Formen

Methoden der Linearen Algebra in der Statistik
Thomas Nagler <t.nagler@lmu.de>

Agenda

1 Definition und Motivation

2 Hauptsachsentheorem

3 Definitheit

4 Variationelle Charakterisierung von Eigenwerten

Agenda

1 Definition und Motivation

2 Hauptsachsentheorem

3 Definitheit

4 Variationelle Charakterisierung von Eigenwerten

Definition und Motivation

- Bisher ging es um lineare Funktionen $\mathbb{R}^n \rightarrow \mathbb{R}^m, \mathbf{x} \mapsto A\mathbf{x}$.
- Sie sind das höherdimensionale Äquivalent zu einer Geraden $f(x) = ax$ im Falle $\mathbb{R} \rightarrow \mathbb{R}$.

Definition und Motivation

- Bisher ging es um lineare Funktionen $\mathbb{R}^n \rightarrow \mathbb{R}^m, \mathbf{x} \mapsto A\mathbf{x}$.
- Sie sind das höherdimensionale Äquivalent zu einer Geraden $f(x) = ax$ im Falle $\mathbb{R} \rightarrow \mathbb{R}$.
- *Quadratische Formen* verallgemeinern quadratische Funktionen $f(x) = ax^2 = xax$ in höhere Dimensionen.

Definition und Motivation

- Bisher ging es um lineare Funktionen $\mathbb{R}^n \rightarrow \mathbb{R}^m, \mathbf{x} \mapsto A\mathbf{x}$.
- Sie sind das höherdimensionale Äquivalent zu einer Geraden $f(x) = ax$ im Falle $\mathbb{R} \rightarrow \mathbb{R}$.
- *Quadratische Formen* verallgemeinern quadratische Funktionen $f(x) = ax^2 = xax$ in höhere Dimensionen.

Definition

Eine **quadratische Form** auf $\mathbb{R}^n$ ist eine Funktion $Q: \mathbb{R}^n \rightarrow \mathbb{R}$ gegeben durch $Q(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x}$, wobei $A \in \mathbb{R}^{n \times n}$ eine symmetrische Matrix ist.

Definition und Motivation

- Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine hinreichend glatte Funktion und $\mathbf{x}^*$ der Punkt, der diese Funktion minimiert.

Definition und Motivation

- Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine hinreichend glatte Funktion und $\mathbf{x}^*$ der Punkt, der diese Funktion minimiert.
- Taylor's theorem:

$$f(\mathbf{x}) \approx \underbrace{f(\mathbf{x}^*)}_{\text{konstant}} + \underbrace{\nabla f(\mathbf{x}^*)}_{=0}(\mathbf{x} - \mathbf{x}^*) + \underbrace{\frac{1}{2}(\mathbf{x} - \mathbf{x}^*)^\top H(\mathbf{x}^*)(\mathbf{x} - \mathbf{x}^*)}_{\text{quadratische form}},$$

wobei

- ▶ Gradient $\nabla f = (\partial f / \partial x_1, \dots, \partial f / \partial x_n)$ der
- ▶ Hesse-Matrix $H = \nabla^2 f = (\partial^2 f / \partial x_i \partial x_j)_{i,j=1}^n$.

Quiz

Gegeben sei eine quadratische Funktion $4x_1^2 - 9x_2^2 - 6x_1x_2$.

Wie sieht die Matrixschreibweise $\mathbf{x}^T A \mathbf{x}$ dazu aus, wenn zudem A symmetrisch ist?

A. $(x_1 \ x_2) \begin{pmatrix} 4 & -3 \\ -3 & 9 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$

B. $(x_1 \ x_2) \begin{pmatrix} 4 & 3 \\ 3 & 9 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$

C. $(x_1 \ x_2) \begin{pmatrix} -4 & 3 \\ 3 & 9 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$

D. $(x_1 \ x_2) \begin{pmatrix} 4 & -3 \\ -3 & -9 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$

Agenda

1 Definition und Motivation

2 Hauptsachsentheorem

3 Definitheit

4 Variationelle Charakterisierung von Eigenwerten

Hauptachsentheorem

$$Q(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x} = \sum_{i=1}^n a_{ii} x_i^2 + \sum_{i=1}^n \sum_{j \neq i} a_{ij} x_i x_j,$$

beinhaltet sowohl rein quadratische Terme $a_{ii} x_i^2$ und gemischte Terme $a_{ij} x_i x_j$.

Hauptsachsentheorem

$$Q(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x} = \sum_{i=1}^n a_{ii} x_i^2 + \sum_{i=1}^n \sum_{j \neq i} a_{ij} x_i x_j,$$

beinhaltet sowohl rein quadratische Terme $a_{ii} x_i^2$ und gemischte Terme $a_{ij} x_i x_j$.

Theorem (Hauptsachsentheorem)

Sei $A \in \mathbb{R}^{n \times n}$ eine symmetrische Matrix, die durch P orthogonal zur Matrix $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ diagonalisiert wird. Dann gilt für $\mathbf{y} = P^\top \mathbf{x}$,

$$\mathbf{x}^\top A \mathbf{x} = \mathbf{y}^\top \Lambda \mathbf{y} = \sum_{i=1}^n \lambda_i y_i^2.$$

Hauptachsentheorem

- In Richtung $\mathbf{p}_i$ entspricht die Funktion Q einer simplen Parabel $\lambda_i y_i^2$.
- Der Eigenwert λ_i gibt dabei die Stärke und Richtung der Krümmung vor.
- Die gesamte Funktion Q lässt sich als Summe von solchen einfachen Parabeln in zueinander orthogonalen Richtungen zusammensetzen.

Agenda

1 Definition und Motivation

2 Hauptsachsentheorem

3 Definitheit

4 Variationelle Charakterisierung von Eigenwerten

Definition

Sei $A \in \mathbb{R}^{n \times n}$ symmetrisch und $Q(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x}$ die zugehörige quadratische Form. Dann nennen wir A und Q

- **positiv definit**, wenn $Q(\mathbf{x}) > 0$ für alle $\mathbf{x} \neq 0$;
- **positiv semidefinit**, wenn $Q(\mathbf{x}) \geq 0$ für alle $\mathbf{x} \neq 0$;
- **negativ definit**, wenn $Q(\mathbf{x}) < 0$ für alle $\mathbf{x} \neq 0$;
- **negativ semidefinit**, wenn $Q(\mathbf{x}) \leq 0$ für alle $\mathbf{x} \neq 0$;
- **indefinit**, wenn sowohl $Q(\mathbf{x}) > 0$ für ein $\mathbf{x} \in \mathbb{R}^n$ also auch $Q(\mathbf{x}) < 0$ für ein anderes $\mathbf{x} \in \mathbb{R}^n$.

Definitheit







Abbildung: Graphen von quadratischen Formen $Q: \mathbb{R}^2 \rightarrow \mathbb{R}$. (Fig 7.2.4 in [LLM].)

Theorem

Sei $A \in \mathbb{R}^{n \times n}$ symmetrisch. Dann ist die quadratische Form $Q(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x}$ genau dann ...

- (i) positiv definit, wenn alle Eigenwerte strikt positiv sind;
- (ii) positiv semidefinit, wenn alle Eigenwerte nichtnegativ sind;
- (iii) negativ definit, wenn alle Eigenwerte strikt negativ sind;
- (iv) negativ semidefinit, wenn alle Eigenwerte nichtpositiv sind;
- (v) indefinit, wenn es einen strikt positiven und einen strikt negativen Eigenwert gibt.

Quiz

Beweise oder widerlege:

Wenn $A \in \mathbb{R}^{n \times n}$ invertierbar ist, dann ist $A^\top A$ positiv definit.

- A. Wahr
- B. Falsch

Agenda

1 Definition und Motivation

2 Hauptsachsentheorem

3 Definitheit

4 Variationelle Charakterisierung von Eigenwerten

Theorem

Sei $A \in \mathbb{R}^{n \times n}$ symmetrisch mit der Größe nach geordneten Eigenwerten $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$. Dann gilt

$$\lambda_n = \min_{\|\mathbf{x}\|=1} \mathbf{x}^\top A \mathbf{x} \leq \max_{\|\mathbf{x}\|=1} \mathbf{x}^\top A \mathbf{x} = \lambda_1.$$

Das Minimum wird für einen Eigenvektor zu λ_n , das Maximum für einen Eigenvektor zu λ_1 angenommen.

Variationelle Charakterisierung




Abbildung: Graph der quadratischen Form $Q(\mathbf{x}) = 3x_1^2 + 7x_2^2$ (links) und die Einschränkung auf $\|\mathbf{x}\| = 1$ (rechts). Das Maximum des rechten Graphen ist der größte Eigenwert ($\lambda_1 = 7$), das Minimum der kleinste Eigenwert $\lambda_2 = 3$. (Fig 7.3.1–2 in [LLM].)

Theorem

Sei $A \in \mathbb{R}^{n \times n}$ symmetrisch mit der Größe nach geordneten Eigenwerten $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ und zugehörigen orthonormalen Eigenvektoren $\mathbf{p}_1, \dots, \mathbf{p}_n$. Dann gilt für alle $k = 1, \dots, n$:

$$\lambda_k = \max_{\substack{\|\mathbf{x}\|=1 \\ \mathbf{x} \perp \text{span}\{\mathbf{p}_1, \dots, \mathbf{p}_{k-1}\}}} \mathbf{x}^\top A \mathbf{x} = \min_{\substack{\|\mathbf{x}\|=1 \\ \mathbf{x} \perp \text{span}\{\mathbf{p}_{k+1}, \dots, \mathbf{p}_n\}}} \mathbf{x}^\top A \mathbf{x}.$$

Das Maximum/Minimum wird jeweils für einen Eigenvektor zu λ_k angenommen.

Theorem

Sei $A \in \mathbb{R}^{n \times n}$ symmetrisch mit der Größe nach geordneten Eigenwerten $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ und zugehörigen orthonormalen Eigenvektoren $\mathbf{p}_1, \dots, \mathbf{p}_n$. Dann gilt für alle $k = 1, \dots, n$:

$$\lambda_k = \max_{\substack{\|\mathbf{x}\|=1 \\ \mathbf{x} \perp \text{span}\{\mathbf{p}_1, \dots, \mathbf{p}_{k-1}\}}} \mathbf{x}^\top A \mathbf{x} = \min_{\substack{\|\mathbf{x}\|=1 \\ \mathbf{x} \perp \text{span}\{\mathbf{p}_{k+1}, \dots, \mathbf{p}_n\}}} \mathbf{x}^\top A \mathbf{x}.$$

Das Maximum/Minimum wird jeweils für einen Eigenvektor zu λ_k angenommen.

→ Diese Charakterisierung hilft uns bei der Interpretation der PCA.

Variationelle Charakterisierung in PCA

- Angenommen ein Zufallsvektor $\mathbf{Y} \in \mathbb{R}^n$ hat Kovarianzmatrix $\text{Cov}(\mathbf{Y}) = \Sigma$.
- Dann folgt aus der Linearität der Kovarianz, dass $\text{Var}(\mathbf{x}^\top \mathbf{Y}) = \mathbf{x}^\top \Sigma \mathbf{x}$ für jede (deterministische) Richtung $\mathbf{x} \in \mathbb{R}^n, \|\mathbf{x}\| = 1$.

Variationelle Charakterisierung in PCA

- Angenommen ein Zufallsvektor $\mathbf{Y} \in \mathbb{R}^n$ hat Kovarianzmatrix $\text{Cov}(\mathbf{Y}) = \Sigma$.
- Dann folgt aus der Linearität der Kovarianz, dass $\text{Var}(\mathbf{x}^\top \mathbf{Y}) = \mathbf{x}^\top \Sigma \mathbf{x}$ für jede (deterministische) Richtung $\mathbf{x} \in \mathbb{R}^n, \|\mathbf{x}\| = 1$.
- Die erste Hauptkomponente $\mathbf{p}_1$ von Σ ist die Richtung mit der größten Varianz und diese Varianz ist gleich λ_1 .

Variationelle Charakterisierung in PCA

- Angenommen ein Zufallsvektor $\mathbf{Y} \in \mathbb{R}^n$ hat Kovarianzmatrix $\text{Cov}(\mathbf{Y}) = \Sigma$.
- Dann folgt aus der Linearität der Kovarianz, dass $\text{Var}(\mathbf{x}^\top \mathbf{Y}) = \mathbf{x}^\top \Sigma \mathbf{x}$ für jede (deterministische) Richtung $\mathbf{x} \in \mathbb{R}^n, \|\mathbf{x}\| = 1$.
- Die erste Hauptkomponente $\mathbf{p}_1$ von Σ ist die Richtung mit der größten Varianz und diese Varianz ist gleich λ_1 .
- Danach suchen wir die zweite Hauptkomponente im Raum orthogonal zu $\mathbf{p}_1$ und maximieren die Varianz unter den verbleibenden Richtungen, etc.

Theorem (Minimum-Maximum-Prinzip)

Sei $A \in \mathbb{R}^{n \times n}$ symmetrisch mit der Größe nach geordneten Eigenwerten $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$. Dann gilt für alle $k = 1, \dots, n$:

$$\begin{aligned}\lambda_k &= \max_{\dim(V)=k} \min_{\substack{\mathbf{x} \in V \\ \|\mathbf{x}\|=1}} \mathbf{x}^\top A \mathbf{x} \\ &= \min_{\dim(V)=n-k+1} \max_{\substack{\mathbf{x} \in V \\ \|\mathbf{x}\|=1}} \mathbf{x}^\top A \mathbf{x},\end{aligned}$$

wobei V jeweils ein Untervektorraum des $\mathbb{R}^n$ ist. Das Maximum/Minimum wird jeweils für einen Eigenvektor zu λ_k angenommen.

Quiz

Welche der folgenden Aussagen sind wahr?

- A. Wenn alle Eigenwerte einer symmetrischen Matrix A positiv sind, dann ist A positiv definit.
- B. $x_1^2 - x_2^2 + x_3^2 + 4x_1x_2x_3$ ist eine quadratische Form.
- C. $(x_1 - 3x_2)^2$ ist eine quadratische Form.
- D. Eine positiv definite Matrix ist invertierbar.
- E. Eine symmetrische Matrix ist entweder positiv definit, negativ definit oder indefinit.
- F. Wenn A eine positiv definite Matrix ist, dann ist $-A$ negativ definit.
- G. $x \cdot x$ ist eine quadratische Form für alle $x \in \mathbb{R}^n$.
- H. Wenn die symmetrische Matrix A nur positive Eigenwerte besitzt, dann ist $x^T Ax$ eine positiv definite quadratische Form.

Wrap-up

Heute gelernt

- Definition und Motivation
- Hauptachsentheorem
- Definitheit
- Variationelle Charakterisierung von Eigenwerten